



Université de Montpellier Paul Valéry

Mémoire de fin de première année de Master

Modélisation des comportements de santé par apprentissage automatique : régression, classification et clustering sur données synthétiques

Étudiant ARDACHAM Mahamat Teguene

Formation Master 1 MIASHS

Tuteurs universitaires Sophie Lèbre & Jérôme Pasquet

Année universitaire 2025–2026

Juin 2026

Remerciements

Je tiens tout d’abord à remercier **Madame Sophie Lèbre** et **Monsieur Jérôme Pasquet**, mes tuteurs universitaires, pour leurs enseignements, leurs conseils tout au long de cette année, ainsi que pour la validation du sujet de ce mémoire.

Je remercie l’ensemble des enseignants du master **MIASHS** de l’Université de Montpellier Paul Valéry, dont les cours ont directement nourri ce projet : **Maximilien Servagean**, **Catherine Trottier**, **Maïlis Amico**, **Arnaud Sallaberry**, **Sandra Bringay**, **Marine Demangeot** et al. Leurs enseignements en machine learning, statistique, visualisation, optimisation, . . . m’ont donné les outils nécessaires pour mener à bien cette analyse.

Je remercie également ma famille pour son soutien indéfectible tout au long de cette année, ainsi que mes amis et camarades de promotion, en particulier **ANZIZA Ahamada Madi**, pour les échanges, l’entraide et les moments partagés durant cette première année de master.

Résumé

Ce mémoire porte sur un projet de data science appliqué à la santé et aux modes de vie, avec pour objectif de modéliser des comportements à partir de données par apprentissage automatique. Le contexte médical s'appuie sur des seuils reconnus : obésité (IMC > 30 selon l'OMS, Organisation Mondiale de la Santé [1]), hypercholestérolémie (cholestérol > 200 mg/dL selon le NCEP, National Cholesterol Education Program [2]), hypertension (pression systolique ≥ 140 mmHg selon l'ESC, European Society of Cardiology [3]). Le jeu de données utilisé est le *Health & Lifestyle Dataset*, un dataset synthétique de 100 000 individus décrits par 15 variables : habitudes de vie (activité physique, sommeil, alimentation, tabagisme, alcool) et indicateurs biologiques (IMC, cholestérol, pression artérielle, fréquence cardiaque).

J'ai mis en place un pipeline complet selon la méthodologie CRISP-DM (Cross-Industry Standard Process for Data Mining) [4], allant de l'exploration des données jusqu'à l'interprétabilité des modèles. L'analyse exploratoire et le feature engineering ont permis de préparer les données : encodage des variables catégorielles, création de trois variables métier (score de style de vie composite, catégorie IMC, hypertension), standardisation. En **régression**, j'ai comparé six modèles (régression linéaire, Ridge, Lasso, ElasticNet, Random Forest, XGBoost) pour prédire le taux de cholestérol, avec tuning par `RandomizedSearchCV` et validation croisée K-Fold ($k = 5$). Un data leakage a été détecté et corrigé sur la variable `hypercholesterol` : le R^2 artificiel de 0.675 s'est réduit à ≈ 0 après sa suppression. En **classification**, trois modèles ont prédit le risque de maladie (`disease_risk`), avec deux stratégies de gestion du déséquilibre des classes comparées : ajustement des poids (`class_weight='balanced'`) et rééchantillonnage SMOTE [5]. En **clustering**, K-Means ($k = 3$) a révélé trois profils biologiques et la CAH (liaison Ward, sous-échantillon de 5 000 individus) a isolé un groupe de fumeurs intenses hypertendus ; les clusters ont été visualisés par ACP (24.3% de variance en 2D). L'**interprétabilité** a été analysée via les coefficients des modèles linéaires, les feature importances et SHAP (utilisé ici comme complément visuel).

Le résultat principal est une **limite fondamentale du dataset synthétique** : les variables ont été générées indépendamment, sans aucune relation causale. Aucun modèle n'a fait mieux qu'un prédicteur naïf ($R^2 \approx 0$, $AUC \approx 0.5$) le Lasso annule les 16 coefficients, le Random Forest atteint $R^2 = -0.005$. La divergence entre les cinq méthodes d'interprétabilité le confirme. Ce n'est pas un échec méthodologique : c'est la rigueur du pipeline qui a permis de le détecter. Ce travail est directement transposable à des données épidémiologiques réelles.

Mots-clés : data science, santé, machine learning, régression, classification, clustering, interprétabilité, SHAP, SMOTE, données synthétiques, data leakage, CRISP-DM.

Note sur l'utilisation de l'intelligence artificielle

Dans le cadre de ce mémoire, j'ai eu recours à des outils d'intelligence artificielle générative — principalement **Claude** (Anthropic) — comme aide à la recherche et à la rédaction. Voici comment ces outils ont été utilisés concrètement :

- **Recherche bibliographique** : exploration et synthèse de la littérature sur les thématiques abordées (machine learning en santé, méthodes de régularisation, gestion du déséquilibre de classes, interprétabilité).
- **Structuration du document** : aide à l'organisation des chapitres et à la formulation des transitions.
- **Relecture et reformulation** : suggestions de reformulation pour améliorer la clarté des explications techniques.
- **Débogage et code** : aide au débogage des notebooks Python (scikit-learn, XGBoost, SHAP) et à la compilation $\text{\LaTeX}$.

L'ensemble du contenu scientifique — choix des modèles, interprétation des résultats, analyse critique, conclusions — a été compris, vérifié et validé par l'auteur. L'IA a servi d'outil d'assistance ; elle n'a pas remplacé le raisonnement ni le travail analytique qui constituent le cœur de ce mémoire. Toutes les erreurs éventuelles restent de ma seule responsabilité.

Table des matières

Remerciements	ii
Résumé	iii
Note sur l'utilisation de l'IA	iv
Liste des figures	vi
Liste des tableaux	vii
Introduction	1
Contexte	1
1 État de l'art	4
1.1 L'apprentissage automatique appliqué à la santé	4
1.2 Régression : prédire des indicateurs biologiques	4
1.3 Classification : prédire le risque de maladie	5
1.4 Clustering : identifier des profils de mode de vie	5
1.5 Interprétabilité des modèles	6
2 Données et analyse exploratoire	7
2.1 Analyse exploratoire des données (EDA)	7
2.1.1 Présentation générale du dataset	7
2.1.2 Statistiques descriptives	7
2.1.3 Distribution des variables	8
2.1.4 Analyse des corrélations	8
2.1.5 Bilan de l'EDA	10
2.2 Feature Engineering et préparation des données	11
2.2.1 Encodage des variables catégorielles	11
2.2.2 Création de nouvelles variables	11
2.2.3 Mise à l'échelle	12
2.2.4 Dataset final	13
3 Modélisation supervisée	14
3.1 Régression : prédire le taux de cholestérol	14
3.1.1 Objectif et variable cible	14
3.1.2 Protocole expérimental	14
3.1.3 Modèles et justification	15

3.1.4	Résultats et analyse critique	17
3.2	Classification : prédire le risque de maladie	18
3.2.1	Objectif et contexte	18
3.2.2	Protocole expérimental	18
3.2.3	Métriques d'évaluation	19
3.2.4	Résultats et analyse critique	19
4	Clustering et interprétabilité	22
4.1	Clustering : identifier des profils de mode de vie	22
4.1.1	Objectif	22
4.1.2	Préparation des données	22
4.1.3	Sélection du nombre de clusters	22
4.1.4	K-Means	23
4.1.5	Classification Hiérarchique Ascendante (CAH)	24
4.1.6	Évaluation et visualisation	25
4.2	Interprétabilité des modèles	26
4.2.1	Objectif	26
4.2.2	Outils utilisés	26
4.2.3	Résultats, convergence et analyse critique	27
5	Organisation, retour d'expérience et perspectives	30
5.1	Méthodologie et organisation	30
5.1.1	Approche CRISP-DM	30
5.1.2	Outils et environnement technique	30
5.1.3	Compétences mobilisées	30
5.2	Difficultés rencontrées et retour d'expérience	30
5.2.1	Difficultés techniques	30
5.2.2	Compétences acquises	31
5.2.3	Plus-value : diagnostiquer les biais du pipeline	31
5.2.4	Positionnement RSE / DDSRS	32
5.2.5	Limites méthodologiques	32
5.3	Perspectives	32
	Conclusion	33
	Bibliographie	34
	Liste des abréviations	36
	Lexique	37
	Annexes	38

Table des figures

1.1	Vue d'ensemble des grandes familles d'algorithmes de machine learning [7]	4
2.1	Distributions des variables continues du dataset	8
2.2	Distribution de la variable cible disease_risk (déséquilibre 75/25)	9
2.3	Matrice de corrélation de Pearson entre toutes les variables du dataset . . .	9
2.4	Corrélations de chaque variable avec la cible disease_risk	10
3.1	Courbes ROC des trois modèles de classification ($AUC \approx 0.5$ pour tous) .	20
3.2	Matrices de confusion des trois modèles de classification	21
4.1	Inertie intra-cluster et coefficient de silhouette selon k (K-Means)	23
4.2	Visualisation des clusters K-Means ($k = 3$) par projection ACP (2 compo- santes, 24.3% de variance)	26
4.3	Coefficients de la régression logistique (variables standardisées)	27
4.4	Feature importances (impureté de Gini) du Random Forest	28
4.5	SHAP summary plot (XGBoost) — complément visuel d'interprétabilité .	29

Liste des tableaux

2.1	Statistiques descriptives des variables continues	7
2.2	Bilan de l'analyse exploratoire	11
3.1	Résultats de régression (variable cible : cholesterol)	17
3.2	Résultats de classification (variable cible : disease_risk)	20
4.1	Inertie et silhouette selon k (K-Means)	23
4.2	Profils des clusters K-Means ($k = 3$)	24
4.3	Profils des clusters CAH ($k = 3, n = 5\,000$)	24
4.4	Comparaison K-Means vs CAH	25
4.5	Variables dans le top 5 de chaque méthode d'interprétabilité	28
5.1	Stack technique du projet	30
5.2	Lien entre enseignements MIASHS et applications projet	31

Introduction

Aujourd'hui, les données de santé sont partout. Les montres connectées mesurent notre sommeil, les applications comptent nos pas, les bilans sanguins enregistrent notre cholestérol. On génère sans le savoir une quantité massive d'informations sur nos habitudes de vie. Mais avoir des données ne suffit pas : encore faut-il savoir les analyser, les comprendre, et en tirer des conclusions utiles.

C'est exactement ce que permet la data science. À l'intersection des mathématiques, de la statistique et de l'informatique, elle offre des outils concrets pour explorer des jeux de données complexes, construire des modèles prédictifs et surtout, expliquer ce qui se passe derrière les chiffres.

Ce mémoire présente un projet de data science appliqué à la santé et aux modes de vie, réalisé dans le cadre de la première année de master MIASHS. La question centrale qui guide l'ensemble du travail est la suivante :

PROBLÉMATIQUE

QUELS FACTEURS DU MODE DE VIE INFLUENCENT LE PLUS L'ÉTAT DE SANTÉ D'UN INDIVIDU — ET PEUT-ON LES IDENTIFIER, LES MODÉLISER ET LES EXPLIQUER DE MANIÈRE RIGOUREUSE ?

Contexte

Contexte data science

La santé publique constitue l'un des domaines d'application les plus prometteurs de la data science [6, 7]. L'apprentissage statistique permet aujourd'hui d'aborder des problèmes variés : prédiction du risque de maladies chroniques, segmentation de populations selon leurs profils de santé, identification des facteurs de risque comportementaux [8].

Dans ce projet, l'objectif n'est pas seulement de prédire — c'est aussi et surtout de **comprendre**. Quand on prédit qu'une personne est à risque de maladie, il est crucial de pouvoir expliquer pourquoi : est-ce à cause de son manque de sommeil ? De son cholestérol élevé ? De son inactivité physique ? Cette dimension explicative est au cœur du travail présenté ici.

Contexte métier

Les maladies chroniques — maladies cardiovasculaires, diabète de type 2, hypertension — représentent aujourd'hui la première cause de mortalité mondiale [8]. Contrairement aux maladies infectieuses, elles se développent progressivement sous l'effet d'une accumulation de comportements quotidiens : sédentarité, mauvais sommeil, tabagisme, consommation d'alcool, alimentation déséquilibrée.

Ces facteurs comportementaux laissent des traces mesurables dans les indicateurs biologiques. Un **IMC** élevé (seuil OMS : 25 pour le surpoids, 30 pour l'obésité [1]) traduit un déséquilibre énergétique chronique. Un **taux de cholestérol** supérieur à 200 mg/dL signale un risque cardiovasculaire accru [2]. Une **pression artérielle** systolique ≥ 140 mmHg ou diastolique ≥ 90 mmHg indique une hypertension [3]. Ces seuils, établis par des organismes médicaux internationaux, servent de référence tout au long de ce mémoire.

L'enjeu est donc double : comprendre comment les habitudes de vie se traduisent en risques mesurables, et évaluer dans quelle mesure des modèles de machine learning peuvent capturer ces relations à partir de données observationnelles.

Présentation du jeu de données

Le projet s'appuie sur le *Health & Lifestyle Dataset*, un jeu de données synthétique disponible sur Kaggle, composé de **100 000 individus** décrits par **15 variables** :

- **Habitudes de vie** : `daily_steps`, `sleep_hours`, `water_intake_l`, `calories_consumed`, `smoker`, `alcohol`.

- **Indicateurs biologiques** : `bmi`, `resting_hr`, `systolic_bp`, `diastolic_bp`, `cholesterol`.
- **Caractéristiques personnelles** : `age`, `gender`, `family_history`.

La variable cible principale est `disease_risk`, un indicateur binaire (0/1) indiquant si un individu est considéré à risque de maladie. Bien que synthétique, ce dataset respecte des distributions statistiquement réalistes [5]. Les données synthétiques sont générées algorithmiquement et ne correspondent à aucun individu réel : elles permettent de développer et tester des méthodes sans risque de ré-identification, contrairement aux données médicales réelles qui sont soumises au Règlement Général sur la Protection des Données (RGPD) [9].

Lien avec la formation

Ce projet est directement ancré dans les enseignements du master MIASHS : réduction de dimension avec l'**ACP**, **régression linéaire et logistique**, **classification supervisée et non supervisée**, **régularisation et optimisation** (Ridge, Lasso, descente de gradient), et **méthodes ensemblistes** (Random Forest, XGBoost). Toutes ces notions sont mises en pratique ici de manière concrète, sur un problème à enjeu sociétal fort. Le deep learning, abordé en cours, n'est pas appliqué dans ce projet : les données tabulaires de taille modérée ne justifient pas son recours face aux méthodes ensemblistes [10].

Objectifs du projet

Le projet s'articule autour de quatre axes complémentaires :

1. **Analyse exploratoire** — comprendre la structure des données, les distributions, les corrélations, et formuler des hypothèses.
2. **Régression** — prédire des indicateurs biologiques continus comme le taux de cholestérol.
3. **Classification** — prédire le risque de maladie (`disease_risk`) et comparer plusieurs algorithmes.
4. **Clustering** — découvrir des profils types d'individus selon leur mode de vie.

Chapitre 1 : État de l’art

1.1 L’apprentissage automatique appliqué à la santé

L’apprentissage automatique a vraiment pris de l’ampleur en santé ces dernières années. Les travaux d’Obermeyer & Emanuel [6] ont montré que les algorithmes de ML peuvent faire mieux que les méthodes statistiques classiques pour anticiper des événements cliniques — ce qui n’est pas rien. Plus récemment, une revue dans *Nature Medicine* [7] dresse un panorama de l’état de l’art : diagnostic médical assisté par IA, prédiction du risque de maladies chroniques, personnalisation des traitements.

Ce qui m’intéresse ici, c’est cette idée que les maladies chroniques ne tombent pas du ciel : elles se développent progressivement à partir de comportements quotidiens mesurables [8]. Et si ces comportements laissent des traces dans les données, on devrait pouvoir les modéliser.




FIGURE 1.1 – Vue d’ensemble des grandes familles d’algorithmes de machine learning [7]

1.2 Régression : prédire des indicateurs biologiques

La régression linéaire reste l’une des méthodes les plus utilisées en statistique appliquée à la santé [11]. Mais elle a des hypothèses fortes, d’où le développement de variantes plus robustes. La régression Ridge [12] ajoute une pénalité $\lambda \|\mathbf{w}\|_2^2$ qui réduit les coefficients sans jamais les annuler — utile quand les variables sont peu informatives. La régression Lasso [13] utilise une pénalisation L_1 qui force certains coefficients exactement à zéro, ce qui revient à une **sélection automatique de variables** — c’est une propriété vraiment pratique.

Pour les données tabulaires, les méthodes ensemblistes comme les **forêts aléatoires** [14] et le **gradient boosting** (XGBoost [15]) donnent souvent de meilleurs résultats, en capturant les relations non-linéaires entre variables que la régression linéaire classique ne peut pas détecter.

1.3 Classification : prédire le risque de maladie

Prédire le risque de maladie est probablement le cas d'usage le plus étudié en santé numérique. Des modèles de classification ont été appliqués avec succès à la prédiction du diabète de type 2, des maladies cardiovasculaires ou encore de l'hypertension [7].

Parmi les algorithmes couramment utilisés :

- La **régression logistique** [11], modèle linéaire interprétable de référence.
- Les **forêts aléatoires** [14] et le **gradient boosting** [15], qui dominent les benchmarks sur données tabulaires.

Un point de vigilance important est le **déséquilibre des classes** [16] : dans notre dataset, 75,2% des individus sont sans risque contre seulement 24,8% à risque. Un modèle naïf qui prédit toujours "sans risque" atteint déjà 75% d'accuracy — sans rien apprendre du tout.

Pour corriger ce biais, deux stratégies sont principalement utilisées. L'**ajustement des poids de classe** (`class_weight='balanced'`) pénalise davantage les erreurs sur la classe minoritaire pendant l'entraînement, sans modifier les données. Le **SMOTE** [5] (*Synthetic Minority Over-sampling Technique*) adopte une approche différente : il crée synthétiquement de nouveaux exemples de la classe minoritaire en interpolant entre observations existantes. Pour un individu x_i et l'un de ses k plus proches voisins x_{nn} dans la classe minoritaire :

$$x_{\text{new}} = x_i + \lambda \cdot (x_{nn} - x_i), \quad \lambda \in [0, 1] \quad (1.1)$$

J'ai appliqué et comparé les deux stratégies dans ce projet. Comme on le verra, aucune ne parvient à améliorer significativement l'AUC : cela confirme que le problème vient de l'absence de signal dans les données, et non du déséquilibre des classes.

1.4 Clustering : identifier des profils de mode de vie

Le clustering vise à regrouper des individus similaires sans variable cible prédéfinie [17]. En santé, cette approche est utilisée pour la **stratification de patients** [8] — identifier des groupes à profils similaires pour adapter la prise en charge.

L'algorithme **K-Means** [17] est la méthode de référence. La **classification hiérarchique ascendante (CAH)** propose une représentation visuelle via le dendrogramme. Pour évaluer la qualité d'un clustering, j'utilise le **coefficient de silhouette** [18] :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (1.2)$$

où $a(i)$ est la distance moyenne de l'observation i aux autres points de son cluster, et $b(i)$ est la distance moyenne au cluster voisin le plus proche. Une valeur proche de 1 indique un bon clustering.

1.5 Interprétabilité des modèles

Un modèle qui prédit bien mais qu'on ne comprend pas n'est pas suffisant — notamment en santé [19]. Deux familles d'approches s'opposent ici.

Les **modèles intrinsèquement interprétables** (régression linéaire, régression logistique, arbres de décision) permettent de lire directement les relations : les coefficients d'une régression indiquent immédiatement le sens et l'amplitude de l'effet de chaque variable.

Les **méthodes post-hoc** s'appliquent après l'entraînement, sur n'importe quel modèle — y compris les boîtes noires. L'idée : ne pas sacrifier les performances pour avoir de l'interprétabilité, mais expliquer le modèle a posteriori. **SHAP** [20] (*SHapley Additive exPlanations*) est la méthode post-hoc la plus répandue aujourd'hui. Issue de la théorie des jeux coopératifs, elle répond à la question : *quelle est la contribution équitable de chaque variable à cette prédiction précise ?* La valeur SHAP ϕ_j de la variable j est :

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f(S \cup \{j\}) - f(S)] \quad (1.3)$$

où F est l'ensemble des variables, S un sous-ensemble ne contenant pas j , et $f(S)$ la prédiction du modèle avec uniquement les variables de S . Pour chaque individu, SHAP produit un score signé par variable : positif si la variable pousse vers le risque, négatif sinon.

Dans ce projet, je l'utilise comme **complément visuel**, aux côtés des feature importances (Random Forest, XGBoost) et des coefficients de la régression logistique — qui restent les interprétations principales.

Chapitre 2 : Données et analyse exploratoire

2.1 Analyse exploratoire des données (EDA)

2.1.1 Présentation générale du dataset

Le jeu de données contient **100 000 observations** décrites par **15 variables** (l'identifiant `id` est exclu). On distingue trois types : variables continues — `age` (âge), `bmi` (IMC), `daily_steps` (nombre de pas quotidiens), `sleep_hours` (heures de sommeil), `cholesterol` (cholestérol), `systolic_bp` et `diastolic_bp` (pressions artérielles), `resting_hr` (fréquence cardiaque au repos) — variables binaires (`smoker`, `alcohol`, `family_history`, `disease_risk`), et une variable catégorielle (`gender`). **Aucune valeur manquante** n'est détectée, ce qui s'explique par la nature synthétique des données.

2.1.2 Statistiques descriptives

Pour chaque variable continue $X = \{x_1, \dots, x_n\}$ avec $n = 100\,000$, j'ai calculé la moyenne et l'écart-type [11] :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (2.1)$$

TABLE 2.1 – Statistiques descriptives des variables continues

Variable	Moyenne	Écart-type	Min	Max
<code>age</code>	48.5 ans	17.9	18	79
<code>bmi</code>	29.0	6.3	18.0	40.0
<code>daily_steps</code>	10 480	5 484	1 000	19 999
<code>sleep_hours</code>	6.5 h	2.0	3.0	10.0
<code>cholesterol</code>	224.3 mg/dL	43.3	150	299
<code>systolic_bp</code>	134.6 mmHg	26.0	90	179
<code>resting_hr</code>	74.5 bpm	14.4	50	99

Interprétation : Un IMC moyen de 29 se situe en limite de surpoids selon la classification OMS, qui fixe le seuil à 25 kg/m² [1]. Le taux moyen de cholestérol à 224 mg/dL dépasse le seuil de 200 mg/dL recommandé par le NCEP [2].

2.1.3 Distribution des variables

Le coefficient d'asymétrie (*skewness*) mesure la symétrie d'une distribution [11] :

$$\text{Skew}(X) = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3 \quad (2.2)$$

Je l'utilise pour décider si une transformation est nécessaire avant modélisation : une distribution très asymétrique ($\text{skewness} > 1$ par exemple) peut biaiser les modèles linéaires et nécessite souvent une transformation logarithmique pour être "redressée". Ici, toutes les variables continues affichent un skewness inférieur à $|0.02|$: distributions **quasi-uniformes**, ce qui s'explique directement par la génération synthétique aléatoire des données [5]. Aucune transformation n'est donc nécessaire.




FIGURE 2.1 – Distributions des variables continues du dataset

La variable cible présente un **déséquilibre des classes** (*class imbalance problem* [16]) : 75 179 individus (75.2%) sont sans risque contre seulement 24 821 (24.8%) à risque. Le problème concret est le suivant : un modèle naïf qui prédit *toujours* "sans risque" obtient déjà 75% d'accuracy — sans avoir rien appris. L'accuracy seule est donc une métrique trompeuse : elle ne distingue pas un bon modèle d'un modèle inutile. C'est pourquoi on privilégie le F1-score, la précision, le rappel et l'AUC-ROC, qui mesurent réellement la capacité à détecter les deux classes [21].

2.1.4 Analyse des corrélations

Le coefficient de corrélation de Pearson entre deux variables X et Y [11] :

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.3)$$




FIGURE 2.2 – Distribution de la variable cible `disease_risk` (déséquilibre 75/25)




FIGURE 2.3 – Matrice de corrélation de Pearson entre toutes les variables du dataset

Résultat central : Les corrélations calculées sur le dataset (notebook 01_EDA) sont toutes inférieures à $|0.01|$. La variable la plus corrélée avec `disease_risk` est `resting_hr` avec $r = 0.01$ — statistiquement non significatif sur 100 000 individus. Cela confirme que la variable cible a été générée indépendamment des autres variables.

Limites de la corrélation de Pearson et exploration non-linéaire.

La corrélation de Pearson ne détecte que les relations *linéaires* : deux variables peuvent être fortement liées de façon non-linéaire (relation en U, effet seuil, interaction) avec $\text{Pearson} = 0$. Face à ce constat, plusieurs approches

complémentaires auraient pu être mobilisées : le **coefficient de Spearman** (corrélation des rangs, capte les relations monotones non-linéaires), la **mutual information** (`mutual_info_classif` dans `scikit-learn`, mesure toute dépendance statistique quelle que soit sa forme), et des **nuages de points** (*scatter plots* ou *pairplot*) pour visualiser visuellement d'éventuelles structures non-linéaires.

Toutefois, l'utilisation de **Random Forest** et **XGBoost** dans les chapitres suivants constitue une réponse plus directe à cette question : ces algorithmes sont capables de capturer *n'importe quelle* relation non-linéaire, y compris des interactions d'ordre élevé [14]. Leur échec ($R^2 \approx 0$, $AUC \approx 0.5$) démontre que même les dépendances non-linéaires sont absentes — résultat plus fort qu'un test de Spearman, car il exploite toute la puissance des méthodes ensemblistes. En pratique, même ces méthodes échouent ici — ce qui confirme l'absence totale de signal, linéaire comme non-linéaire.




FIGURE 2.4 – Corrélations de chaque variable avec la cible `disease_risk`

2.1.5 Bilan de l'EDA

Méthode IQR pour la détection des outliers. L'*Interquartile Range* (écart interquartile) est la méthode standard de détection des valeurs aberrantes [11]. On calcule Q_1 (25^e percentile) et Q_3 (75^e percentile), puis :

$$IQR = Q_3 - Q_1 \quad (2.4)$$

TABLE 2.2 – Bilan de l’analyse exploratoire

Point	Constat	Implication
Valeurs manquantes	Aucune	Pas de preprocessing nécessaire
Distributions	Quasi-uniformes ($\text{skewness} < 0.02 $)	Pas de transformation logarithmique
Outliers	Aucun (méthode IQR)	Pas de traitement nécessaire
Corrélations	Quasi-nulles (< 0.01)	Privilégier modèles non-linéaires
Classe cible	Déséquilibrée (75/25)	Utiliser F1-score, AUC-ROC, SMOTE

Tout point en dehors de l’intervalle $[Q_1 - 1,5 \times \text{IQR} ; Q_3 + 1,5 \times \text{IQR}]$ est considéré comme un outlier. Par exemple, pour `bmi` : $Q_1 = 23,5$, $Q_3 = 34,5$, $\text{IQR} = 11$ borne basse = 7, borne haute = 51. Toutes les valeurs de `bmi` (18 à 40) restent dans cet intervalle : aucun outlier détecté. Ce résultat est cohérent sur l’ensemble des variables, ce qui confirme la régularité artificielle d’un dataset synthétique.

2.2 Feature Engineering et préparation des données

2.2.1 Encodage des variables catégorielles

La variable `gender` est encodée en variable binaire [10] :

$$\text{gender_enc} = \begin{cases} 1 & \text{si Male} \\ 0 & \text{si Female} \end{cases} \quad (2.5)$$

La colonne `id` est supprimée : identifiant technique sans pouvoir prédictif. La variable `hypercholesterol` (= 1 si `cholesterol` > 200 mg/dL, seuil NCEP [2]) a été créée **temporairement dans le notebook de régression uniquement pour démontrer l’effet du data leakage** : en l’incluant comme feature, le R^2 monte artificiellement à 0.675. Elle n’a jamais été utilisée dans le clustering ni dans aucun autre notebook — elle est **exclue de toute modélisation**. Il s’agit d’un *data leakage* [22] direct : `hypercholesterol` est dérivée de `cholesterol`, la variable cible de la régression. Inclure une feature construite à partir de la cible revient à "donner la réponse" au modèle pendant l’entraînement — il obtient alors un R^2 artificiellement élevé qui s’effondrerait sur de nouvelles données réelles.

2.2.2 Création de nouvelles variables

J’ai construit trois nouvelles variables à partir de **connaissances métier** [10] : plutôt que de se limiter aux variables brutes, on encode directement dans les features des savoirs médicaux établis. Par exemple, on ne "découvre" pas le seuil d’hypertension dans les données — on le connaît *a priori* grâce aux recommandations cliniques.

Hypertension selon les seuils de l'ESC (*European Society of Cardiology*, l'organisme médical européen définissant les recommandations cardiovasculaires) [3] :

$$\text{hypertension} = \begin{cases} 1 & \text{si systolic_bp} \geq 140 \text{ ou diastolic_bp} \geq 90 \\ 0 & \text{sinon} \end{cases} \quad (2.6)$$

Catégories IMC selon la classification OMS [1] :

$$\text{bmi_cat} = \begin{cases} 0 & \text{bmi} < 18.5 \text{ (sous-poids)} \\ 1 & 18.5 \leq \text{bmi} < 25 \text{ (normal)} \\ 2 & 25 \leq \text{bmi} < 30 \text{ (surpoids)} \\ 3 & \text{bmi} \geq 30 \text{ (obèse)} \end{cases} \quad (2.7)$$

Score de style de vie — score composite heuristique résumant l'hygiène de vie globale d'un individu en une seule valeur. Il n'est pas validé médicalement, mais repose sur la cohérence avec la littérature [8] : les facteurs favorables à la santé contribuent positivement, les facteurs de risque pénalisent. Chaque variable continue est divisée par son maximum pour la ramener entre 0 et 1, ce qui évite qu'une variable à grande échelle (comme `daily_steps`, jusqu'à 20 000) domine une variable à petite échelle (comme `sleep_hours`, entre 3 et 10) :

$$\begin{aligned} \text{lifestyle_score} = & \frac{\text{daily_steps}}{\text{max}} + \frac{\text{sleep_hours}}{\text{max}} + \frac{\text{water_intake_l}}{\text{max}} \\ & - \text{smoker} - \text{alcohol} \\ & - \frac{\text{bmi}}{\text{max}} - \frac{\text{calories_consumed}}{\text{max}} \end{aligned} \quad (2.8)$$

Les termes **positifs** (`daily_steps`, `sleep_hours`, `water_intake_l`) correspondent à des comportements bénéfiques pour la santé ; les termes **négatifs** (`smoker`, `alcohol`, `bmi` élevé, excès calorique) correspondent à des facteurs de risque établis [8].

2.2.3 Mise à l'échelle

Deux méthodes de mise à l'échelle sont appliquées selon le contexte [10] :

Standardisation (z-score) pour les modèles linéaires :

$$z_i = \frac{x_i - \bar{x}}{s} \quad (2.9)$$

Normalisation min-max pour les algorithmes de distance (K-Means) :

$$x_i^{\text{norm}} = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (2.10)$$

2.2.4 Dataset final

Le dataset original contient **15 variables** (identifiant `id` exclu). Après preprocessing, le dataset final compte **18 variables** : `gender` est remplacée par `gender_enc` (substitution directe, le nombre reste 15), puis trois nouvelles variables métier sont ajoutées (`bmi_cat`, `hypertension`, `lifestyle_score`), soit $15 + 3 = 18$ variables au total. Ces 18 variables couvrent les dimensions démographiques, les habitudes de vie, les indicateurs biologiques et les variables métier construites.

Chapitre 3 : Modélisation supervisée

3.1 Régression : prédire le taux de cholestérol

3.1.1 Objectif et variable cible

On cherche à prédire le taux de cholestérol (`cholesterol`, en mg/dL) à partir des habitudes de vie et indicateurs biologiques. Ce choix est médicalement motivé : le cholestérol est un facteur de risque cardiovasculaire reconnu [2].

Variables utilisées pour la prédiction. Le dataset final compte 18 variables. Pour la régression, 16 d’entre elles servent de features (18 totales – `cholesterol` qui est la cible – `disease_risk` non pertinente ici) : `age`, `bmi`, `daily_steps`, `sleep_hours`, `water_intake_l`, `calories_consumed`, `smoker`, `alcohol`, `resting_hr`, `systolic_bp`, `diastolic_bp`, `family_history`, `gender_enc`, `bmi_cat`, `hypertension`, `lifestyle_score`. La variable `cholesterol` est la cible (exclue des features), `disease_risk` n’est pas pertinente ici, et `hypercholesterol` est exclue pour la raison suivante.

Note sur le data leakage : la variable `hypercholesterol` (= 1 si cholestérol > 200 mg/dL) a été créée temporairement dans ce notebook pour démontrer l’effet du leakage. Elle est directement dérivée de la variable cible : l’inclure comme feature revient à donner la réponse au modèle pendant l’entraînement — c’est un *data leakage* [22] qui gonfle artificiellement le R^2 à 0.675. Une fois retirée, le R^2 chute à ≈ 0 pour tous les modèles. Cette variable n’a été utilisée dans aucun autre notebook.

3.1.2 Protocole expérimental

Split 80/20 : 80 000 individus en entraînement, 20 000 en test (`random_state=42`). Le paramètre `random_state=42` fixe la graine du générateur aléatoire : il garantit que le découpage est **identique à chaque exécution du code**. Sans cette graine, le split serait différent à chaque run, rendant les résultats non reproductibles. Fixer `random_state` est une bonne pratique scientifique fondamentale : n’importe qui relançant le code obtient exactement les mêmes 80 000 individus d’entraînement et les mêmes 20 000 de test [11]. Ce ratio classique garantit un ensemble d’entraînement suffisamment grand pour que les modèles apprennent, tout en conservant 20 000 observations pour une évaluation statistiquement fiable. On n’utilise pas de troisième split (train/validation/test) car la validation croisée remplace avantageusement le jeu de validation fixe : elle exploite l’intégralité des données d’entraînement et produit une estimation plus robuste.

Validation croisée K-Fold ($k = 5$) [10] : le jeu d’entraînement est découpé en k plis égaux. À chaque itération, $k - 1$ plis servent à entraîner et le pli restant à valider ; on

répète k fois en changeant le pli de validation. Le score moyen sur les k itérations est :

$$\text{CV-score} = \frac{1}{k} \sum_{i=1}^k \text{score}_i, \quad k = 5 \quad (3.1)$$

où $k = 5$ est la valeur consensus dans la littérature [11] : avec 80 000 individus, chaque fold contient 16 000 exemples (suffisant), et $k = 5$ offre un bon compromis entre coût de calcul et fiabilité de l'estimation. $k = 10$ serait plus précis mais deux fois plus lent.

Ce que garantit la validation croisée : la CV garantit la **robustesse de l'estimation** hors-échantillon — avec $k = 5$ itérations, le résultat $R^2 \approx 0$ n'est pas un artefact du split particulier, mais une estimation stable. En revanche, elle ne garantit pas qu'un signal prédictif existe dans les données : elle mesure ce signal avec précision, quelle qu'en soit la valeur. Un $R^2 \approx 0$ bien estimé reste ≈ 0 .

Métriques d'évaluation [11] :

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3.2)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.3)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.4)$$

où y_i est la valeur observée (cholestérol réel), $\hat{y}_i$ la valeur prédite par le modèle, et $\bar{y}$ la moyenne observée. Ces trois métriques sont complémentaires.

Le R^2 répond à la question : "**mon modèle prédit-il mieux que la moyenne ?**" [11]. $R^2 = 1$ signifie une prédiction parfaite ; $R^2 = 0$ signifie que le modèle prédit uniquement la moyenne $\bar{y} = 224.3$ mg/dL pour tout le monde, sans utiliser les features ; $R^2 < 0$ signifie que le modèle est *pire* que de prédire la moyenne.

Le RMSE exprime l'erreur en mg/dL en pénalisant les grandes erreurs. Un résultat clé : le RMSE observé de **43.33 mg/dL correspond exactement à l'écart-type du cholestérol** dans le dataset (43.3 mg/dL, voir Table 2.1). Cela signifie que tous les modèles font la même erreur qu'un modèle qui prédirait $\bar{y} = 224.3$ mg/dL pour chaque individu — ils n'ont rien appris des features. La MAE donne l'erreur absolue moyenne, plus lisible : ici $\text{MAE} \approx 37.6$ mg/dL signifie que le modèle se trompe en moyenne de 37.6 mg/dL.

3.1.3 Modèles et justification

Les six modèles retenus suivent une logique de **spectre de complexité** : on part d'une baseline linéaire simple pour établir un plancher de performance, on ajoute des méthodes régularisées pour tester si contraindre les coefficients aide, puis des méthodes ensemblistes pour capturer d'éventuelles non-linéarités. Ce choix respecte un principe fondamental : si

un modèle plus complexe ne fait pas mieux que la baseline, sa complexité supplémentaire n'est pas justifiée [11]. C'est exactement ce qu'on observe ici.

Régression linéaire (baseline) : point de référence obligatoire [11]. Si les autres modèles, plus complexes, ne font pas mieux, leur complexité supplémentaire n'est pas justifiée. Ici, c'est exactement ce qu'on observe.

Ridge (régularisation L_2) [12] : la régression linéaire classique minimise uniquement les erreurs de prédiction, ce qui peut mener à des coefficients très grands et instables quand les variables sont peu informatives. Ridge ajoute une pénalité qui bride les coefficients :

$$\mathcal{L}_{\text{Ridge}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_j w_j^2 \quad (3.5)$$

où $\lambda \geq 0$ est le paramètre de régularisation (contrôle la force de la pénalité) et w_j sont les coefficients du modèle. Plus λ est grand, plus les coefficients sont réduits vers zéro — sans jamais les annuler complètement.

Lasso (régularisation L_1) [13] : similaire à Ridge mais la pénalité sur $|w_j|$ (valeur absolue au lieu du carré) a une propriété remarquable : elle force certains coefficients *exactement* à zéro, réalisant ainsi une **sélection automatique de variables** :

$$\mathcal{L}_{\text{Lasso}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_j |w_j| \quad (3.6)$$

Résultat observé : avec $\lambda = 9.54$ (tuné par RandomizedSearchCV), Lasso fixe les **16 coefficients sur 16 à zéro** — il prédit simplement la moyenne du cholestérol pour tous les individus, confirmant formellement l'absence de signal prédictif linéaire.

ElasticNet [10] : combine les pénalités L_1 et L_2 via un paramètre de mélange $\rho \in [0, 1]$:

$$\mathcal{L}_{\text{EN}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \left[\rho \sum_j |w_j| + \frac{1-\rho}{2} \sum_j w_j^2 \right] \quad (3.7)$$

où $\rho = 1$ redonne le Lasso, $\rho = 0$ redonne Ridge. Utile quand on ne sait pas a priori lequel des deux convient mieux.

Random Forest [14] : construit B arbres de décision indépendants, chacun entraîné sur un sous-échantillon aléatoire des données et des variables. La prédiction finale est la moyenne des B arbres :

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (3.8)$$

où $T_b(\mathbf{x})$ est la prédiction du b -ième arbre. Cette approche réduit la variance par rapport à un arbre unique et capture les non-linéarités. J'ai dû contraindre les paramètres : `max_depth=15`, `max_samples=0.5`, `n_jobs=-1` pour éviter des entraînements de plusieurs heures observés avec les paramètres par défaut (`max_depth=None`).

XGBoost [15] : contrairement à Random Forest qui construit des arbres en parallèle, XGBoost les construit *séquentiellement* — chaque arbre corrige les erreurs du précédent. La prédiction à l'itération t est :

$$\hat{y}^{(t)} = \hat{y}^{(t-1)} + \eta \cdot T_t(\mathbf{x}) \quad (3.9)$$

où $\eta \in (0, 1]$ est le *taux d'apprentissage* (learning rate) qui contrôle la contribution de chaque arbre, et $T_t(\mathbf{x})$ est l'arbre ajouté à l'itération t .

Tuning par RandomizedSearchCV [23] : les hyperparamètres (λ , `max_depth`, `learning_rate...`) ne peuvent pas être appris depuis les données — ils doivent être fixés avant l'entraînement. "Tuné" signifie que leur valeur optimale a été trouvée *automatiquement* par RandomizedSearchCV : à chaque itération, une combinaison aléatoire d'hyperparamètres est tirée et évaluée par validation croisée. Avec `n_iter=20`, on explore 20 combinaisons aléatoires — beaucoup plus rapide que GridSearch qui testerait toutes les combinaisons possibles, tout en couvrant suffisamment l'espace des paramètres [23].

3.1.4 Résultats et analyse critique

TABLE 3.1 – Résultats de régression (variable cible : `cholesterol`)

Modèle	R^2	RMSE (mg/dL)	MAE (mg/dL)	CV- R^2
LinearRegression (baseline)	0.0001	43.33	37.59	≈ 0
Ridge ($\lambda = 7197$, tuné)	0.0001	43.33	37.59	≈ 0
Lasso ($\lambda = 9.54$, tuné)	-0.0000	43.33	37.60	≈ 0
ElasticNet	-0.0000	43.33	37.60	≈ 0
Random Forest (tuné)	-0.005	43.44	37.67	≈ 0
XGBoost (tuné)	0.0001	43.33	37.59	≈ 0

Analyse critique : Aucun modèle ne parvient à prédire le taux de cholestérol ($R^2 \approx 0$ pour tous). Plusieurs observations renforcent ce constat. D'abord, le Lasso (tuné) fixe les **16 coefficients sur 16 à zéro** : il se contente de prédire la moyenne du cholestérol (224.3 mg/dL) pour chaque individu — c'est la preuve formelle qu'aucune variable n'est linéairement prédictive. Ensuite, Random Forest et XGBoost non-tunés affichent des R^2 *négatifs* : ils sont plus mauvais que de prédire la moyenne, ce qui révèle qu'ils ont surajusté du bruit. Le tuning améliore légèrement XGBoost (R^2 repasse à 0.0001) mais ne change pas le fond du problème. Ce résultat illustre la **limite fondamentale du dataset synthétique** : les variables ont été générées indépendamment, sans relations causales réalistes encodées. Sur des données réelles, alimentation, activité physique et tabagisme influencent significativement le cholestérol [8] — cette relation est tout simplement absente ici.

Quel est le meilleur modèle en régression ? Aucun ne peut être retenu. Les différences entre modèles sont négligeables (R^2 entre -0.005 et 0.0001) : le « meilleur » sur le jeu de test (XGBoost tuné, $R^2 = 0.0001$) n'est pas statistiquement différent de la baseline linéaire. Sélectionner un modèle ici n'aurait aucun sens — tous prédisent essentiellement la moyenne du cholestérol (224.3 mg/dL) pour chaque individu.

3.2 Classification : prédire le risque de maladie

3.2.1 Objectif et contexte

On cherche à prédire si un individu est à risque de maladie (`disease_risk = 1`) ou non (`disease_risk = 0`). Le dataset présente un **déséquilibre de classes** : 75.2% sans risque, 24.8% à risque [16].

3.2.2 Protocole expérimental

Split stratifié 80/20 : le paramètre `stratify=y` maintient le ratio 75.2/24.8 dans les deux ensembles, évitant qu'un split aléatoire ne crée un jeu de test avec trop peu d'individus à risque [11].

Stratified K-Fold ($k = 5$) : maintient le ratio de classes dans chaque fold. Sans stratification, un fold pourrait ne contenir que des individus sans risque et biaiser l'évaluation [16].

Pourquoi 20 000 individus dans le jeu de test ? Le jeu de test correspond au split 80/20 : 20% de $100\ 000 = 20\ 000$ individus. Ces individus n'ont jamais été vus pendant l'entraînement ni pendant le tuning des hyperparamètres. Toutes les matrices de confusion et métriques (AUC, F1, accuracy) sont calculées sur ces 20 000 observations — l'estimation de performance est donc non biaisée.

Gestion du déséquilibre : j'ai comparé deux stratégies. L'ajustement des poids de classe pénalise davantage les erreurs sur la classe minoritaire [16] :

$$w_k = \frac{n}{K \cdot n_k} \quad (3.10)$$

où n est le nombre total d'observations, K le nombre de classes et n_k le nombre d'observations dans la classe k . SMOTE [5] crée synthétiquement de nouveaux exemples minoritaires par interpolation : $\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda(\mathbf{x}_{\text{voisin}} - \mathbf{x}_i)$, où $\lambda \in [0, 1]$ est tiré aléatoirement. Le but est de rééquilibrer les classes pour que le modèle voie autant d'exemples des deux classes. Les deux approches sont comparées dans ce projet.

Résultat et conclusion sur SMOTE : ni SMOTE ni l'ajustement des poids n'améliorent les performances (AUC reste ≈ 0.5). Ce résultat confirme que le problème provient de l'**absence totale de signal**, pas du déséquilibre des classes : SMOTE génère de nouveaux exemples minoritaires, mais ces exemples synthétiques ont les mêmes valeurs de

features que les exemples majoritaires — il ne peut pas créer un signal qui n'existe pas dans les données.

3.2.3 Métriques d'évaluation

$$\text{Précision} = \frac{TP}{TP + FP}, \quad \text{Rappel} = \frac{TP}{TP + FN} \quad (3.11)$$

$$\text{F1-score} = \frac{2 \times \text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (3.12)$$

où TP (vrais positifs), FP (faux positifs) et FN (faux négatifs) sont issus de la matrice de confusion. La **précision** mesure la proportion de prédictions "à risque" qui sont réellement à risque ; le **rappel** mesure la proportion d'individus réellement à risque qui ont bien été détectés. Le **F1-score** est leur moyenne harmonique : utile quand les deux comptent également.

La courbe **ROC** trace le taux de vrais positifs en fonction du taux de faux positifs pour tous les seuils de décision. L'**AUC-ROC** [11] synthétise cette courbe en un seul chiffre : $AUC = 1$ = discrimination parfaite, $AUC = 0.5$ = tirage aléatoire (aucun pouvoir discriminant).

Note sur le SVM : le SVM a été écarté en raison de sa **complexité algorithmique**. La complexité d'un algorithme décrit comment son temps de calcul augmente avec la taille des données n . Le SVM nécessite de calculer des distances entre paires d'observations, ce qui donne une complexité en $\mathcal{O}(n^2)$ à $\mathcal{O}(n^3)$: doubler n multiplie le temps par 4 (voire 8). Concrètement : sur 5 000 individus, l'entraînement prend quelques secondes. Sur 100 000 individus, le même calcul représenterait $100^2 = 10\,000$ fois plus d'opérations, soit plusieurs heures sans infrastructure dédiée. Un test sur 5 000 individus a confirmé des performances similaires aux autres modèles ($AUC \approx 0.5$) : l'exclure ne prive pas l'analyse de résultats utiles.


Note sur le classifieur naïf de Bayes : fondé sur l'hypothèse d'indépendance conditionnelle des variables étant donné la classe [11], ce classifieur est précisément adapté à notre dataset — les variables ont justement été générées indépendamment. Son absence constitue une **limite du choix de modèles** : il aurait été pertinent de l'inclure, et l'on anticipe un résultat identique ($AUC \approx 0.5$), l'absence de signal ne dépendant pas du classifieur choisi.

3.2.4 Résultats et analyse critique

* La précision du modèle naïf est indéfinie : ce modèle prédit toujours 0, donc il n'émet jamais de prédiction positive ($TP = 0$, $FP = 0$), ce qui conduit à une division par zéro dans la formule $\frac{TP}{TP+FP}$.

TABLE 3.2 – Résultats de classification (variable cible : `disease_risk`)

Modèle	Accuracy	Précision	Rappel	F1	AUC-ROC
Naïf (tout à 0)	0.752	—	0.000	0.000	0.500
Logistic Regression	0.498	0.249	0.509	0.335	0.499
Random Forest	0.568	0.245	0.355	0.290	0.494
XGBoost	0.525	0.246	0.441	0.316	0.499

FIGURE 3.1 – Courbes ROC des trois modèles de classification ($AUC \approx 0.5$ pour tous)

Analyse critique : La colonne **AUC-ROC** est la métrique centrale : tous les modèles affichent $AUC \approx 0.5$, ce qui signifie qu'aucun ne discrimine mieux qu'un tirage aléatoire [11]. L'accuracy seule est trompeuse : Random Forest affiche 56.8% d'accuracy mais une AUC de **0.494** — **inférieure au modèle naïf** (0.500). En pratique, un Random Forest à 56.8% d'accuracy est pire qu'un modèle qui dit toujours "sans risque", en termes de capacité à distinguer les deux classes. Cela illustre pourquoi l'accuracy seule est dangereuse sur des données déséquilibrées [21] : elle peut masquer un modèle inutile derrière un chiffre élevé.

Lecture des matrices de confusion (Figure 3.2) : chaque matrice est calculée sur les 20 000 individus du jeu de test. Les lignes correspondent aux vraies étiquettes (ce que l'individu est réellement), les colonnes aux étiquettes prédites. Un modèle efficace aurait des valeurs élevées sur la diagonale (vrais positifs + vrais négatifs) et faibles hors-diagonale. Ici, pour chaque modèle, les chiffres de chaque ligne sont presque équilibrés entre les deux colonnes : un vrai malade a à peu près autant de chances d'être prédit "à risque" que "sans risque". C'est exactement le comportement




FIGURE 3.2 – Matrices de confusion des trois modèles de classification

d'un modèle qui tire au sort — cohérent avec $AUC \approx 0.5$.

Avec `class_weight='balanced'`, les modèles augmentent leur rappel (ils détectent plus d'individus à risque) mais leur accuracy tombe sous 50% — ils sur-correct le déséquilibre au détriment de la précision. Ces résultats sont cohérents avec ceux de la régression ($R^2 \approx 0$) : les deux confirment que `disease_risk` a été généré indépendamment de toutes les autres variables.

Quel est le meilleur modèle en classification ? Aucun modèle n'est retenu pour déploiement. Avec $AUC \approx 0.5$ pour tous, aucun ne discrimine mieux qu'un tirage aléatoire : choisir le « meilleur » n'a pas de sens statistique. Les légères différences d'accuracy ou de F1 entre modèles reflètent des variations aléatoires sur un signal nul, et non une vraie hiérarchie de performance.

Effet de la taille du jeu de données. Augmenter le nombre d'observations ne ferait pas apparaître un signal absent : 100 000 individus est déjà un très grand échantillon, et les corrélations restent inférieures à $|0.01|$ quelle que soit la taille. En revanche, sur des **données réelles** présentant de vraies relations, un plus grand dataset permettrait de détecter des effets de faible amplitude qu'un petit échantillon masquerait [11]. Diminuer la taille augmenterait la variance des estimations sans résoudre le problème fondamental ici.

Chapitre 4 : Clustering et interprétabilité

4.1 Clustering : identifier des profils de mode de vie

4.1.1 Objectif

Le clustering est une méthode d'**apprentissage non supervisé** : il n'y a pas de variable cible. L'objectif est de regrouper les individus selon leur similarité pour identifier des **profils types de mode de vie** [17]. La variable `disease_risk` est exclue du clustering.

4.1.2 Préparation des données

Les 15 variables explicatives sont standardisées (z-score) avant d'appliquer les algorithmes. K-Means et CAH reposent sur la **distance euclidienne** [17] :

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2} \quad (4.1)$$

où p est le nombre de variables (ici $p = 15$), et x_j, y_j sont les valeurs de la j -ième variable pour les individus $\mathbf{x}$ et $\mathbf{y}$.

Cette distance est sensible aux échelles : sans standardisation, `daily_steps` (valeurs jusqu'à 20 000) dominerait `sleep_hours` (valeurs entre 3 et 10) même si les deux variables sont médicalement aussi importantes — la distance serait quasiment déterminée par `daily_steps` seul, et le clustering ignorerait les autres variables [10]. Le z-score ramène chaque variable à une moyenne de 0 et un écart-type de 1, garantissant une contribution équitable de toutes les dimensions.

La CAH étant de complexité $\mathcal{O}(n^2)$ (voir note sur le SVM au chapitre 3), elle est appliquée sur un sous-échantillon aléatoire de **5 000 individus** pour rester dans des temps de calcul raisonnables.

4.1.3 Sélection du nombre de clusters

Méthode du coude : on trace l'**inertie intra-cluster** $W(k)$ en fonction de k . L'inertie mesure la dispersion totale à l'intérieur des clusters :

$$W(k) = \sum_{j=1}^k \sum_{\mathbf{x} \in C_j} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \quad (4.2)$$

où C_j désigne le j -ème cluster et $\boldsymbol{\mu}_j$ son centroïde (vecteur des moyennes). Plus k augmente, plus l'inertie diminue — mais à partir d'un certain k , le gain devient marginal : c'est le "coude" de la courbe, au-delà duquel ajouter des clusters ne compense plus la complexité.

Coefficient de silhouette [18] : défini au chapitre 1, il mesure la qualité de séparation des clusters. Pour rappel :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (4.3)$$

où $a(i)$ est la distance moyenne de l'individu i aux autres membres de son cluster, et $b(i)$ la distance moyenne au cluster voisin le plus proche. Une valeur proche de 1 indique une bonne séparation.

TABLE 4.1 – Inertie et silhouette selon k (K-Means)

k	Inertie	Silhouette
2	1 346 768	0.0979
3	1 238 076	0.1030
4	1 188 303	0.0967
5	1 152 260	0.0886
10	1 031 548	0.0744

$k = 3$ maximise la silhouette et correspond au coude de la courbe d'inertie. $k = 3$ est retenu.




FIGURE 4.1 – Inertie intra-cluster et coefficient de silhouette selon k (K-Means)

4.1.4 K-Means

L'algorithme K-Means [17] alterne deux étapes : affectation de chaque individu au centroïde le plus proche (selon la distance euclidienne), puis mise à jour de chaque centroïde comme la moyenne de ses membres :

$$\mu_j = \frac{1}{|C_j|} \sum_{\mathbf{x} \in C_j} \mathbf{x} \quad (4.4)$$

où $|C_j|$ est le nombre d'individus dans le cluster j . Ces deux étapes se répètent jusqu'à convergence (stabilisation des affectations).

Interprétation : K-Means partitionne la population selon l'**IMC** et la **pression artérielle systolique**. Ce résultat s'explique par la sensibilité de K-Means aux variables à grande variance : dans notre dataset, **bmi** (écart-type = 6.3) et

TABLE 4.2 – Profils des clusters K-Means ($k = 3$)

Cluster	Taille	IMC moyen	Syst. (mmHg)	Profil
0	32 754	35.0 (obèse)	142 (hypertendu)	Obèse hypertendu
1	27 673	29.1 (surpoids)	115 (normotendu)	Surpoids normotendu
2	39 573	24.0 (normal)	142 (hypertendu)	Poids normal hypertendu

systolic_bp (écart-type = 26.0) ont les dispersions les plus larges après standardisation, ce qui les rend naturellement "dominantes" pour la distance euclidienne. Le cluster 1 regroupe les individus les plus sains (surpoids mais normotendus), tandis que les clusters 0 et 2 correspondent à deux profils à risque cardiovasculaire distincts selon la classification OMS [1] et ESC [3].

4.1.5 Classification Hiérarchique Ascendante (CAH)

La CAH construit un **dendrogramme** en fusionnant progressivement les clusters les plus proches. Au départ, chaque individu est son propre cluster ; à chaque étape, on fusionne les deux clusters dont la fusion est la "moins coûteuse" [10].

La **méthode de liaison Ward** définit ce coût : fusionner A et B augmente la variance intra-cluster d'une quantité :

$$\Delta(A, B) = \frac{|A| \cdot |B|}{|A| + |B|} \|\mu_A - \mu_B\|^2 \quad (4.5)$$

où $|A|$ et $|B|$ sont les tailles des clusters, et μ_A , μ_B leurs centroïdes. On fusionne toujours les deux clusters qui minimisent Δ : Ward favorise ainsi des clusters **compacts et de tailles équilibrées**, contrairement à d'autres méthodes (liaison simple, liaison complète) qui peuvent produire des clusters très déséquilibrés.

TABLE 4.3 – Profils des clusters CAH ($k = 3$, $n = 5\,000$)

Cluster	Taille	Fumeurs	Syst. (mmHg)	Profil
0	2 928	2%	142	Non-fumeurs hypertendus
1	1 407	18%	115	Fumeurs modérés, normotendus
2	665	100%	142	Fumeurs intenses, hypertendus

Interprétation : La CAH isole un **cluster de fumeurs intenses** (100% de fumeurs + hypertendus). Ce résultat s'explique par la nature de l'algorithme : Ward cherche des sous-groupes *homogènes*, y compris sur des variables binaires comme **smoker**. K-Means, guidé par les grandes variances numériques, n'aurait pas isolé ce groupe de 665 individus — il les aurait dilués dans les clusters dominés par l'IMC et la pression. Les deux méthodes sont donc **complémentaires** : K-Means donne une vue globale par dimensions biologiques continues, la CAH révèle des sous-groupes comportementaux fins. Le profil tabagisme + hypertension est un double facteur de risque cardiovasculaire bien documenté [8].

4.1.6 Évaluation et visualisation

Visualisation par ACP (Analyse en Composantes Principales). Nos données vivent dans un espace à 15 dimensions : il est impossible de les représenter directement. L'ACP projette ces 15 dimensions sur les 2 axes qui capturent le maximum de variance, permettant une visualisation 2D des clusters. Les deux premières composantes expliquent **24.3%** de la variance totale : la projection 2D "voit" seulement 24.3% de l'information originale. Si les clusters semblent peu séparés sur le graphique, ce n'est pas la preuve qu'ils n'existent pas — ils se distinguent dans les 15 dimensions d'origine, pas dans la réduction 2D. Avec 15 variables quasi-indépendantes (confirmé par l'EDA), aucune direction ne concentre beaucoup de variance : 24.3% en 2D est donc attendu.

Pourquoi les clusters ont-ils une forme rectangulaire dans la projection ACP ?

Sur le graphique ACP (figure 4.2), les clusters apparaissent comme des **blocs rectangulaires** plutôt que des nuages sphériques — résultat directement lié à la nature des variables du dataset.

La première composante principale (PC1, axe horizontal) est fortement influencée par **bmi_cat**, une variable ordinaire à **4 valeurs discrètes** (0 = sous-poids, 1 = normal, 2 = surpoids, 3 = obèse). Cette discrétisation crée des **colonnes verticales** : les individus s'alignent en 4 bandes distinctes plutôt que de se répartir continûment sur l'axe. La deuxième composante (PC2, axe vertical) est dominée par **hypertension**, une variable **binaire** (0 ou 1) : une variable binaire ne peut prendre que deux valeurs, ce qui produit un **saut net haut/bas** dans la projection, divisant les individus entre normotendus (bas) et hypertendus (haut).

Par ailleurs, les distributions quasi-uniformes de toutes les variables continues (chapitre 2) créent des nuages de points dispersés sans gradient de densité visible : les points se répartissent uniformément au lieu de former des ellipses denses au centre. Le résultat final est une grille de rectangles dont la forme reflète la structure discrète du dataset plutôt qu'une vraie géométrie en clusters.

Indice de Davies-Bouldin [?]. Cet indice mesure la qualité du clustering en calculant, pour chaque cluster i , le ratio entre la dispersion interne et la distance entre centroïdes :

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{d(\mu_i, \mu_j)} \right) \quad (4.6)$$

où σ_i est la dispersion moyenne des points du cluster i autour de son centroïde, et $d(\mu_i, \mu_j)$ la distance entre les centroïdes i et j . **Un DB proche de 0 est idéal** : les clusters sont compacts (faible σ) et bien séparés (grande distance). Un DB élevé indique des clusters éparpillés ou trop proches les uns des autres. Contrairement à la silhouette qui évalue chaque point individuellement, Davies-Bouldin évalue chaque paire de clusters : les deux métriques sont complémentaires.

TABLE 4.4 – Comparaison K-Means vs CAH

Métrique	K-Means	CAH	Interprétation
Silhouette	0.103	0.105	Faible — clusters peu séparés
Davies-Bouldin	2.655	2.721	Élevé — chevauchement entre clusters
Variance ACP (2D)	24.3%		Projection insuffisante (15 dims → 2D)




FIGURE 4.2 – Visualisation des clusters K-Means ($k = 3$) par projection ACP (2 composantes, 24.3% de variance)

Malgré des silhouettes faibles (≈ 0.10), les deux méthodes révèlent des structures interprétables médicalement [1, 8] : obèse hypertendu (K-Means), fumeurs intenses + hypertendus (CAH). La faible silhouette reflète l'absence de groupes naturels francs dans des données synthétiques générées sans structure causale — pas une erreur méthodologique.

4.2 Interprétabilité des modèles

4.2.1 Objectif

Cette section pose une question précise : **les outils d'interprétabilité convergent-ils vers les mêmes variables influentes, même en l'absence de signal?** La réponse est elle-même un résultat analytique.

4.2.2 Outils utilisés

Coefficients des modèles linéaires : un coefficient $w_j > 0$ indique qu'une augmentation de la variable j est associée à une augmentation de la prédiction [11]. Leur magnitude reflète l'importance relative de chaque variable — sous réserve que les variables soient standardisées.

Feature Importance (impureté de Gini) [14] : pour les forêts aléatoires, l'importance de la variable j mesure la réduction moyenne d'impureté qu'elle apporte dans tous les nuds où

elle est utilisée :

$$FI(j) = \sum_{t \in \mathcal{T}_j} \frac{n_t}{n} \left[I(t) - \frac{n_{t_L}}{n_t} I(t_L) - \frac{n_{t_R}}{n_t} I(t_R) \right] \quad (4.7)$$

où $\mathcal{T}_j$ est l'ensemble des nuds qui utilisent la variable j , n_t le nombre d'observations au nud t , n l'effectif total, $I(t)$ l'impureté au nud t (critère de Gini), et t_L, t_R les nuds fils gauche et droit.

SHAP : défini au chapitre 1 (formule des valeurs de Shapley) et utilisé ici comme complément visuel, il attribue à chaque variable une contribution signée à chaque prédiction individuelle. Les formules ne sont pas redéfinies ici.

4.2.3 Résultats, convergence et analyse critique

Les cinq méthodes d'interprétabilité (coefficients LR, Ridge, feature importance RF, XG-Boost, SHAP) sont appliquées et leurs top 5 variables comparés.

Analyse critique : Les cinq méthodes ne s'accordent pas sur un classement stable — **cette divergence est elle-même un résultat** [19] : sans signal prédictif réel, chaque outil mesure du bruit aléatoire et s'accroche à des corrélations parasites différentes. La seule variable présente dans les cinq méthodes est `systolic_bp` : dans la littérature épidémiologique réelle, la pression artérielle est effectivement l'un des facteurs de risque cardiovasculaire les mieux documentés [3] — mais dans nos données, cette convergence résulte de sa grande variance, pas d'une vraie relation causale.

Sur des données réelles [1,8], on s'attendrait à voir la pression artérielle, le cholestérol LDL, le tabagisme, l'IMC et l'activité physique dominer clairement les classements, avec des coefficients significativement différents de zéro.




FIGURE 4.3 – Coefficients de la régression logistique (variables standardisées)




FIGURE 4.4 – Feature importances (impureté de Gini) du Random Forest

Comment lire le SHAP summary plot ? Chaque **ligne** correspond à une variable, triée de haut en bas par importance décroissante (impact moyen en valeur absolue). Sur chaque ligne, chaque **point** représente un individu. L'**axe horizontal** indique l'impact SHAP sur la prédiction : un point à droite ($x > 0$) signifie que la variable pousse la prédiction vers 1 (**disease_risk** élevé); un point à gauche ($x < 0$) la pousse vers 0; en $x = 0$, aucun impact. La **couleur** encode la valeur réelle de la variable : rouge = valeur élevée, bleu = valeur faible.

Sur des données avec un signal réel, on verrait un gradient net : par exemple, si une pression artérielle élevée (rouge) est un facteur de risque, les points rouges se concentreraient à droite et les bleus à gauche. Ici, les couleurs sont **mélangées aléatoirement** autour de zéro : des points rouges et bleus occupent les mêmes positions horizontales, sans aucun pattern. Cela confirme qu'aucune variable n'a d'impact systématique — SHAP détecte du bruit plutôt qu'un signal.

Le tableau suivant synthétise la présence de chaque variable dans le top 5 des cinq méthodes :

TABLE 4.5 – Variables dans le top 5 de chaque méthode d'interprétabilité

Variable	LR	RF	XGB	SHAP	Ridge	Score
systolic_bp	✓	✓	✓	✓	✓	5/5
daily_steps	✓	✓	—	✓	—	3/5
family_history	✓	—	✓	—	✓	3/5
bmi	—	✓	—	✓	—	2/5




FIGURE 4.5 – SHAP summary plot (XGBoost) — complément visuel d’interprétabilité

Chapitre 5 : Organisation, retour d’expérience et perspectives

5.1 Méthodologie et organisation

5.1.1 Approche CRISP-DM

Ce projet a été conduit en suivant le cycle **CRISP-DM** [4], qui structure un projet de data science en six phases : compréhension du problème, compréhension des données, préparation des données, modélisation, évaluation, et déploiement. Chaque phase a alimenté la suivante de manière itérative : l’EDA a révélé l’absence de signal linéaire, ce qui a orienté le choix des modèles non-linéaires ; la détection du data leakage a conduit à réviser le feature engineering ; les résultats de classification ont confirmé le diagnostic de l’EDA.

5.1.2 Outils et environnement technique

TABLE 5.1 – Stack technique du projet

Catégorie	Outil	Usage
Langage	Python 3	Ensemble du projet
Manipulation données	pandas, numpy	Chargement, nettoyage, feature engineering
Modélisation	scikit-learn, xgboost	Entraînement, tuning, évaluation
Déséquilibre classes	imbalanced-learn	Rééchantillonnage SMOTE
Interprétabilité	shap	Valeurs SHAP sur XGBoost
Réduction de dim.	scikit-learn (PCA)	Visualisation clustering
Versionnement	Git / GitHub	Suivi des notebooks et du rapport
Rédaction	L ^A T _E X	Mémoire

5.1.3 Compétences mobilisées

5.2 Difficultés rencontrées et retour d’expérience

5.2.1 Difficultés techniques

La limite fondamentale du dataset synthétique est la difficulté principale que j’ai rencontrée. Découvrir que $R^2 \approx 0$ et $AUC \approx 0.5$ pour tous les modèles a demandé un vrai travail de diagnostic : relier ce résultat au constat de l’EDA (corrélations < 0.01) et à la nature synthétique des données a été l’exercice analytique central de ce projet.

TABLE 5.2 – Lien entre enseignements MIASHS et applications projet

Enseignement M1	Application dans le projet
ACP / ACM	Réduction dimensionnelle pour la visualisation des clusters
Régression linéaire & diagnostic	Baseline régression, Ridge, Lasso, ElasticNet
Classification supervisée	Logistic Regression, Random Forest, XGBoost
Apprentissage non supervisé	K-Means, CAH
Descente de gradient & optimisation	Compréhension de XGBoost et de la log-loss
Régression logistique	Baseline classification + interprétation coefficients
Régularisation & optimisation	Ridge, Lasso, ElasticNet
Déséquilibre de classes	class_weight, SMOTE (imbalanced-learn)
Python	Ensemble du pipeline de data science

La détection du data leakage sur `hypercholesterol` [22] est une difficulté classique en ML, rarement rencontrée dans les travaux académiques. Le R^2 artificiel de 0.675 aurait pu passer inaperçu sans une analyse rigoureuse des feature importances.

Le coût computationnel : un premier essai de Random Forest sans `max_depth` ni `n_jobs=-1` a conduit à un entraînement de plus de 3 heures interrompu avant convergence. Ça m’a forcé à comprendre les paramètres internes de l’algorithme. Le SVM a été écarté pour la même raison, sa complexité en $\mathcal{O}(n^2)$ étant incompatible avec 100 000 observations.

5.2.2 Compétences acquises

- **Détection et correction du data leakage** [22] : piège courant non systématiquement couvert en cours théoriques.
- **RandomizedSearchCV** [23] : logique de l’exploration aléatoire vs exhaustive des hyperparamètres.
- **Gestion du déséquilibre de classes** : comparaison concrète entre `class_weight='balanced'` et SMOTE [5], et compréhension de la différence entre accuracy, F1-score et AUC-ROC [21].
- **Interprétabilité multi-méthodes** : la divergence entre outils est elle-même informative [19].
- **Analyse critique d’un résultat négatif** : savoir diagnostiquer pourquoi un modèle échoue est aussi précieux que d’en construire un qui réussit.

5.2.3 Plus-value : diagnostiquer les biais du pipeline

Ce projet ne produit pas un modèle prédictif déployable — les métriques ($R^2 \approx 0$, AUC ≈ 0.5) l’excluent. Sa plus-value réside dans une contribution différente : **construire un pipeline capable de diagnostiquer pourquoi un modèle échoue**, et d’identifier rigoureusement ses biais.

Trois apports concrets peuvent être retenus :

1. **Détection du data leakage**. La variable `hypercholesterol` produisait un R^2 artificiel de 0.675 [22]. Un pipeline mal construit aurait publié ce résultat comme une performance

réelle. La détection et la correction rigoureuse de ce biais est une compétence directement valorisable sur des données épidémiologiques réelles.

2. **Diagnostic de l'absence de signal par cinq preuves convergentes.** Corrélations de Pearson < 0.01 (EDA), $R^2 \approx 0$ sur six modèles de régression dont des méthodes non-linéaires (Random Forest, XGBoost), AUC ≈ 0.5 sur trois modèles de classification, silhouettes ≈ 0.10 en clustering, et divergence des cinq outils d'interprétabilité. Cette convergence de preuves indépendantes est plus robuste qu'un résultat isolé.
3. **Accuracy trompeuse sur données déséquilibrées.** Un modèle naïf atteignait 75% d'accuracy sur le déséquilibre 75/25 ; le Random Forest affichait 56.8% d'accuracy mais une AUC de 0.494, soit *pire* que le hasard pur [21]. Identifier et exposer ce piège méthodologique est un résultat analytique à part entière.

Ce pipeline est **directement transposable** sur des données réelles [24, 25] : les mêmes étapes de détection de leakage, de validation des métriques et de comparaison des méthodes s'appliquent, et le signal réel permettrait d'obtenir des résultats prédictifs exploitables.

5.2.4 Positionnement RSE / DDRS

L'utilisation d'un dataset **synthétique** s'inscrit dans une démarche éthique : les données de santé sont sensibles et encadrées par le RGPD [9]. Les données synthétiques éliminent tout risque de ré-identification tout en permettant de développer des méthodes — un compromis central de l'IA responsable [9].

Le coût énergétique des entraînements a été limité en contraignant la profondeur des arbres (`max_depth=15`) et en réduisant `n_iter` dans `RandomizedSearchCV`, avec un impact positif sur l'empreinte carbone du calcul.

5.2.5 Limites méthodologiques

Corrélations non-linéaires non explorées. L'analyse de Pearson a révélé des coefficients inférieurs à $|0.01|$ — mais Pearson ne détecte que les relations *linéaires* [11]. Une analyse complémentaire aurait pu mobiliser le coefficient de Spearman (corrélation des rangs, capte les relations monotones), la *mutual information* (`mutual_info_classif` dans scikit-learn, toute dépendance statistique quelle que soit sa forme), ou des nuages de points pour identifier visuellement des structures non-linéaires (relations en U, effets seuil, interactions).

Toutefois, l'utilisation de **Random Forest et XGBoost** [14] — algorithmes capables de capturer n'importe quelle relation non-linéaire — constitue une réponse indirecte à cette limite. Leur échec ($R^2 \approx 0$, AUC ≈ 0.5) démontre que même les dépendances non-linéaires sont absentes : résultat plus fort qu'un test de Spearman ou de mutual information, car il exploite toute la puissance des méthodes ensemblistes sur 100 000 individus.

5.3 Perspectives

1. **Changer de dataset** : reproduire le pipeline sur un dataset réel, comme la cohorte Framingham [24] ou les données NHANES [25], qui contiennent de vraies relations entre habitudes

de vie et indicateurs de santé. Les méthodes développées ici sont directement transposables.

2. Améliorer les modèles de classification : explorer le **stacking** (combinaison de plusieurs modèles [10]) et les **réseaux de neurones** pour capturer des relations très non-linéaires — en lien direct avec le module Deep Learning du master. SMOTE ayant déjà été intégré dans ce projet, ces pistes constituent la suite logique.

3. Déploiement : un modèle de classification pourrait être déployé sous forme d’API REST (FastAPI) permettant de soumettre un profil individuel et d’obtenir une prédiction avec ses valeurs SHAP associées, rendant le modèle accessible et explicable.

4. Interprétabilité avancée : les *Partial Dependence Plots* (PDP) et les *Individual Conditional Expectation* (ICE) permettraient de visualiser comment la prédiction varie en fonction d’une variable, toutes choses égales par ailleurs — une limite de SHAP qui agrège les contributions.

5. Robustesse sur le long terme (*data drift*) : sur des données réelles en production, un modèle se dégrade si la distribution des données évolue au fil du temps — on parle de *concept drift* [10]. Les habitudes de vie d’une population changent, les seuils médicaux sont révisés, les profils épidémiologiques se transforment. En pratique, cela implique de surveiller les performances du modèle périodiquement (suivi de l’AUC sur de nouvelles cohortes) et de le réentraîner dès que les performances se dégradent. Cette problématique ne s’applique pas au dataset synthétique statique de ce projet, mais sera centrale sur des données réelles.

6. Vers le Master 2 : les thématiques de causalité, fairness algorithmique et apprentissage fédéré constituent des pistes naturelles pour un travail de recherche en M2, dans la continuité directe de ce projet.

Ce projet a mobilisé un pipeline complet de data science — analyse exploratoire, feature engineering, régression, classification, clustering et interprétabilité — appliqué à un jeu de données de santé et de mode de vie de 100 000 individus. La question centrale que je me suis posée dès le départ était : *quels facteurs du mode de vie influencent le plus l'état de santé d'un individu — et peut-on les identifier, les modéliser et les expliquer de manière rigoureuse ?*

La réponse est double. **Du point de vue des résultats** : ce dataset synthétique ne permet pas de répondre à cette question — les variables ont été générées indépendamment, sans relation causale encodée. Aucun modèle, linéaire ou non-linéaire, simple ou optimisé, n'a dépassé les performances d'un prédicteur naïf ($R^2 \approx 0$, $AUC \approx 0.5$). Cette découverte progressive est elle-même un résultat analytique : elle illustre concrètement la différence entre données synthétiques et données réelles, et la nécessité d'interroger la qualité du signal avant de construire des modèles.

Du point de vue méthodologique : chaque étape du pipeline a été conduite avec rigueur. L'EDA a permis d'anticiper les difficultés. La détection d'un data leakage [22] a évité une surestimation artificielle des performances. La comparaison systématique de six modèles avec tuning par `RandomizedSearchCV` [23] et validation croisée stratifiée a respecté les bonnes pratiques d'évaluation. La gestion du déséquilibre des classes a été traitée sous deux angles complémentaires : ajustement des poids (`class_weight='balanced'`) et rééchantillonnage SMOTE [5], confirmant que ni l'une ni l'autre ne peut extraire un signal absent. L'analyse d'interprétabilité multi-méthodes a montré que la divergence entre outils est elle-même informative [19].

Ce projet m'a appris ce que ça veut dire travailler en data scientist : ne pas se contenter de faire tourner des algorithmes, mais comprendre ce que les données peuvent — et ne peuvent pas — dire. Comme le souligne Rudin [19], un bon modèle prédictif ne vaut rien sans une évaluation honnête de ses limites. Cette posture critique, à l'intersection des mathématiques, de la statistique et de l'informatique appliquée, est au cœur de la formation MIAHS.

Les perspectives identifiées — notamment l'application de ce pipeline sur des données épidémiologiques réelles comme les cohortes Framingham [24] ou NHANES [25] — ouvrent des directions concrètes pour un travail de recherche en Master 2, avec l'ambition d'obtenir des modèles à la fois performants, interprétables et éthiquement responsables.

Bibliographie

- [1] World Health Organization. Obesity : preventing and managing the global epidemic. Technical Report 894, WHO, 2000.
- [2] National Cholesterol Education Program. Third report of the expert panel on detection, evaluation, and treatment of high blood cholesterol in adults (atp iii). Technical Report 02-5215, NIH, 2002.
- [3] Bryan Williams et al. 2018 esc/esh guidelines for the management of arterial hypertension. *European Heart Journal*, 39(33) :3021–3104, 2018.
- [4] Pete Chapman et al. Crisp-dm 1.0 : Step-by-step data mining guide. Technical report, SPSS Inc., 2000.
- [5] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote : Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16 :321–357, 2002.
- [6] Ziad Obermeyer and Ezekiel J. Emanuel. Predicting the future — big data, machine learning, and clinical medicine. *New England Journal of Medicine*, 375(13) :1216–1219, 2016.
- [7] Pranav Rajpurkar, Emma Chen, Oishi Banerjee, and Eric J. Topol. Ai in health and medicine. *Nature Medicine*, 28(1) :31–38, 2022.
- [8] Frank W. Booth, Christian K. Roberts, and Matthew J. Laye. Lack of exercise is a major cause of chronic diseases. *Comprehensive Physiology*, 2(2) :1143–1211, 2012.
- [9] Parlement européen et Conseil de l’Union européenne. Règlement (ue) 2016/679 — rgpd, 2016.
- [10] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.
- [11] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning*. Springer, 2 edition, 2021.
- [12] Arthur E. Hoerl and Robert W. Kennard. Ridge regression : Biased estimation for nonorthogonal problems. *Technometrics*, 12(1) :55–67, 1970.
- [13] Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society : Series B*, 58(1) :267–288, 1996.
- [14] Leo Breiman. Random forests. *Machine Learning*, 45(1) :5–32, 2001.
- [15] Tianqi Chen and Carlos Guestrin. Xgboost : A scalable tree boosting system. In *Proceedings of KDD 2016*, pages 785–794, 2016.
- [16] Nathalie Japkowicz and Shaju Stephen. The class imbalance problem : A systematic study. *Intelligent Data Analysis*, 6(5) :429–449, 2002.
- [17] James MacQueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297, 1967.

- [18] Peter J. Rousseeuw. Silhouettes : A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20 :53–65, 1987.
- [19] Cynthia Rudin. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5) :206–215, 2019.
- [20] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 4765–4774, 2017.
- [21] Marina Sokolova and Guy Lapalme. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4) :427–437, 2009.
- [22] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining : Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4) :1–21, 2012.
- [23] James Bergstra and Yoshua Bengio. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13 :281–305, 2012.
- [24] Thomas R. Dawber, Gilcin F. Meadors, and Felix E. Moore. Epidemiological approaches to heart disease : The framingham study. *American Journal of Public Health*, 41(3) :279–286, 1951.
- [25] Centers for Disease Control and Prevention. National health and nutrition examination survey (nhanes). <https://www.cdc.gov/nchs/nhanes>, 2023.

ACP	Analyse en Composantes Principales
AUC	Area Under the Curve
CAH	Classification Ascendante Hiérarchique
EDA	Exploratory Data Analysis (Analyse Exploratoire des Données)
ESC	European Society of Cardiology
FE	Feature Engineering
IMC	Indice de Masse Corporelle
MAE	Mean Absolute Error (Erreur Absolue Moyenne)
MIASHS	Mathématiques et Informatique Appliqués aux Sciences Humaines et Sociales
ML	Machine Learning
NCEP	National Cholesterol Education Program
OMS	Organisation Mondiale de la Santé
RMSE	Root Mean Squared Error (Racine de l’Erreur Quadratique Moyenne)
ROC	Receiver Operating Characteristic
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SVM	Support Vector Machine
WHO	World Health Organization

Clustering Méthode d'apprentissage non supervisé visant à regrouper des observations similaires sans variable cible prédéfinie.

Cross-validation (validation croisée) Technique d'évaluation qui consiste à diviser les données en k sous-ensembles et à entraîner/tester le modèle k fois.

Data leakage Fuite d'information du jeu de test vers le jeu d'entraînement, entraînant une surestimation artificielle des performances.

Feature engineering Processus de création ou de transformation de variables à partir des données brutes pour améliorer les performances des modèles.

Feature importance Mesure de la contribution de chaque variable à la prédiction d'un modèle.

Hyperparamètre Paramètre d'un modèle fixé avant l'entraînement (ex. : λ pour Ridge, k pour K-Means).

Overfitting (surapprentissage) Phénomène où un modèle apprend trop précisément les données d'entraînement et généralise mal sur de nouvelles données.

Pipeline Enchaînement structuré d'étapes de traitement des données et de modélisation.

Régularisation Technique pénalisant la complexité d'un modèle pour réduire l'overfitting (ex. : Ridge L_2 , Lasso L_1).

SHAP Méthode d'interprétabilité basée sur la théorie des jeux coopératifs, attribuant à chaque variable une contribution marginale à la prédiction.

Silhouette Coefficient mesurant la qualité d'un clustering : proche de 1 si les clusters sont bien séparés, proche de 0 s'ils se chevauchent.

SMOTE Technique de rééchantillonnage qui génère synthétiquement des exemples de la classe minoritaire pour corriger le déséquilibre des classes.

Tuning Processus d'optimisation des hyperparamètres d'un modèle, souvent via une recherche aléatoire ou par grille.

Annexe A Variables du dataset

Variable	Type	Description	Unité / Modalités
age	Continue	Âge de l'individu	années
bmi	Continue	Indice de masse corporelle	kg/m ²
daily_steps	Continue	Nombre de pas quotidiens	pas/jour
sleep_hours	Continue	Durée de sommeil	heures/nuit
water_intake_l	Continue	Consommation d'eau	litres/jour
calories_consumed	Continue	Apport calorique quotidien	kcal/jour
smoker	Binaire	Statut tabagique	0 = non, 1 = oui
alcohol	Binaire	Consommation d'alcool	0 = non, 1 = oui
resting_hr	Continue	Fréquence cardiaque au repos	bpm
systolic_bp	Continue	Pression artérielle systolique	mmHg
diastolic_bp	Continue	Pression artérielle diastolique	mmHg
cholesterol	Continue	Taux de cholestérol total	mg/dL
family_history	Binaire	Antécédents familiaux de maladie	0 = non, 1 = oui
gender	Catégorielle	Sexe de l'individu	Male / Female
disease_risk	Binaire	Variable cible : risque de maladie	0 = non, 1 = oui

Annexe B Hyperparamètres testés (RandomizedSearchCV)

Modèle	Hyperparamètre	Valeurs explorées
Ridge	alpha	[0.01, 0.1, 1, 10, 100]
Lasso	alpha	[0.001, 0.01, 0.1, 1, 10]
ElasticNet	alpha, l1_ratio	[0.01–10], [0.1, 0.5, 0.9]
Random Forest	n_estimators, max_depth	[50, 100, 200], [5, 10, 15]
XGBoost	learning_rate, n_estimators	[0.01, 0.05, 0.1], [100, 200]