



Université de Montpellier Paul Valéry

Mémoire de fin de première année de Master

Modélisation des comportements de santé par apprentissage automatique : régression, classification et clustering sur données synthétiques

Étudiant ARDACHAM Mahamat Teguene

Formation Master 1 MIASHS

Tuteurs universitaires Sophie Lèbre & Jérôme Pasquet

Année universitaire 2025–2026

Juin 2026

Remerciements

Je tiens tout d’abord à remercier **Madame Sophie Lèbre** et **Monsieur Jérôme Pasquet**, mes tuteurs universitaires, pour leurs enseignements, leurs conseils tout au long de cette année, ainsi que pour la validation du sujet de ce mémoire.

Je remercie l’ensemble des enseignants du master **MIASHS** de l’Université de Montpellier Paul Valéry, dont les cours ont directement nourri ce projet : **Maximilien Servagean**, **Catherine Trottier**, **Maïlis Amico**, **Arnaud Sallaberry**, **Sandra Bringay**, **Marine Demangeot** et al. Leurs enseignements en machine learning, statistique, visualisation, optimisation, . . . m’ont donné les outils nécessaires pour mener à bien cette analyse.

Je remercie également ma famille pour son soutien indéfectible tout au long de cette année, ainsi que mes amis et camarades de promotion, en particulier **ANZIZA Ahamada Madi**, pour les échanges, l’entraide et les moments partagés durant cette première année de master.

Résumé

Ce mémoire porte sur un projet de data science appliqué à la santé et aux modes de vie, avec pour objectif de modéliser des comportements à partir de données par apprentissage automatique. Le contexte médical s'appuie sur des seuils reconnus : obésité (IMC > 30 selon l'OMS, Organisation Mondiale de la Santé [1]), hypercholestérolémie (cholestérol > 200 mg/dL selon le NCEP, National Cholesterol Education Program [2]), hypertension (pression systolique ≥ 140 mmHg selon l'ESC, European Society of Cardiology [3]). Le jeu de données utilisé est le *Health & Lifestyle Dataset*, un dataset synthétique de 100 000 individus décrits par 15 variables : habitudes de vie (activité physique, sommeil, alimentation, tabagisme, alcool) et indicateurs biologiques (IMC, cholestérol, pression artérielle, fréquence cardiaque).

J'ai mis en place un pipeline complet selon la méthodologie CRISP-DM (Cross-Industry Standard Process for Data Mining) [4], allant de l'exploration des données jusqu'à l'interprétabilité des modèles. L'analyse exploratoire et le feature engineering ont permis de préparer les données : encodage des variables catégorielles, création de trois variables métier (score de style de vie composite, catégorie IMC, hypertension), standardisation. En **régression**, j'ai comparé six modèles (régression linéaire, Ridge, Lasso, ElasticNet, Random Forest, XGBoost) pour prédire le taux de cholestérol, avec tuning par `RandomizedSearchCV` et validation croisée K-Fold ($k = 5$). Un data leakage a été détecté et corrigé sur la variable `hypercholesterol` : le R^2 artificiel de 0.675 s'est réduit à ≈ 0 après sa suppression. En **classification**, trois modèles ont prédit le risque de maladie (`disease_risk`), avec deux stratégies de gestion du déséquilibre des classes comparées : ajustement des poids (`class_weight='balanced'`) et rééchantillonnage SMOTE [5]. En **clustering**, K-Means ($k = 3$) a révélé trois profils biologiques et la CAH (liaison Ward, sous-échantillon de 5 000 individus) a isolé un groupe de fumeurs intenses hypertendus ; les clusters ont été visualisés par ACP (24.3% de variance en 2D). L'**interprétabilité** a été analysée via les coefficients des modèles linéaires, les feature importances et SHAP (utilisé ici comme complément visuel).

Le résultat principal est une **limite fondamentale du dataset synthétique** : les variables ont été générées indépendamment, sans aucune relation causale. Aucun modèle n'a fait mieux qu'un prédicteur naïf ($R^2 \approx 0$, $AUC \approx 0.5$) le Lasso annule les 16 coefficients, le Random Forest atteint $R^2 = -0.005$. La divergence entre les cinq méthodes d'interprétabilité le confirme. Ce n'est pas un échec méthodologique : c'est la rigueur du pipeline qui a permis de le détecter. Ce travail est directement transposable à des données épidémiologiques réelles.

Mots-clés : data science, santé, machine learning, régression, classification, clustering, interprétabilité, SHAP, SMOTE, données synthétiques, data leakage, CRISP-DM.

Note sur l'utilisation de l'intelligence artificielle

Dans le cadre de ce mémoire, j'ai eu recours à des outils d'intelligence artificielle générative — principalement **Claude** (Anthropic) — comme aide à la recherche et à la rédaction. Voici comment ces outils ont été utilisés concrètement :

- **Recherche bibliographique** : exploration et synthèse de la littérature sur les thématiques abordées (machine learning en santé, méthodes de régularisation, gestion du déséquilibre de classes, interprétabilité).
- **Structuration du document** : aide à l'organisation des chapitres et à la formulation des transitions.
- **Relecture et reformulation** : suggestions de reformulation pour améliorer la clarté des explications techniques.
- **Débogage et code** : aide au débogage des notebooks Python (scikit-learn, XGBoost, SHAP) et à la compilation $\text{\LaTeX}$.

L'ensemble du contenu scientifique — choix des modèles, interprétation des résultats, analyse critique, conclusions — a été compris, vérifié et validé par l'auteur. L'IA a servi d'outil d'assistance ; elle n'a pas remplacé le raisonnement ni le travail analytique qui constituent le cœur de ce mémoire. Toutes les erreurs éventuelles restent de ma seule responsabilité.

Table des matières

Remerciements	ii
Résumé	iii
Note sur l'utilisation de l'IA	iv
Liste des figures	vii
Liste des tableaux	viii
Introduction	1
Contexte	1
1 État de l'art	4
1.1 L'apprentissage automatique appliqué à la santé	4
1.2 Régression : prédire des indicateurs biologiques	5
1.3 Classification : prédire le risque de maladie	5
1.4 Clustering : identifier des profils de mode de vie	6
1.5 Interprétabilité des modèles	6
1.6 Approches récentes et limites de l'état de l'art (2020–2024)	7
1.6.1 Transformers et modèles d'attention en santé	7
1.6.2 Foundation models et intelligence artificielle généraliste en médecine	8
1.6.3 Apprentissage fédéré : apprendre sans centraliser les données	8
1.6.4 Apprentissage causal : aller au-delà de la corrélation	8
1.6.5 Positionnement de ce projet dans l'état de l'art	9
2 Données et analyse exploratoire	10
2.1 Analyse exploratoire des données (EDA)	10
2.1.1 Présentation générale du dataset	10
2.1.2 Statistiques descriptives	10
2.1.3 Distribution des variables	10
2.1.4 Analyse des corrélations	11
2.1.5 Bilan de l'EDA	15
2.2 Feature Engineering et préparation des données	15
2.2.1 Encodage des variables catégorielles	15
2.2.2 Création de nouvelles variables	15
2.2.3 Mise à l'échelle	16

2.2.4	Dataset final	17
3	Modélisation supervisée	18
3.1	Régression : prédire le taux de cholestérol	18
3.1.1	Objectif et variable cible	18
3.1.2	Protocole expérimental	18
3.1.3	Modèles et justification	19
3.1.4	Résultats et analyse critique	20
3.2	Classification : prédire le risque de maladie	21
3.2.1	Objectif et contexte	21
3.2.2	Protocole expérimental	21
3.2.3	Métriques d'évaluation	22
3.2.4	Résultats et analyse critique	23
4	Clustering et interprétabilité	25
4.1	Clustering : identifier des profils de mode de vie	25
4.1.1	Objectif	25
4.1.2	Préparation des données	25
4.1.3	Sélection du nombre de clusters	25
4.1.4	K-Means	26
4.1.5	Classification Hiérarchique Ascendante (CAH)	26
4.1.6	Évaluation et visualisation	27
4.2	Interprétabilité des modèles	29
4.2.1	Objectif	29
4.2.2	Outils utilisés	29
4.2.3	Résultats, convergence et analyse critique	30
5	Organisation, bilan et perspectives	33
5.1	Méthodologie et organisation	33
5.1.1	Approche CRISP-DM	33
5.1.2	Outils et environnement technique	33
5.1.3	Compétences mobilisées	33
5.2	Difficultés rencontrées et retour d'expérience	33
5.2.1	Difficultés techniques	33
5.2.2	Compétences acquises	34
5.2.3	Plus-value : diagnostiquer les biais du pipeline	34
5.2.4	Biais identifiés et enjeux éthiques	35
5.2.5	Positionnement RSE / DDRS	36
5.2.6	Limites méthodologiques	36
5.3	Perspectives	37

Conclusion	37
Bibliographie	38
Liste des abréviations	41
Lexique	42
Annexes	43

Table des figures

1.1	Vue d'ensemble des grandes familles d'algorithmes de machine learning [7]	5
2.1	Distributions des variables continues du dataset	11
2.2	Distribution de la variable cible disease_risk (déséquilibre 75/25)	11
2.3	Matrice de corrélation de Pearson entre toutes les variables du dataset . . .	12
2.4	Corrélations de chaque variable avec la cible disease_risk	13
2.5	Pearson vs Spearman sur disease_risk et cholesterol — les deux méthodes donnent des valeurs quasi-nulles	13
2.6	Information Mutuelle des features avec disease_risk et cholesterol — $MI \approx 0$ confirme l'absence de toute dépendance statistique	14
2.7	Nuages de points : variables vs cholesterol (n=5 000) — la ligne de tendance est quasi-plate pour toutes les variables	14
2.8	Distribution des variables selon disease_risk : les deux groupes sont quasi-indiscernables	14
3.1	Courbes ROC des trois modèles de classification ($AUC \approx 0.5$ pour tous) .	23
3.2	Matrices de confusion des trois modèles de classification	24
4.1	Inertie intra-cluster et coefficient de silhouette selon k (K-Means)	26
4.2	Visualisation des clusters K-Means ($k = 3$) par projection ACP (2 composantes, 24.3% de variance)	29
4.3	Coefficients de la régression logistique (variables standardisées)	31
4.4	Feature importances (impureté de Gini) du Random Forest	31
4.5	SHAP summary plot (XGBoost) — complément visuel d'interprétabilité .	32

Liste des tableaux

2.1	Statistiques descriptives des variables continues	10
2.2	Bilan de l'analyse exploratoire	15
3.1	Résultats de régression (variable cible : cholesterol)	21
3.2	Résultats de classification (variable cible : disease_risk)	23
4.1	Inertie et silhouette selon k (K-Means)	26
4.2	Profils des clusters K-Means ($k = 3$)	26
4.3	Profils des clusters CAH ($k = 3, n = 5\,000$)	27
4.4	Comparaison K-Means vs CAH	28
4.5	Variables dans le top 5 de chaque méthode d'interprétabilité	30
5.1	Stack technique du projet	33
5.2	Lien entre enseignements MIASHS et applications projet	34

Introduction

Aujourd'hui, les données de santé sont partout. Les montres connectées mesurent notre sommeil, les applications comptent nos pas, les bilans sanguins enregistrent notre cholestérol. On génère sans le savoir une quantité massive d'informations sur nos habitudes de vie. Mais avoir des données ne suffit pas : encore faut-il savoir les analyser, les comprendre, et en tirer des conclusions utiles.

C'est exactement ce que permet la data science. À l'intersection des mathématiques, de la statistique et de l'informatique, elle offre des outils concrets pour explorer des jeux de données complexes, construire des modèles prédictifs et surtout, expliquer ce qui se passe derrière les chiffres.

Ce mémoire présente un projet de data science appliqué à la santé et aux modes de vie, réalisé dans le cadre de la première année de master MIASHS. La question centrale qui guide l'ensemble du travail est la suivante :

PROBLÉMATIQUE

QUELS FACTEURS DU MODE DE VIE INFLUENCENT LE PLUS L'ÉTAT DE SANTÉ D'UN INDIVIDU — ET PEUT-ON LES IDENTIFIER, LES MODÉLISER ET LES EXPLIQUER DE MANIÈRE RIGOUREUSE ?

Contexte

Contexte data science

La santé publique constitue l'un des domaines d'application les plus prometteurs de la data science [6, 7]. L'apprentissage statistique permet aujourd'hui d'aborder des problèmes variés : prédiction du risque de maladies chroniques, segmentation de populations selon leurs profils de santé, identification des facteurs de risque comportementaux [8].

Dans ce projet, l'objectif n'est pas seulement de prédire — c'est aussi et surtout de **comprendre**. Quand on prédit qu'une personne est à risque de maladie, il est crucial de pouvoir expliquer pourquoi : est-ce à cause de son manque de sommeil ? De son cholestérol élevé ? De son inactivité physique ? Cette dimension explicative est au cœur du travail présenté ici.

Contexte métier

Les maladies chroniques — maladies cardiovasculaires, diabète de type 2, hypertension — représentent aujourd'hui la première cause de mortalité mondiale [8]. Contrairement aux maladies infectieuses, elles se développent progressivement sous l'effet d'une accumulation de comportements quotidiens : sédentarité, mauvais sommeil, tabagisme, consommation d'alcool, alimentation déséquilibrée.

Ces facteurs comportementaux laissent des traces mesurables dans les indicateurs biologiques. Un **IMC** élevé (seuil OMS : 25 pour le surpoids, 30 pour l'obésité [1]) traduit un déséquilibre énergétique chronique. Un **taux de cholestérol** supérieur à 200 mg/dL signale un risque cardiovasculaire accru [2]. Une **pression artérielle** systolique ≥ 140 mmHg ou diastolique ≥ 90 mmHg indique une hypertension [3]. Ces seuils, établis par des organismes médicaux internationaux, servent de référence tout au long de ce mémoire.

L'enjeu est donc double : comprendre comment les habitudes de vie se traduisent en risques mesurables, et évaluer dans quelle mesure des modèles de machine learning peuvent capturer ces relations à partir de données observationnelles.

Présentation du jeu de données

Le projet s'appuie sur le *Health & Lifestyle Dataset*, un jeu de données synthétique disponible sur Kaggle, composé de **100 000 individus** décrits par **15 variables** :

- **Habitudes de vie** : `daily_steps`, `sleep_hours`, `water_intake_l`, `calories_consumed`, `smoker`, `alcohol`.

- **Indicateurs biologiques** : `bmi`, `resting_hr`, `systolic_bp`, `diastolic_bp`, `cholesterol`.
- **Caractéristiques personnelles** : `age`, `gender`, `family_history`.

La variable cible principale est `disease_risk`, un indicateur binaire (0/1) indiquant si un individu est considéré à risque de maladie. Bien que synthétique, ce dataset respecte des distributions statistiquement réalistes [5]. Les données synthétiques sont générées algorithmiquement et ne correspondent à aucun individu réel : elles permettent de développer et tester des méthodes sans risque de ré-identification, contrairement aux données médicales réelles qui sont soumises au Règlement Général sur la Protection des Données (RGPD) [9].

Lien avec la formation

Ce projet est directement ancré dans les enseignements du master MIAHS : réduction de dimension avec l'**ACP**, **régression linéaire et logistique**, **classification supervisée et non supervisée**, **régularisation et optimisation** (Ridge, Lasso, descente de gradient), et **méthodes ensemblistes** (Random Forest, XGBoost). Toutes ces notions sont mises en pratique ici de manière concrète, sur un problème à enjeu sociétal fort. Le deep learning, abordé en cours, n'est pas appliqué dans ce projet : les données tabulaires de taille modérée ne justifient pas son recours face aux méthodes ensemblistes [10].

Objectifs du projet

Le projet s'articule autour de quatre axes complémentaires :

1. **Analyse exploratoire** — comprendre la structure des données, les distributions, les corrélations, et formuler des hypothèses.
2. **Régression** — prédire des indicateurs biologiques continus comme le taux de cholestérol.
3. **Classification** — prédire le risque de maladie (`disease_risk`) et comparer plusieurs algorithmes.
4. **Clustering** — découvrir des profils types d'individus selon leur mode de vie.

Chapitre 1 : État de l’art

1.1 L’apprentissage automatique appliqué à la santé

L’apprentissage automatique a vraiment pris de l’ampleur en santé ces dernières années. Les travaux d’Obermeyer & Emanuel [6] ont montré que les algorithmes de ML peuvent faire mieux que les méthodes statistiques classiques pour anticiper des événements cliniques — ce qui n’est pas rien. Plus récemment, une revue dans *Nature Medicine* [7] dresse un panorama de l’état de l’art : diagnostic médical assisté par IA, prédiction du risque de maladies chroniques, personnalisation des traitements.

Ce qui m’intéresse ici, c’est cette idée que les maladies chroniques ne tombent pas du ciel : elles se développent progressivement à partir de comportements quotidiens mesurables [8]. Et si ces comportements laissent des traces dans les données, on devrait pouvoir les modéliser.




FIGURE 1.1 – Vue d'ensemble des grandes familles d'algorithmes de machine learning [7]

1.2 Régression : prédire des indicateurs biologiques

La régression linéaire reste l'une des méthodes les plus utilisées en statistique appliquée à la santé [11]. Mais elle a des hypothèses fortes, d'où le développement de variantes plus robustes. La régression Ridge [12] ajoute une pénalité $\lambda \|\mathbf{w}\|_2^2$ qui réduit les coefficients sans jamais les annuler — utile quand les variables sont peu informatives. La régression Lasso [13] utilise une pénalisation L_1 qui force certains coefficients exactement à zéro, ce qui revient à une **sélection automatique de variables** — c'est une propriété vraiment pratique.

Pour les données tabulaires, les méthodes ensemblistes comme les **forêts aléatoires** [14] et le **gradient boosting** (XGBoost [15]) donnent souvent de meilleurs résultats, en capturant les relations non-linéaires entre variables que la régression linéaire classique ne peut pas détecter.

1.3 Classification : prédire le risque de maladie

Prédire le risque de maladie est probablement le cas d'usage le plus étudié en santé numérique. Des modèles de classification ont été appliqués avec succès à la prédiction du diabète de type 2, des maladies cardiovasculaires ou encore de l'hypertension [7].

Parmi les algorithmes couramment utilisés :

- La **régression logistique** [11], modèle linéaire interprétable de référence.
- Les **forêts aléatoires** [14] et le **gradient boosting** [15], qui dominent les benchmarks sur données tabulaires.

Un point de vigilance important est le **déséquilibre des classes** [16] : dans notre dataset, 75,2% des individus sont sans risque contre seulement 24,8% à risque. Un modèle naïf qui prédit toujours "sans risque" atteint déjà 75% d'accuracy — sans rien apprendre

du tout.

Pour corriger ce biais, deux stratégies sont principalement utilisées. L'**ajustement des poids de classe** (`class_weight='balanced'`) pénalise davantage les erreurs sur la classe minoritaire pendant l'entraînement, sans modifier les données. Le **SMOTE** [5] (*Synthetic Minority Over-sampling Technique*) adopte une approche différente : il crée synthétiquement de nouveaux exemples de la classe minoritaire en interpolant entre observations existantes. Pour un individu x_i et l'un de ses k plus proches voisins x_{nn} dans la classe minoritaire :

$$x_{\text{new}} = x_i + \lambda \cdot (x_{nn} - x_i), \quad \lambda \in [0, 1] \quad (1.1)$$

J'ai appliqué et comparé les deux stratégies dans ce projet. Comme on le verra, aucune ne parvient à améliorer significativement l'AUC : cela confirme que le problème vient de l'absence de signal dans les données, et non du déséquilibre des classes.

1.4 Clustering : identifier des profils de mode de vie

Le clustering vise à regrouper des individus similaires sans variable cible prédéfinie [17]. En santé, cette approche est utilisée pour la **stratification de patients** [8] — identifier des groupes à profils similaires pour adapter la prise en charge.

L'algorithme **K-Means** [17] est la méthode de référence. La **classification hiérarchique ascendante (CAH)** propose une représentation visuelle via le dendrogramme. Pour évaluer la qualité d'un clustering, j'utilise le **coefficient de silhouette** [18] :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (1.2)$$

où $a(i)$ est la distance moyenne de l'observation i aux autres points de son cluster, et $b(i)$ est la distance moyenne au cluster voisin le plus proche. Une valeur proche de 1 indique un bon clustering.

1.5 Interprétabilité des modèles

Un modèle qui prédit bien mais qu'on ne comprend pas n'est pas suffisant — notamment en santé [19]. Deux familles d'approches s'opposent ici.

Les **modèles intrinsèquement interprétables** (régression linéaire, régression logistique, arbres de décision) permettent de lire directement les relations : les coefficients d'une régression indiquent immédiatement le sens et l'amplitude de l'effet de chaque variable.

Les **méthodes post-hoc** s'appliquent après l'entraînement, sur n'importe quel modèle — y compris les boîtes noires. L'idée : ne pas sacrifier les performances pour avoir de l'interprétabilité, mais expliquer le modèle a posteriori. **SHAP** [20] (*SHapley Additive exPlanations*) est la méthode post-hoc la plus répandue aujourd'hui. Issue de la théorie

des jeux coopératifs, elle répond à la question : *quelle est la contribution équitale de chaque variable à cette prédiction précise ?* La valeur SHAP ϕ_j de la variable j est :

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f(S \cup \{j\}) - f(S)] \quad (1.3)$$

où F est l'ensemble des variables, S un sous-ensemble ne contenant pas j , et $f(S)$ la prédiction du modèle avec uniquement les variables de S . Pour chaque individu, SHAP produit un score signé par variable : positif si la variable pousse vers le risque, négatif sinon.

Dans ce projet, je l'utilise comme **complément visuel**, aux côtés des feature importances (Random Forest, XGBoost) et des coefficients de la régression logistique — qui restent les interprétations principales.

1.6 Approches récentes et limites de l'état de l'art (2020–2024)

Les méthodes présentées dans les sections précédentes — régression régularisée, forêts aléatoires, XGBoost, K-Means — constituent l'outillage classique du ML appliqué à la santé. Elles restent pertinentes et largement utilisées sur des données tabulaires structurées. Cependant, le paysage du machine learning en santé a connu des transformations profondes depuis 2020, qu'il est nécessaire de situer.

1.6.1 Transformers et modèles d'attention en santé

Les architectures *transformer* [21] — initialement développées pour le traitement du langage naturel — ont été adaptées au domaine médical avec des résultats notables. **ClinicalBERT** [22] et ses variantes sont entraînés sur des millions de notes cliniques et permettent d'extraire de l'information structurée à partir de textes médicaux non structurés, un verrou majeur en santé numérique. En imagerie médicale, les *Vision Transformers* (ViT) rivalisent désormais avec les réseaux convolutifs (CNN) sur des tâches de classification radiologique [7].

L'avantage fondamental des transformers réside dans leur mécanisme d'*attention* : le modèle apprend à pondérer dynamiquement les relations entre tous les éléments d'une entrée, sans hypothèse de localité (contrairement aux CNN) ni de séquentialité stricte (contrairement aux LSTM). Sur des données tabulaires hétérogènes — mêlant variables continues, binaires et catégorielles comme dans notre dataset — des architectures comme **TabTransformer** [23] ou **FT-Transformer** [24] montrent des gains par rapport aux méthodes ensemblistes classiques, bien que XGBoost reste compétitif sur de nombreux benchmarks [25].

1.6.2 Foundation models et intelligence artificielle généraliste en médecine

Une rupture plus profonde est l'émergence des *foundation models* — de très grands modèles pré-entraînés sur des corpus massifs, adaptables à de nombreuses tâches par *fine-tuning*. **Med-PaLM** [26] (Google, 2022) et **GPT-4** [27] atteignent des niveaux de performance comparables à des cliniciens sur des questions médicales standardisées (USMLE). **BioMedLM** [28] est entraîné spécifiquement sur la littérature biomédicale PubMed.

Ces modèles posent cependant des questions critiques : leur performance sur des benchmarks académiques ne garantit pas leur fiabilité en contexte clinique réel, où les erreurs peuvent avoir des conséquences graves [26]. La question de la calibration — est-ce que la confiance exprimée par le modèle reflète sa vraie précision ? — reste ouverte, et constitue un enjeu de recherche actif.

1.6.3 Apprentissage fédéré : apprendre sans centraliser les données

Le **federated learning** [29] est une approche distribuée où les modèles sont entraînés localement sur chaque institution (hôpital, cabinet), et seuls les gradients — jamais les données brutes — sont agrégés sur un serveur central. Cette architecture répond directement aux contraintes du RGPD [9] et à la sensibilité des données de santé : une donnée patient ne quitte jamais l'établissement qui la détient.

En pratique, le federated learning introduit des défis propres : la distribution des données peut différer entre institutions (*non-IID setting*), ce qui complique la convergence du modèle agrégé. Des travaux comme FedAvg [30] et ses extensions abordent cette hétérogénéité. Dans le cadre de ce projet, les données sont centralisées et synthétiques ; mais toute transposition à des données épidémiologiques réelles multi-sites nécessiterait de considérer cette architecture.

1.6.4 Apprentissage causal : aller au-delà de la corrélation

La limite fondamentale des méthodes de ML classiques — y compris celles utilisées dans ce projet — est qu'elles modélisent des **corrélations**, pas des **relations causales**. Or, en santé, la question qui importe est rarement "est-ce que A est corrélé à B ?" mais "est-ce que A cause B ?", et surtout "si on intervient sur A, qu'arrive-t-il à B ?".

L'**inférence causale** [31] et l'**apprentissage causal** [32] répondent à cette question en modélisant explicitement des graphes causaux (*DAG* — *Directed Acyclic Graphs*) et en raisonnant sur des interventions ou des contrefactuels. Ces approches sont particulièrement pertinentes en épidémiologie : identifier les vrais facteurs de risque d'une maladie chronique (et non de simples marqueurs corrélés) nécessite une modélisation causale.

Dans le contexte de ce projet, l'absence de structure causale dans les données synthétiques est précisément ce qui rend toute inférence impossible : les variables ont été générées indépendamment, il n'existe donc aucun graphe causal sous-jacent à découvrir. Ce constat renforce l'intérêt d'un dataset réel pour une étude de suivi.

1.6.5 Positionnement de ce projet dans l'état de l'art

Les méthodes mobilisées dans ce mémoire — régression régularisée, méthodes ensemblistes, clustering, SHAP — constituent une base solide et reconnue pour une première exploration de données tabulaires de santé. Elles permettent d'établir des *baselines* interprétables et reproductibles, indispensables avant d'envisager des approches plus complexes.

L'apport de ce projet n'est pas de surpasser l'état de l'art, mais de construire un **pipeline de diagnostic rigoureux** : détection du data leakage, identification des biais du dataset, validation croisée stratifiée, comparaison multi-méthodes d'interprétabilité. Ce pipeline est directement transposable à des données réelles, où les méthodes récentes (federated learning, apprentissage causal) prendront tout leur sens.

Chapitre 2 : Données et analyse exploratoire

2.1 Analyse exploratoire des données (EDA)

2.1.1 Présentation générale du dataset

Le jeu de données contient **100 000 observations** décrites par **15 variables** (l'identifiant id est exclu), réparties en trois types :

- **Variables continues** : age, bmi, daily_steps, sleep_hours, cholesterol, resting_hr, systolic_bp, diastolic_bp (pressions artérielles).
- **Variables binaires** : smoker, alcohol, family_history, disease_risk.
- **Variable catégorielle** : gender.

Aucune valeur manquante n'est détectée, ce qui s'explique par la nature synthétique des données.

2.1.2 Statistiques descriptives

TABLE 2.1 – Statistiques descriptives des variables continues

Variable	Moyenne	Écart-type	Min	Max
age	48.5 ans	17.9	18	79
bmi	29.0	6.3	18.0	40.0
daily_steps	10 480	5 484	1 000	19 999
sleep_hours	6.5 h	2.0	3.0	10.0
cholesterol	224.3 mg/dL	43.3	150	299
systolic_bp	134.6 mmHg	26.0	90	179
resting_hr	74.5 bpm	14.4	50	99

Interprétation : Un IMC moyen de 29 se situe en limite de surpoids selon la classification OMS, qui fixe le seuil à 25 kg/m² [1]. Le taux moyen de cholestérol à 224 mg/dL dépasse le seuil de 200 mg/dL recommandé par le NCEP [2].

2.1.3 Distribution des variables

Toutes les variables continues affichent un skewness inférieur à $|0.02|$ — distributions **quasi-uniformes**, signature directe de la génération synthétique aléatoire. Une distribution réelle de l'IMC ou du cholestérol présenterait une asymétrie droite (valeurs extrêmes plus fréquentes vers le haut), ce qui nécessiterait une transformation logarithmique avant




FIGURE 2.1 – Distributions des variables continues du dataset




FIGURE 2.2 – Distribution de la variable cible `disease_risk` (déséquilibre 75/25)

modélisation. L'absence d'asymétrie ici est donc un premier signal de la nature artificielle des données, pas une propriété favorable de la population.

La variable cible présente un **déséquilibre des classes** (*class imbalance problem* [16]) : 75 179 individus (75.2%) sont sans risque contre seulement 24 821 (24.8%) à risque. Le problème concret est le suivant : un modèle naïf qui prédit *toujours* "sans risque" obtient déjà 75% d'accuracy — sans avoir rien appris. L'accuracy seule est donc une métrique trompeuse : elle ne distingue pas un bon modèle d'un modèle inutile. C'est pourquoi on privilégie le F1-score, la précision, le rappel et l'AUC-ROC, qui mesurent réellement la capacité à détecter les deux classes [33].

2.1.4 Analyse des corrélations

Résultat central : Les corrélations calculées sur le dataset sont toutes inférieures à $|0.01|$. La variable la plus corrélée avec `disease_risk` est `resting_hr` avec $r = 0.01$ —




FIGURE 2.3 – Matrice de corrélation de Pearson entre toutes les variables du dataset

statistiquement non significatif sur 100 000 individus. Cela confirme que la variable cible a été générée indépendamment des autres variables.

Au-delà de Pearson : trois analyses complémentaires. Pearson ne détecte que les relations linéaires. Trois approches ont été appliquées pour explorer les dépendances non-linéaires :

1. **Corrélation de Spearman** : corrélations inférieures à $|0.01|$ pour toutes les paires, identiques à Pearson (Figure 2.5). Aucune relation monotone non-linéaire détectée.
2. **Information Mutuelle** (`mutual_info_classif` et `mutual_info_regression`) : $MI \approx 0$ pour toutes les features vis-à-vis des deux cibles (Figure 2.6). Aucune dépendance statistique, quelle que soit sa forme.
3. **Nuages de points et Mann-Whitney U** : nuages uniformes sans structure (Figure 2.7), taille d'effet $r < 0.01$ pour toutes les variables.

Ces trois analyses convergent avec les résultats des modèles non-linéaires (chapitres suivants) : l'absence de signal est robuste quelle que soit la méthode [14].




FIGURE 2.4 – Corrélations de chaque variable avec la cible `disease_risk`




FIGURE 2.5 – Pearson vs Spearman sur `disease_risk` et `cholesterol` — les deux méthodes donnent des valeurs quasi-nulles




FIGURE 2.6 – Information Mutuelle des features avec `disease_risk` et `cholesterol` — $MI \approx 0$ confirme l'absence de toute dépendance statistique




FIGURE 2.7 – Nuages de points : variables vs `cholesterol` (n=5 000) — la ligne de tendance est quasi-plate pour toutes les variables




FIGURE 2.8 – Distribution des variables selon `disease_risk` : les deux groupes sont quasi-indiscernables

2.1.5 Bilan de l'EDA

TABLE 2.2 – Bilan de l'analyse exploratoire

Point	Constat	Implication
Valeurs manquantes	Aucune	Pas de preprocessing nécessaire
Distributions	Quasi-uniformes ($\text{skewness} < 0.02 $)	Pas de transformation logarithmique
Outliers	Aucun (méthode IQR)	Pas de traitement nécessaire
Corrélations	Quasi-nulles (< 0.01)	Privilégier modèles non-linéaires
Classe cible	Déséquilibrée (75/25)	Utiliser F1-score, AUC-ROC, SMOTE

Méthode IQR pour la détection des outliers. La règle $\pm 1.5 \times \text{IQR}$ appliquée à chaque variable continue ne détecte aucun outlier. Là encore, ce résultat s'explique par la génération synthétique : toutes les valeurs se distribuent uniformément entre un minimum et un maximum fixés, sans queue de distribution. Sur des données réelles, des cas extrêmes ($\text{IMC} > 45$, $\text{cholestérol} > 350 \text{ mg/dL}$) apparaîtraient systématiquement et nécessiteraient une décision explicite de traitement ou de conservation [11].

2.2 Feature Engineering et préparation des données

2.2.1 Encodage des variables catégorielles

La variable `gender` est encodée en variable binaire [10] :

$$\text{gender_enc} = \begin{cases} 1 & \text{si Male} \\ 0 & \text{si Female} \end{cases} \quad (2.1)$$

La colonne `id` est supprimée : identifiant technique sans pouvoir prédictif. La variable `hypercholesterol` ($= 1$ si `cholesterol` $> 200 \text{ mg/dL}$, seuil NCEP [2]) a été créée **temporairement dans le notebook de régression uniquement pour démontrer l'effet du data leakage** : en l'incluant comme feature, le R^2 monte artificiellement à 0.675. Elle n'a jamais été utilisée dans le clustering ni dans aucun autre notebook — elle est **exclue de toute modélisation**. Il s'agit d'un *data leakage* [34] direct : `hypercholesterol` est dérivée de `cholesterol`, la variable cible de la régression. Inclure une feature construite à partir de la cible revient à "donner la réponse" au modèle pendant l'entraînement — il obtient alors un R^2 artificiellement élevé qui s'effondrerait sur de nouvelles données réelles.

2.2.2 Création de nouvelles variables

J'ai construit trois nouvelles variables à partir de **connaissances métier** [10] : plutôt que de se limiter aux variables brutes, on encode directement dans les features des savoirs

médicaux établis. Par exemple, on ne "découvre" pas le seuil d'hypertension dans les données — on le connaît *a priori* grâce aux recommandations cliniques.

Hypertension selon les seuils de l'ESC (*European Society of Cardiology*, l'organisme médical européen définissant les recommandations cardiovasculaires) [3] :

$$\text{hypertension} = \begin{cases} 1 & \text{si systolic_bp} \geq 140 \text{ ou diastolic_bp} \geq 90 \\ 0 & \text{sinon} \end{cases} \quad (2.2)$$

Catégories IMC selon la classification OMS [1] :

$$\text{bmi_cat} = \begin{cases} 0 & \text{bmi} < 18.5 \text{ (sous-poids)} \\ 1 & 18.5 \leq \text{bmi} < 25 \text{ (normal)} \\ 2 & 25 \leq \text{bmi} < 30 \text{ (surpoids)} \\ 3 & \text{bmi} \geq 30 \text{ (obèse)} \end{cases} \quad (2.3)$$

Score de style de vie — score composite heuristique résumant l'hygiène de vie globale d'un individu en une seule valeur. Il n'est pas validé médicalement, mais repose sur la cohérence avec la littérature [8] : les facteurs favorables à la santé contribuent positivement, les facteurs de risque pénalisent. Chaque variable continue est divisée par son maximum pour la ramener entre 0 et 1, ce qui évite qu'une variable à grande échelle (comme `daily_steps`, jusqu'à 20 000) domine une variable à petite échelle (comme `sleep_hours`, entre 3 et 10) :

$$\begin{aligned} \text{lifestyle_score} = & \frac{\text{daily_steps}}{\text{max}} + \frac{\text{sleep_hours}}{\text{max}} + \frac{\text{water_intake_l}}{\text{max}} \\ & - \text{smoker} - \text{alcohol} \\ & - \frac{\text{bmi}}{\text{max}} - \frac{\text{calories_consumed}}{\text{max}} \end{aligned} \quad (2.4)$$

Les termes **positifs** (`daily_steps`, `sleep_hours`, `water_intake_l`) correspondent à des comportements bénéfiques pour la santé ; les termes **négatifs** (`smoker`, `alcohol`, `bmi` élevé, excès calorique) correspondent à des facteurs de risque établis [8].

2.2.3 Mise à l'échelle

Deux méthodes de mise à l'échelle sont appliquées selon le contexte [10] :

Standardisation (z-score) pour les modèles linéaires :

$$z_i = \frac{x_i - \bar{x}}{s} \quad (2.5)$$

Normalisation min-max pour les algorithmes de distance (K-Means) :

$$x_i^{\text{norm}} = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (2.6)$$

2.2.4 Dataset final

Le dataset original contient **15 variables** (identifiant `id` exclu). Après preprocessing, le dataset final compte **18 variables** : `gender` est remplacée par `gender_enc` (substitution directe, le nombre reste 15), puis trois nouvelles variables métier sont ajoutées (`bmi_cat`, `hypertension`, `lifestyle_score`), soit $15 + 3 = 18$ variables au total. Ces 18 variables couvrent les dimensions démographiques, les habitudes de vie, les indicateurs biologiques et les variables métier construites.

Chapitre 3 : Modélisation supervisée

3.1 Régression : prédire le taux de cholestérol

3.1.1 Objectif et variable cible

On cherche à prédire le taux de cholestérol (`cholesterol`, en mg/dL) à partir des habitudes de vie et indicateurs biologiques. Ce choix est médicalement motivé : le cholestérol est un facteur de risque cardiovasculaire reconnu [2].

Variables utilisées pour la prédiction. Pour la régression, 16 des 18 variables servent de features (`cholesterol` est la cible, `disease_risk` non pertinente ici) :

```
age, bmi, daily_steps, sleep_hours, water_intake_l, calories_consumed, smoker,
    alcohol,
    resting_hr, systolic_bp, diastolic_bp, family_history, gender_enc, bmi_cat,
    hypertension, lifestyle_score.
```

La variable `hypercholesterol` est exclue pour la raison suivante.

Note sur le data leakage : la variable `hypercholesterol` (= 1 si cholestérol > 200 mg/dL) a été créée temporairement dans ce notebook pour démontrer l'effet du leakage. Elle est directement dérivée de la variable cible : l'inclure comme feature revient à donner la réponse au modèle pendant l'entraînement — c'est un *data leakage* [34] qui gonfle artificiellement le R^2 à 0.675. Une fois retirée, le R^2 chute à ≈ 0 pour tous les modèles. Cette variable n'a été utilisée dans aucun autre notebook.

3.1.2 Protocole expérimental

Split 80/20 : 80 000 individus en entraînement, 20 000 en test (`random_state=42`). Le paramètre `random_state=42` fixe la graine du générateur aléatoire : il garantit que le découpage est **identique à chaque exécution du code**. Sans cette graine, le split serait différent à chaque run, rendant les résultats non reproductibles. Fixer `random_state` est une bonne pratique scientifique fondamentale : n'importe qui relançant le code obtient exactement les mêmes 80 000 individus d'entraînement et les mêmes 20 000 de test [11]. Ce ratio classique garantit un ensemble d'entraînement suffisamment grand pour que les modèles apprennent, tout en conservant 20 000 observations pour une évaluation statistiquement fiable. On n'utilise pas de troisième split (train/validation/test) car la validation croisée remplace avantageusement le jeu de validation fixe : elle exploite l'intégralité des données d'entraînement et produit une estimation plus robuste.

Validation croisée K-Fold ($k = 5$) [10] : le jeu d'entraînement est découpé en k plis égaux. À chaque itération, $k - 1$ plis servent à entraîner et le pli restant à valider ; on

répète k fois en changeant le pli de validation. Le score moyen sur les k itérations est :

$$\text{CV-score} = \frac{1}{k} \sum_{i=1}^k \text{score}_i, \quad k = 5 \quad (3.1)$$

où $k = 5$ est la valeur consensus dans la littérature [11] : avec 80 000 individus, chaque fold contient 16 000 exemples (suffisant), et $k = 5$ offre un bon compromis entre coût de calcul et fiabilité de l'estimation. $k = 10$ serait plus précis mais deux fois plus lent.

Ce que garantit la validation croisée : la CV garantit la **robustesse de l'estimation** hors-échantillon — avec $k = 5$ itérations, le résultat $R^2 \approx 0$ n'est pas un artefact du split particulier, mais une estimation stable. En revanche, elle ne garantit pas qu'un signal prédictif existe dans les données : elle mesure ce signal avec précision, quelle qu'en soit la valeur. Un $R^2 \approx 0$ bien estimé reste ≈ 0 .

Métriques d'évaluation. Trois métriques complémentaires [11] :

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i| \quad (3.2)$$

Le R^2 mesure si le modèle prédit mieux que la moyenne : $R^2 = 0$ signifie qu'il prédit $\bar{y}$ pour tout le monde, $R^2 < 0$ qu'il est pire que cette baseline triviale. L'interprétation la plus révélatrice est celle du RMSE : **43.33 mg/dL = exactement l'écart-type du cholestérol** dans le dataset (voir Table 2.1). Un modèle qui prédirait la moyenne $\bar{y} = 224.3$ mg/dL pour chaque individu obtiendrait, par définition, $\text{RMSE} = \sigma_y = 43.3$ mg/dL. C'est exactement ce que font tous nos modèles : le RMSE ne baisse pas, les features ne réduisent pas l'erreur d'une seule unité.

3.1.3 Modèles et justification

Les six modèles retenus suivent une logique de **spectre de complexité** : on part d'une baseline linéaire simple pour établir un plancher de performance, on ajoute des méthodes régularisées pour tester si contraindre les coefficients aide, puis des méthodes ensemblistes pour capturer d'éventuelles non-linéarités. Ce choix respecte un principe fondamental : si un modèle plus complexe ne fait pas mieux que la baseline, sa complexité supplémentaire n'est pas justifiée [11]. C'est exactement ce qu'on observe ici.

Régression linéaire (baseline) : point de référence obligatoire [11]. Si les autres modèles, plus complexes, ne font pas mieux, leur complexité supplémentaire n'est pas justifiée. Ici, c'est exactement ce qu'on observe.

Ridge (régularisation L_2) [12] :

$$\mathcal{L}_{\text{Ridge}} = \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j w_j^2 \quad (3.3)$$

La pénalité L_2 bride les coefficients sans les annuler. Résultat : avec $\lambda = 7197$ (très forte régularisation), les coefficients sont quasi-nuls — le modèle "apprend" à ignorer toutes les features, cohérent avec l'absence de signal.

Lasso (régularisation L_1) [13] :

$$\mathcal{L}_{\text{Lasso}} = \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j |w_j| \quad (3.4)$$

La pénalité L_1 réalise une **sélection automatique de variables** en forçant exactement certains coefficients à zéro. Résultat : avec $\lambda = 9.54$, Lasso fixe les **16 coefficients sur 16 à zéro** — preuve formelle que aucune des 16 features n'est linéairement prédictive du cholestérol.

ElasticNet [10] : combinaison des pénalités L_1 et L_2 via un paramètre de mélange $\rho \in [0, 1]$, offrant un compromis entre sélection (Lasso) et stabilité (Ridge). Produit ici des résultats identiques.

Random Forest [14] : bagging de B arbres de décision, chacun entraîné sur un sous-échantillon aléatoire :

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (3.5)$$

Contrairement aux méthodes linéaires, RF capture n'importe quelle relation non-linéaire. Son échec ($R^2 \approx 0$) est donc un résultat analytiquement plus fort que celui des méthodes linéaires : il élimine la possibilité d'une structure non-linéaire dans les données. En pratique, j'ai contraint les paramètres (`max_depth=15`, `max_samples=0.5`) pour éviter des temps d'entraînement de plusieurs heures observés avec `max_depth=None`.

XGBoost [15] : gradient boosting séquentiel — chaque arbre T_t corrige les erreurs résiduelles du modèle précédent avec un taux d'apprentissage η :

$$\hat{y}^{(t)} = \hat{y}^{(t-1)} + \eta \cdot T_t(\mathbf{x}) \quad (3.6)$$

XGBoost est généralement plus performant que RF sur données tabulaires [25]. Ici, $R^2 = 0.0001$ (tuné) contre $R^2 = -0.005$ pour RF non-contraint : une nuance sans signification pratique.

Tuning par RandomizedSearchCV [35] : les hyperparamètres (λ , `max_depth`, `learning_rate...`) sont fixés avant l'entraînement et ne peuvent pas être appris depuis les données. L'algorithme tire aléatoirement `n_iter=20` combinaisons d'hyperparamètres et les évalue par validation croisée : bien plus rapide que la grille exhaustive, pour une couverture suffisante [35].

3.1.4 Résultats et analyse critique

Analyse critique : Aucun modèle ne parvient à prédire le taux de cholestérol ($R^2 \approx 0$ pour tous). Plusieurs observations renforcent ce constat. D'abord, le

TABLE 3.1 – Résultats de régression (variable cible : `cholesterol`)

Modèle	R^2	RMSE (mg/dL)	MAE (mg/dL)	CV- R^2
LinearRegression (baseline)	0.0001	43.33	37.59	≈ 0
Ridge ($\lambda = 7197$, tuné)	0.0001	43.33	37.59	≈ 0
Lasso ($\lambda = 9.54$, tuné)	-0.0000	43.33	37.60	≈ 0
ElasticNet	-0.0000	43.33	37.60	≈ 0
Random Forest (tuné)	-0.005	43.44	37.67	≈ 0
XGBoost (tuné)	0.0001	43.33	37.59	≈ 0

Lasso (tuné) fixe les **16 coefficients sur 16 à zéro** : il se contente de prédire la moyenne du cholestérol (224.3 mg/dL) pour chaque individu — c’est la preuve formelle qu’aucune variable n’est linéairement prédictive. Ensuite, Random Forest et XGBoost non-tunés affichent des R^2 *négatifs* : ils sont plus mauvais que de prédire la moyenne, ce qui révèle qu’ils ont surajusté du bruit. Le tuning améliore légèrement XGBoost (R^2 repasse à 0.0001) mais ne change pas le fond du problème. Ce résultat illustre la **limite fondamentale du dataset synthétique** : les variables ont été générées indépendamment, sans relations causales réalistes encodées. Sur des données réelles, alimentation, activité physique et tabagisme influencent significativement le cholestérol [8] — cette relation est tout simplement absente ici.

Quel est le meilleur modèle en régression ? Aucun ne peut être retenu. Les différences entre modèles sont négligeables (R^2 entre -0.005 et 0.0001) : le « meilleur » sur le jeu de test (XGBoost tuné, $R^2 = 0.0001$) n’est pas statistiquement différent de la baseline linéaire. Sélectionner un modèle ici n’aurait aucun sens — tous prédisent essentiellement la moyenne du cholestérol (224.3 mg/dL) pour chaque individu.

3.2 Classification : prédire le risque de maladie

3.2.1 Objectif et contexte

On cherche à prédire si un individu est à risque de maladie (`disease_risk = 1`) ou non (`disease_risk = 0`). Le dataset présente un **déséquilibre de classes** : 75.2% sans risque, 24.8% à risque [16].

3.2.2 Protocole expérimental

Split stratifié 80/20 : le paramètre `stratify=y` maintient le ratio 75.2/24.8 dans les deux ensembles, évitant qu’un split aléatoire ne crée un jeu de test avec trop peu d’individus à risque [11].

Stratified K-Fold ($k = 5$) : maintient le ratio de classes dans chaque fold. Sans stratification, un fold pourrait ne contenir que des individus sans risque et biaiser l'évaluation [16].

Pourquoi 20 000 individus dans le jeu de test ? Le jeu de test correspond au split 80/20 : 20% de 100 000 = 20 000 individus. Ces individus n'ont jamais été vus pendant l'entraînement ni pendant le tuning des hyperparamètres. Toutes les matrices de confusion et métriques (AUC, F1, accuracy) sont calculées sur ces 20 000 observations — l'estimation de performance est donc non biaisée.

Gestion du déséquilibre : j'ai comparé deux stratégies. L'ajustement des poids (`class_weight='balanced'`) pénalise davantage les erreurs sur la classe minoritaire sans modifier les données [16]. SMOTE [5] crée synthétiquement de nouveaux exemples minoritaires par interpolation entre observations existantes, rééquilibrant les classes au niveau des données. Les deux approches sont comparées.

Résultat et conclusion sur SMOTE : ni SMOTE ni l'ajustement des poids n'améliorent les performances (AUC reste ≈ 0.5). Ce résultat confirme que le problème provient de l'**absence totale de signal**, pas du déséquilibre des classes : SMOTE génère de nouveaux exemples minoritaires, mais ces exemples synthétiques ont les mêmes valeurs de features que les exemples majoritaires — il ne peut pas créer un signal qui n'existe pas dans les données.

3.2.3 Métriques d'évaluation

Les métriques de classification retenues [33] :

$$\text{Précision} = \frac{TP}{TP + FP}, \quad \text{Rappel} = \frac{TP}{TP + FN}, \quad \text{F1} = \frac{2 \cdot \text{Précision} \cdot \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (3.7)$$

Le choix de la métrique principale est ici non trivial. L'accuracy (75% pour un modèle naïf) est trompeuse sur données déséquilibrées [16]. Le F1-score pénalise également les faux positifs et les faux négatifs — utile, mais ne rend pas compte du classement des individus par probabilité de risque. L'**AUC-ROC** [11] est la métrique centrale : elle mesure la capacité à ordonner correctement les individus (un malade a-t-il un score supérieur à un non-malade ?) indépendamment du seuil de décision. $\text{AUC} = 0.5$ = hasard pur, $\text{AUC} = 1$ = discrimination parfaite.

Note sur le SVM : le SVM a été écarté pour sa complexité $\mathcal{O}(n^2)$ à $\mathcal{O}(n^3)$, incompatible avec 100 000 observations sans infrastructure dédiée. Un test sur 5 000 individus a confirmé $\text{AUC} \approx 0.5$: son exclusion ne prive pas l'analyse d'un résultat différenciant.

Note sur le classifieur naïf de Bayes : fondé sur l'hypothèse d'indépendance conditionnelle des variables étant donné la classe [11], ce classifieur est précisément adapté à notre dataset — les variables ont justement été générées indépendamment. Son absence constitue une **limite du choix de modèles** : il aurait été pertinent de l'inclure, et l'on




FIGURE 3.1 – Courbes ROC des trois modèles de classification ($AUC \approx 0.5$ pour tous)

anticipe un résultat identique ($AUC \approx 0.5$), l'absence de signal ne dépendant pas du classifieur choisi.

3.2.4 Résultats et analyse critique

TABLE 3.2 – Résultats de classification (variable cible : `disease_risk`)

Modèle	Accuracy	Précision	Rappel	F1	AUC-ROC
Naïf (tout à 0)	0.752	—	0.000	0.000	0.500
Logistic Regression	0.498	0.249	0.509	0.335	0.499
Random Forest	0.568	0.245	0.355	0.290	0.494
XGBoost	0.525	0.246	0.441	0.316	0.499

* La précision du modèle naïf est indéfinie : ce modèle prédit toujours 0, donc il n'émet jamais de prédiction positive ($TP = 0$, $FP = 0$), ce qui conduit à une division par zéro dans la formule $\frac{TP}{TP+FP}$.




FIGURE 3.2 – Matrices de confusion des trois modèles de classification

Analyse critique : La colonne **AUC-ROC** est la métrique centrale : tous les modèles affichent $AUC \approx 0.5$, ce qui signifie qu’aucun ne discrimine mieux qu’un tirage aléatoire [11]. L’accuracy seule est trompeuse : Random Forest affiche 56.8% d’accuracy mais une AUC de **0.494** — **inférieure au modèle naïf** (0.500). En pratique, un Random Forest à 56.8% d’accuracy est pire qu’un modèle qui dit toujours "sans risque", en termes de capacité à distinguer les deux classes. Cela illustre pourquoi l’accuracy seule est dangereuse sur des données déséquilibrées [33] : elle peut masquer un modèle inutile derrière un chiffre élevé.

Lecture des matrices de confusion (Figure 3.2) : chaque matrice est calculée sur les 20 000 individus du jeu de test. Les lignes correspondent aux vraies étiquettes (ce que l’individu est réellement), les colonnes aux étiquettes prédites. Un modèle efficace aurait des valeurs élevées sur la diagonale (vrais positifs + vrais négatifs) et faibles hors-diagonale. Ici, pour chaque modèle, les chiffres de chaque ligne sont presque équilibrés entre les deux colonnes : un vrai malade a à peu près autant de chances d’être prédit "à risque" que "sans risque". C’est exactement le comportement d’un modèle qui tire au sort — cohérent avec $AUC \approx 0.5$.

Avec `class_weight='balanced'`, les modèles augmentent leur rappel (ils détectent plus d’individus à risque) mais leur accuracy tombe sous 50% — ils sur-correctent le déséquilibre au détriment de la précision. Ces résultats sont cohérents avec ceux de la régression ($R^2 \approx 0$) : les deux confirment que `disease_risk` a été généré indépendamment de toutes les autres variables.

Quel est le meilleur modèle en classification ? Aucun modèle n’est retenu pour déploiement. Avec $AUC \approx 0.5$ pour tous, aucun ne discrimine mieux qu’un tirage aléatoire : choisir le « meilleur » n’a pas de sens statistique. Les légères différences d’accuracy ou de F1 entre modèles reflètent des variations aléatoires sur un signal nul, et non une vraie hiérarchie de performance.

Effet de la taille du jeu de données. Augmenter le nombre d’observations ne ferait pas apparaître un signal absent : 100 000 individus est déjà un très grand échantillon, et les corrélations restent inférieures à $|0.01|$ quelle que soit la taille. En revanche, sur des **données réelles** présentant de vraies relations, un plus grand dataset permettrait de détecter des effets de faible amplitude qu’un petit échantillon masquerait [11]. Diminuer la taille augmenterait la variance des estimations sans résoudre le problème fondamental ici.

Chapitre 4 : Clustering et interprétabilité

4.1 Clustering : identifier des profils de mode de vie

4.1.1 Objectif

Le clustering est une méthode d'**apprentissage non supervisé** : il n'y a pas de variable cible. L'objectif est de regrouper les individus selon leur similarité pour identifier des **profils types de mode de vie** [17]. La variable `disease_risk` est exclue du clustering.

4.1.2 Préparation des données

Les 15 variables explicatives sont standardisées (z-score) avant d'appliquer les algorithmes. K-Means et CAH reposent sur la **distance euclidienne** [17] : sans standardisation, `daily_steps` (valeurs jusqu'à 20 000) dominerait mécaniquement `sleep_hours` (3 à 10), et le clustering serait réduit à une partition par cette seule variable. Le z-score garantit une contribution équitable de chacune des 15 dimensions [10].

La CAH étant de complexité $\mathcal{O}(n^2)$ (voir note sur le SVM au chapitre 3), elle est appliquée sur un sous-échantillon aléatoire de **5 000 individus** pour rester dans des temps de calcul raisonnables.

4.1.3 Sélection du nombre de clusters

Méthode du coude : on trace l'**inertie intra-cluster** $W(k)$ en fonction de k . L'inertie mesure la dispersion totale à l'intérieur des clusters :

$$W(k) = \sum_{j=1}^k \sum_{\mathbf{x} \in C_j} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \quad (4.1)$$

où C_j désigne le j -ème cluster et $\boldsymbol{\mu}_j$ son centroïde (vecteur des moyennes). Plus k augmente, plus l'inertie diminue — mais à partir d'un certain k , le gain devient marginal : c'est le "coude" de la courbe, au-delà duquel ajouter des clusters ne compense plus la complexité.

Coefficient de silhouette [18] : défini au chapitre 1, il mesure la qualité de séparation des clusters. Pour rappel :


$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (4.2)$$

où $a(i)$ est la distance moyenne de l'individu i aux autres membres de son cluster, et $b(i)$ la distance moyenne au cluster voisin le plus proche. Une valeur proche de 1 indique une bonne séparation.

$k = 3$ maximise la silhouette et correspond au coude de la courbe d'inertie. $k = 3$ **est retenu**.

TABLE 4.1 – Inertie et silhouette selon k (K-Means)

k	Inertie	Silhouette
2	1 346 768	0.0979
3	1 238 076	0.1030
4	1 188 303	0.0967
5	1 152 260	0.0886
10	1 031 548	0.0744

FIGURE 4.1 – Inertie intra-cluster et coefficient de silhouette selon k (K-Means)

4.1.4 K-Means

L'algorithme K-Means [17] alterne affectation au centroïde le plus proche et mise à jour des centroïdes : $\mu_j = \frac{1}{|C_j|} \sum_{\mathbf{x} \in C_j} \mathbf{x}$, jusqu'à convergence.

TABLE 4.2 – Profils des clusters K-Means ($k = 3$)

Cluster	Taille	IMC moyen	Syst. (mmHg)	Profil
0	32 754	35.0 (obèse)	142 (hypertendu)	Obèse hypertendu
1	27 673	29.1 (surpoids)	115 (normotendu)	Surpoids normotendu
2	39 573	24.0 (normal)	142 (hypertendu)	Poids normal hypertendu

Interprétation : K-Means partitionne la population selon l'**IMC** et la **pression artérielle systolique**. Ce résultat s'explique par la sensibilité de K-Means aux variables à grande variance : dans notre dataset, **bmi** (écart-type = 6.3) et **systolic_bp** (écart-type = 26.0) ont les dispersions les plus larges après standardisation, ce qui les rend naturellement "dominantes" pour la distance euclidienne. Le cluster 1 regroupe les individus les plus sains (surpoids mais normotendus), tandis que les clusters 0 et 2 correspondent à deux profils à risque cardiovasculaire distincts selon la classification OMS [1] et ESC [3].

4.1.5 Classification Hiérarchique Ascendante (CAH)

La CAH construit un **dendrogramme** en fusionnant progressivement les clusters les plus proches. Au départ, chaque individu est son propre cluster ; à chaque étape, on fusionne les deux

clusters dont la fusion est la "moins coûteuse" [10].

La **méthode de liaison Ward** définit le coût de fusion de A et B comme l'augmentation de variance intra-cluster :

$$\Delta(A, B) = \frac{|A| \cdot |B|}{|A| + |B|} \|\mu_A - \mu_B\|^2 \quad (4.3)$$

Ward minimise ce coût à chaque étape, favorisant des clusters **compacts et équilibrés** — d'où sa sensibilité aux sous-groupes comportementaux homogènes dans nos données.

TABLE 4.3 – Profils des clusters CAH ($k = 3$, $n = 5\,000$)

Cluster	Taille	Fumeurs	Syst. (mmHg)	Profil
0	2 928	2%	142	Non-fumeurs hypertendus
1	1 407	18%	115	Fumeurs modérés, normotendus
2	665	100%	142	Fumeurs intenses, hypertendus

Interprétation : La CAH isole un **cluster de fumeurs intenses** (100% de fumeurs + hypertendus). Ce résultat s'explique par la nature de l'algorithme : Ward cherche des sous-groupes *homogènes*, y compris sur des variables binaires comme **smoker**. K-Means, guidé par les grandes variances numériques, n'aurait pas isolé ce groupe de 665 individus — il les aurait dilués dans les clusters dominés par l'IMC et la pression. Les deux méthodes sont donc **complémentaires** : K-Means donne une vue globale par dimensions biologiques continues, la CAH révèle des sous-groupes comportementaux fins. Le profil tabagisme + hypertension est un double facteur de risque cardiovasculaire bien documenté [8].

4.1.6 Évaluation et visualisation

Visualisation par ACP (Analyse en Composantes Principales). Nos données vivent dans un espace à 15 dimensions : il est impossible de les représenter directement. L'ACP projette ces 15 dimensions sur les 2 axes qui capturent le maximum de variance, permettant une visualisation 2D des clusters. Les deux premières composantes expliquent **24.3%** de la variance totale : la projection 2D "voit" seulement 24.3% de l'information originale. Si les clusters semblent peu séparés sur le graphique, ce n'est pas la preuve qu'ils n'existent pas — ils se distinguent dans les 15 dimensions d'origine, pas dans la réduction 2D. Avec 15 variables quasi-indépendantes (confirmé par l'EDA), aucune direction ne concentre beaucoup de variance : 24.3% en 2D est donc attendu.

Pourquoi les clusters ont-ils une forme rectangulaire dans la projection ACP ? Sur le graphique ACP (figure 4.2), les clusters apparaissent comme des **blocs rectangulaires** plutôt que des nuages sphériques — résultat directement lié à la nature des variables du dataset.

La première composante (PC1, axe horizontal) est fortement influencée par **bmi_cat**, variable ordinaire à **4 valeurs discrètes** (sous-poids, normal, surpoids, obèse) : les individus s'alignent en 4 bandes verticales au lieu de se répartir continûment. La deuxième composante (PC2, axe vertical) est dominée par **hypertension**, variable **binaire** : ses deux seules valeurs produisent un saut net haut/bas, divisant le nuage entre normotendus et hypertendus.

Par ailleurs, les distributions quasi-uniformes de toutes les variables continues (chapitre 2) créent des nuages de points dispersés sans gradient de densité visible : les points se répartissent uniformément au lieu de former des ellipses denses au centre. Le résultat final est une grille de rectangles dont la forme reflète la structure discrète du dataset plutôt qu’une vraie géométrie en clusters.

Indice de Davies-Bouldin [36]. Cet indice mesure la qualité du clustering en calculant, pour chaque cluster i , le ratio entre la dispersion interne et la distance entre centroïdes :

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{d(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j)} \right) \quad (4.4)$$

où σ_i est la dispersion moyenne des points du cluster i autour de son centroïde, et $d(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j)$ la distance entre les centroïdes i et j . **Un DB proche de 0 est idéal** : les clusters sont compacts (faible σ) et bien séparés (grande distance). Un DB élevé indique des clusters éparpillés ou trop proches les uns des autres. Contrairement à la silhouette qui évalue chaque point individuellement, Davies-Bouldin évalue chaque paire de clusters : les deux métriques sont complémentaires.

TABLE 4.4 – Comparaison K-Means vs CAH

Métrique	K-Means	CAH	Interprétation
Silhouette	0.103	0.105	Faible — clusters peu séparés
Davies-Bouldin	2.655	2.721	Élevé — chevauchement entre clusters
Variance ACP (2D)	24.3%		Projection insuffisante (15 dims $\rightarrow$ 2D)

Malgré des silhouettes faibles (≈ 0.10), les deux méthodes révèlent des structures interprétables médicalement [1, 8] : obèse hypertendu (K-Means), fumeurs intenses + hypertendus (CAH). La faible silhouette reflète l’absence de groupes naturels francs dans des données synthétiques générées sans structure causale — pas une erreur méthodologique.




FIGURE 4.2 – Visualisation des clusters K-Means ($k = 3$) par projection ACP (2 composantes, 24.3% de variance)

4.2 Interprétabilité des modèles

4.2.1 Objectif

Cette section pose une question précise : **les outils d'interprétabilité convergent-ils vers les mêmes variables influentes, même en l'absence de signal?** La réponse est elle-même un résultat analytique.

4.2.2 Outils utilisés

Coefficients des modèles linéaires : un coefficient $w_j > 0$ indique qu'une augmentation de la variable j est associée à une augmentation de la prédiction [11]. Leur magnitude reflète l'importance relative de chaque variable — sous réserve que les variables soient standardisées.

Feature Importance (impureté de Gini) [14] : pour les forêts aléatoires, l'importance de la variable j agrège la réduction d'impureté de Gini qu'elle apporte à travers tous les nœuds de tous les arbres. Plus une variable est utilisée haut dans les arbres pour des décisions qui séparent bien les classes, plus son importance est élevée. La limite connue de cet indicateur : il favorise les variables à haute cardinalité ou grande variance — ce qui, dans notre cas, explique que `systolic_bp` domine systématiquement.

SHAP : défini au chapitre 1 (formule des valeurs de Shapley) et utilisé ici comme complément visuel, il attribue à chaque variable une contribution signée à chaque prédiction individuelle. Les formules ne sont pas redéfinies ici.

4.2.3 Résultats, convergence et analyse critique

Les cinq méthodes d'interprétabilité (coefficients LR, Ridge, feature importance RF, XGBoost, SHAP) sont appliquées et leurs top 5 variables comparés.

Analyse critique : Les cinq méthodes ne s'accordent pas sur un classement stable — **cette divergence est elle-même un résultat** [19] : sans signal prédictif réel, chaque outil mesure du bruit aléatoire et s'accroche à des corrélations parasites différentes. La seule variable présente dans les cinq méthodes est `systolic_bp` : dans la littérature épidémiologique réelle, la pression artérielle est effectivement l'un des facteurs de risque cardiovasculaire les mieux documentés [3] — mais dans nos données, cette convergence résulte de sa grande variance, pas d'une vraie relation causale.

Sur des données réelles [1,8], on s'attendrait à voir la pression artérielle, le cholestérol LDL, le tabagisme, l'IMC et l'activité physique dominer clairement les classements, avec des coefficients significativement différents de zéro.

Comment lire le SHAP summary plot ? Chaque **ligne** correspond à une variable, triée de haut en bas par importance décroissante (impact moyen en valeur absolue). Sur chaque ligne, chaque **point** représente un individu. L'**axe horizontal** indique l'impact SHAP sur la prédiction : un point à droite ($x > 0$) signifie que la variable pousse la prédiction vers 1 (`disease_risk` élevé) ; un point à gauche ($x < 0$) la pousse vers 0 ; en $x = 0$, aucun impact. La **couleur** encode la valeur réelle de la variable : rouge = valeur élevée, bleu = valeur faible.

Sur des données avec un signal réel, on verrait un gradient net : par exemple, si une pression artérielle élevée (rouge) est un facteur de risque, les points rouges se concentreraient à droite et les bleus à gauche. Ici, les couleurs sont **mélangées aléatoirement** autour de zéro : des points rouges et bleus occupent les mêmes positions horizontales, sans aucun pattern. Cela confirme qu'aucune variable n'a d'impact systématique — SHAP détecte du bruit plutôt qu'un signal.

Le tableau suivant synthétise la présence de chaque variable dans le top 5 des cinq méthodes :

TABLE 4.5 – Variables dans le top 5 de chaque méthode d'interprétabilité

Variable	LR	RF	XGB	SHAP	Ridge	Score
<code>systolic_bp</code>	✓	✓	✓	✓	✓	5/5
<code>daily_steps</code>	✓	✓	—	✓	—	3/5
<code>family_history</code>	✓	—	✓	—	✓	3/5
<code>bmi</code>	—	✓	—	✓	—	2/5




FIGURE 4.3 – Coefficients de la régression logistique (variables standardisées)




FIGURE 4.4 – Feature importances (impureté de Gini) du Random Forest




FIGURE 4.5 – SHAP summary plot (XGBoost) — complément visuel d’interprétabilité

Chapitre 5 : Organisation, bilan et perspectives

5.1 Méthodologie et organisation

5.1.1 Approche CRISP-DM

Ce projet a été conduit en suivant le cycle **CRISP-DM** [4], qui structure un projet de data science en six phases : compréhension du problème, compréhension des données, préparation des données, modélisation, évaluation, et déploiement. Chaque phase a alimenté la suivante de manière itérative : l'EDA a révélé l'absence de signal linéaire, ce qui a orienté le choix des modèles non-linéaires ; la détection du data leakage a conduit à réviser le feature engineering ; les résultats de classification ont confirmé le diagnostic de l'EDA.

5.1.2 Outils et environnement technique

TABLE 5.1 – Stack technique du projet

Catégorie	Outil	Usage
Langage	Python 3	Ensemble du projet
Manipulation données	pandas, numpy	Chargement, nettoyage, feature engineering
Modélisation	scikit-learn, xgboost	Entraînement, tuning, évaluation
Déséquilibre classes	imbalanced-learn	Rééchantillonnage SMOTE
Interprétabilité	shap	Valeurs SHAP sur XGBoost
Réduction de dim.	scikit-learn (PCA)	Visualisation clustering
Versionnement	Git / GitHub	Suivi des notebooks et du rapport
Rédaction	L ^A T _E X	Mémoire

5.1.3 Compétences mobilisées

5.2 Difficultés rencontrées et retour d'expérience

5.2.1 Difficultés techniques

La limite fondamentale du dataset synthétique est la difficulté principale que j'ai rencontrée. Découvrir que $R^2 \approx 0$ et $AUC \approx 0.5$ pour tous les modèles a demandé un vrai travail de diagnostic : relier ce résultat au constat de l'EDA (corrélations < 0.01) et à la nature synthétique des données a été l'exercice analytique central de ce projet.

TABLE 5.2 – Lien entre enseignements MIASHS et applications projet

Enseignement M1	Application dans le projet
ACP / ACM	Réduction dimensionnelle pour la visualisation des clusters
Régression linéaire & diagnostic	Baseline régression, Ridge, Lasso, ElasticNet
Classification supervisée	Logistic Regression, Random Forest, XGBoost
Apprentissage non supervisé	K-Means, CAH
Descente de gradient & optimisation	Compréhension de XGBoost et de la log-loss
Régression logistique	Baseline classification + interprétation coefficients
Régularisation & optimisation	Ridge, Lasso, ElasticNet
Déséquilibre de classes	class_weight, SMOTE (imbalanced-learn)
Python	Ensemble du pipeline de data science

La détection du data leakage sur `hypercholesterol` [34] est une difficulté classique en ML, rarement rencontrée dans les travaux académiques. Le R^2 artificiel de 0.675 aurait pu passer inaperçu sans une analyse rigoureuse des feature importances.

Le coût computationnel : un premier essai de Random Forest sans contraintes de profondeur ni parallélisation a conduit à un entraînement de plus de 3 heures interrompu avant convergence. Cela m’a forcé à comprendre les paramètres internes (`max_depth`, `n_jobs`). Le SVM a été écarté pour la même raison : complexité $\mathcal{O}(n^2)$ incompatible avec 100 000 observations.

5.2.2 Compétences acquises

- **Détection et correction du data leakage** [34] : piège courant non systématiquement couvert en cours théoriques.
- **RandomizedSearchCV** [35] : logique de l’exploration aléatoire vs exhaustive des hyperparamètres.
- **Gestion du déséquilibre de classes** : comparaison concrète entre ajustement des poids (`class_weight`) et SMOTE [5], et maîtrise de la différence entre accuracy, F1-score et AUC-ROC [33].
- **Interprétabilité multi-méthodes** : la divergence entre outils est elle-même informative [19].
- **Analyse critique d’un résultat négatif** : savoir diagnostiquer pourquoi un modèle échoue est aussi précieux que d’en construire un qui réussit.

5.2.3 Plus-value : diagnostiquer les biais du pipeline

Ce projet ne produit pas un modèle prédictif déployable — les métriques ($R^2 \approx 0$, AUC ≈ 0.5) l’excluent. Sa plus-value réside dans une contribution différente : **construire un pipeline capable de diagnostiquer pourquoi un modèle échoue**, et d’identifier rigoureusement ses biais.

Trois apports concrets peuvent être retenus :

1. **Détection du data leakage.** La variable `hypercholesterol` produisait un R^2 artificiel de 0.675 [34]. Un pipeline mal construit aurait publié ce résultat comme une performance

réelle. La détection et la correction rigoureuse de ce biais est une compétence directement valorisable sur des données épidémiologiques réelles.

2. **Diagnostic de l'absence de signal par cinq preuves convergentes.** Corrélations de Pearson < 0.01 (EDA), $R^2 \approx 0$ sur six modèles de régression dont des méthodes non-linéaires (Random Forest, XGBoost), AUC ≈ 0.5 sur trois modèles de classification, silhouettes ≈ 0.10 en clustering, et divergence des cinq outils d'interprétabilité. Cette convergence de preuves indépendantes est plus robuste qu'un résultat isolé.
3. **Accuracy trompeuse sur données déséquilibrées.** Un modèle naïf atteignait 75% d'accuracy sur le déséquilibre 75/25 ; le Random Forest affichait 56.8% d'accuracy mais une AUC de 0.494, soit *pire* que le hasard pur [33]. Identifier et exposer ce piège méthodologique est un résultat analytique à part entière.

Ce pipeline est **directement transposable** sur des données réelles [37, 38] : les mêmes étapes de détection de leakage, de validation des métriques et de comparaison des méthodes s'appliquent, et le signal réel permettrait d'obtenir des résultats prédictifs exploitables.

5.2.4 Biais identifiés et enjeux éthiques

Au-delà du data leakage — biais technique identifié et corrigé — ce projet met en évidence des biais plus fondamentaux, de nature méthodologique et éthique, qu'il est nécessaire d'analyser explicitement.

1. Biais de représentation : l'impossibilité de généraliser. Le dataset est synthétique : les 100 000 individus ne représentent aucune population réelle. Les distributions ont été générées sans ancrage épidémiologique validé (aucune cohorte de référence, aucun rapport sur la méthode de génération). Cela rend toute généralisation structurellement impossible : un modèle entraîné ici ne peut pas être évalué sur Framingham [37] ou NHANES [38], car les distributions diffèrent de façon inconnue. Ce biais est antérieur à toute modélisation : il est inscrit dans le choix du dataset.

2. Biais de conception : répondre à une question avec des données inadaptées. L'objectif initial est de modéliser les relations entre habitudes de vie et indicateurs biologiques. Or, dans un dataset synthétique sans structure causale, les variables ont été générées indépendamment : il n'existe, par construction, aucune relation à découvrir [32]. Appliquer des méthodes de ML sur ces données revient à chercher un signal que l'on sait absent. Ce biais de conception est distinct du biais de représentation : même si le dataset représentait une vraie population, l'absence de structure causale rendrait l'inférence impossible. En termes d'apprentissage causal [31], le DAG sous-jacent est un graphe sans arcs — chaque variable est une île.

3. Enjeux de fairness algorithmique. Si ce pipeline était déployé sur des données réelles, un biais critique émergerait : les performances peuvent varier considérablement selon les sous-groupes. Le travail d'Obermeyer et al. [39] a démontré qu'un algorithme utilisé dans des millions d'hôpitaux américains présentait un biais racial systématique, pénalisant les patients noirs à sévérité médicale égale. En santé, la fairness n'est pas un aspect secondaire : un modèle avec AUC globale acceptable peut masquer des performances très inégales selon le genre, l'âge, ou d'autres attributs protégés [19]. Dans ce projet, le déséquilibre 75/25 sur `disease_risk` est lui-

même un signal : si cette variable était réelle, le seuil de décision du classificateur devrait être calibré en tenant compte de l'impact différentiel sur les groupes sous-représentés.

4. Risques de déploiement : quand l'absence de signal devient dangereuse. Un résultat central de ce projet — $AUC \approx 0.5$ — signifie que les modèles ne font pas mieux que le hasard pour prédire `disease_risk`. Ce résultat, s'il était mal interprété ou ignoré, pourrait conduire à des décisions erronées. Un praticien ou un décideur qui fait confiance à un modèle avec $AUC = 0.494$ prend des décisions au hasard, avec en plus l'illusion d'une base scientifique. Cette situation — modèle inutile mais présenté comme fiable — est l'un des risques les plus documentés de l'IA en santé [7]. La calibration des prédictions (est-ce que "70% de probabilité de risque" en sortie correspond vraiment à 70% de cas réels?) est une exigence minimale avant tout déploiement.

Ces quatre biais — représentation, conception, fairness, déploiement — constituent l'essentiel du travail critique qu'un data scientist doit conduire avant de présenter des résultats, y compris des résultats négatifs. Les identifier n'invalide pas le projet : cela en précise le périmètre de validité et les conditions d'un travail de suivi crédible.

5.2.5 Positionnement RSE / DDRS

L'utilisation d'un dataset **synthétique** s'inscrit dans une démarche éthique : les données de santé sont sensibles et encadrées par le RGPD [9]. Les données synthétiques éliminent tout risque de ré-identification tout en permettant de développer des méthodes — un compromis central de l'IA responsable [9].

Le coût énergétique des entraînements a été limité en contraignant la profondeur des arbres (`max_depth=15`) et en réduisant `n_iter` dans `RandomizedSearchCV`, avec un impact positif sur l'empreinte carbone du calcul.

5.2.6 Limites méthodologiques

Corrélations non-linéaires non explorées. L'analyse de Pearson a révélé des coefficients inférieurs à $|0.01|$ — mais Pearson ne détecte que les relations *linéaires* [11]. Une analyse complémentaire aurait pu mobiliser le coefficient de Spearman (corrélation des rangs, capte les relations monotones), la *mutual information* (`mutual_info_classif` dans scikit-learn, toute dépendance statistique quelle que soit sa forme), ou des nuages de points pour identifier visuellement des structures non-linéaires (relations en U, effets seuil, interactions).

Toutefois, l'utilisation de **Random Forest** et **XGBoost** [14] — algorithmes capables de capturer n'importe quelle relation non-linéaire — constitue une réponse indirecte à cette limite. Leur échec ($R^2 \approx 0$, $AUC \approx 0.5$) démontre que même les dépendances non-linéaires sont absentes : résultat plus fort qu'un test de Spearman ou de mutual information, car il exploite toute la puissance des méthodes ensemblistes sur 100 000 individus.

5.3 Perspectives

1. Changer de dataset : reproduire le pipeline sur un dataset réel, comme la cohorte Framingham [37] ou les données NHANES [38], qui contiennent de vraies relations entre habitudes de vie et indicateurs de santé. Les méthodes développées ici sont directement transposables.

2. Améliorer les modèles de classification : explorer le **stacking** (combinaison de plusieurs modèles [10]) et les **réseaux de neurones** pour capturer des relations très non-linéaires — en lien direct avec le module Deep Learning du master. SMOTE ayant déjà été intégré dans ce projet, ces pistes constituent la suite logique.

3. Déploiement : un modèle de classification pourrait être déployé sous forme d’API REST (FastAPI) permettant de soumettre un profil individuel et d’obtenir une prédiction avec ses valeurs SHAP associées, rendant le modèle accessible et explicable.

4. Interprétabilité avancée : les *Partial Dependence Plots* (PDP) et les *Individual Conditional Expectation* (ICE) permettraient de visualiser comment la prédiction varie en fonction d’une variable, toutes choses égales par ailleurs — une limite de SHAP qui agrège les contributions.

5. Robustesse sur le long terme (*data drift*) : sur des données réelles en production, un modèle se dégrade si la distribution des données évolue au fil du temps — on parle de *concept drift* [10]. Les habitudes de vie d’une population changent, les seuils médicaux sont révisés, les profils épidémiologiques se transforment. En pratique, cela implique de surveiller les performances du modèle périodiquement (suivi de l’AUC sur de nouvelles cohortes) et de le réentraîner dès que les performances se dégradent. Cette problématique ne s’applique pas au dataset synthétique statique de ce projet, mais sera centrale sur des données réelles.

6. Vers le Master 2 : les thématiques de causalité, fairness algorithmique et apprentissage fédéré constituent des pistes naturelles pour un travail de recherche en M2, dans la continuité directe de ce projet.

Ce projet a mobilisé un pipeline complet de data science — analyse exploratoire, feature engineering, régression, classification, clustering et interprétabilité — appliqué à un jeu de données de santé et de mode de vie de 100 000 individus. La question centrale que je me suis posée dès le départ était : *quels facteurs du mode de vie influencent le plus l'état de santé d'un individu — et peut-on les identifier, les modéliser et les expliquer de manière rigoureuse ?*

La réponse est double. **Du point de vue des résultats** : ce dataset synthétique ne permet pas de répondre à cette question — les variables ont été générées indépendamment, sans relation causale encodée. Aucun modèle, linéaire ou non-linéaire, simple ou optimisé, n'a dépassé les performances d'un prédicteur naïf ($R^2 \approx 0$, $AUC \approx 0.5$). Cette découverte progressive est elle-même un résultat analytique : elle illustre concrètement la différence entre données synthétiques et données réelles, et la nécessité d'interroger la qualité du signal avant de construire des modèles.

Du point de vue méthodologique : chaque étape du pipeline a été conduite avec rigueur. L'EDA a permis d'anticiper les difficultés. La détection d'un data leakage [34] a évité une surestimation artificielle des performances. La comparaison systématique de six modèles avec tuning par `RandomizedSearchCV` [35] et validation croisée stratifiée a respecté les bonnes pratiques d'évaluation. La gestion du déséquilibre des classes a été traitée sous deux angles complémentaires : ajustement des poids (`class_weight='balanced'`) et rééchantillonnage SMOTE [5], confirmant que ni l'une ni l'autre ne peut extraire un signal absent. L'analyse d'interprétabilité multi-méthodes a montré que la divergence entre outils est elle-même informative [19].

Ce projet m'a appris ce que ça veut dire travailler en data scientist : ne pas se contenter de faire tourner des algorithmes, mais comprendre ce que les données peuvent — et ne peuvent pas — dire. Comme le souligne Rudin [19], un bon modèle prédictif ne vaut rien sans une évaluation honnête de ses limites. Cette posture critique, à l'intersection des mathématiques, de la statistique et de l'informatique appliquée, est au cœur de la formation MIAHS.

Les perspectives identifiées — notamment l'application de ce pipeline sur des données épidémiologiques réelles comme les cohortes Framingham [37] ou NHANES [38] — ouvrent des directions concrètes pour un travail de recherche en Master 2, avec l'ambition d'obtenir des modèles à la fois performants, interprétables et éthiquement responsables.

Bibliographie

- [1] World Health Organization. Obesity : preventing and managing the global epidemic. Technical Report 894, WHO, 2000.
- [2] National Cholesterol Education Program. Third report of the expert panel on detection, evaluation, and treatment of high blood cholesterol in adults (atp iii). Technical Report 02-5215, NIH, 2002.
- [3] Bryan Williams et al. 2018 esc/esh guidelines for the management of arterial hypertension. *European Heart Journal*, 39(33) :3021–3104, 2018.
- [4] Pete Chapman et al. Crisp-dm 1.0 : Step-by-step data mining guide. Technical report, SPSS Inc., 2000.
- [5] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote : Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16 :321–357, 2002.
- [6] Ziad Obermeyer and Ezekiel J. Emanuel. Predicting the future — big data, machine learning, and clinical medicine. *New England Journal of Medicine*, 375(13) :1216–1219, 2016.
- [7] Pranav Rajpurkar, Emma Chen, Oishi Banerjee, and Eric J. Topol. Ai in health and medicine. *Nature Medicine*, 28(1) :31–38, 2022.
- [8] Frank W. Booth, Christian K. Roberts, and Matthew J. Laye. Lack of exercise is a major cause of chronic diseases. *Comprehensive Physiology*, 2(2) :1143–1211, 2012.
- [9] Parlement européen et Conseil de l’Union européenne. Règlement (ue) 2016/679 — rgpd, 2016.
- [10] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.
- [11] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning*. Springer, 2 edition, 2021.
- [12] Arthur E. Hoerl and Robert W. Kennard. Ridge regression : Biased estimation for nonorthogonal problems. *Technometrics*, 12(1) :55–67, 1970.
- [13] Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society : Series B*, 58(1) :267–288, 1996.
- [14] Leo Breiman. Random forests. *Machine Learning*, 45(1) :5–32, 2001.
- [15] Tianqi Chen and Carlos Guestrin. Xgboost : A scalable tree boosting system. In *Proceedings of KDD 2016*, pages 785–794, 2016.
- [16] Nathalie Japkowicz and Shaju Stephen. The class imbalance problem : A systematic study. *Intelligent Data Analysis*, 6(5) :429–449, 2002.
- [17] James MacQueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297, 1967.

- [18] Peter J. Rousseeuw. Silhouettes : A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20 :53–65, 1987.
- [19] Cynthia Rudin. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5) :206–215, 2019.
- [20] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 4765–4774, 2017.
- [21] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, ukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.
- [22] Emily Alsentzer, John R. Murphy, Willie Boag, Wei-Hung Weng, Di Jin, Tristan Naumann, and Matthew B. A. McDermott. Publicly available clinical bert embeddings. In *Proceedings of the 2nd Clinical Natural Language Processing Workshop*, pages 72–78, 2019.
- [23] Xin Huang, Ashish Khetan, Milan Cvitkovic, and Zohar Karnin. Tabtransformer : Tabular data modeling using contextual embeddings, 2020. arXiv :2012.06678.
- [24] Yury Gorishniy, Ivan Rubachev, Valentin Khrulkov, and Artem Babenko. Revisiting deep learning models for tabular data. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 34, 2021.
- [25] Léo Grinsztajn, Edouard Oyallon, and Gaël Varoquaux. Why tree-based models still outperform deep learning on tabular data. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 35, 2022.
- [26] Karan Singhal, Shekoofeh Azizi, Tao Tu, et al. Large language models encode clinical knowledge. *Nature*, 620 :172–180, 2023.
- [27] OpenAI. Gpt-4 technical report, 2023. arXiv :2303.08774.
- [28] Elliot Bolton, David Hall, Michihiro Yasunaga, Tony Lee, Chris Manning, and Percy Liang. BioMedLM : A 2.7b parameter language model trained on biomedical text, 2022. Stanford CRFM.
- [29] Nicola Rieke, Jonny Hancox, Wenqi Li, et al. The future of digital health with federated learning. *npj Digital Medicine*, 3(1) :119, 2020.
- [30] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agüera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 1273–1282, 2017.
- [31] Judea Pearl. *Causality : Models, Reasoning and Inference*. Cambridge University Press, 2 edition, 2009.
- [32] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, et al. Toward causal representation learning. *Proceedings of the IEEE*, 109(5) :612–634, 2021.
- [33] Marina Sokolova and Guy Lapalme. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4) :427–437, 2009.

- [34] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining : Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4) :1–21, 2012.
- [35] James Bergstra and Yoshua Bengio. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13 :281–305, 2012.
- [36] David L. Davies and Donald W. Bouldin. A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1(2) :224–227, 1979.
- [37] Thomas R. Dawber, Gilcin F. Meadors, and Felix E. Moore. Epidemiological approaches to heart disease : The framingham study. *American Journal of Public Health*, 41(3) :279–286, 1951.
- [38] Centers for Disease Control and Prevention. National health and nutrition examination survey (nhanes). <https://www.cdc.gov/nchs/nhanes>, 2023.
- [39] Ziad Obermeyer, Brian Powers, Christine Vogeli, and Sendhil Mullainathan. Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464) :447–453, 2019.

ACP	Analyse en Composantes Principales
AUC	Area Under the Curve
CAH	Classification Ascendante Hiérarchique
EDA	Exploratory Data Analysis (Analyse Exploratoire des Données)
ESC	European Society of Cardiology
FE	Feature Engineering
IMC	Indice de Masse Corporelle
MAE	Mean Absolute Error (Erreur Absolue Moyenne)
MIASHS	Mathématiques et Informatique Appliqués aux Sciences Humaines et Sociales
ML	Machine Learning
NCEP	National Cholesterol Education Program
OMS	Organisation Mondiale de la Santé
RMSE	Root Mean Squared Error (Racine de l’Erreur Quadratique Moyenne)
ROC	Receiver Operating Characteristic
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SVM	Support Vector Machine
WHO	World Health Organization

Clustering Méthode d'apprentissage non supervisé visant à regrouper des observations similaires sans variable cible prédéfinie.

Cross-validation (validation croisée) Technique d'évaluation qui consiste à diviser les données en k sous-ensembles et à entraîner/tester le modèle k fois.

Data leakage Fuite d'information du jeu de test vers le jeu d'entraînement, entraînant une surestimation artificielle des performances.

Feature engineering Processus de création ou de transformation de variables à partir des données brutes pour améliorer les performances des modèles.

Feature importance Mesure de la contribution de chaque variable à la prédiction d'un modèle.

Hyperparamètre Paramètre d'un modèle fixé avant l'entraînement (ex. : λ pour Ridge, k pour K-Means).

Overfitting (surapprentissage) Phénomène où un modèle apprend trop précisément les données d'entraînement et généralise mal sur de nouvelles données.

Pipeline Enchaînement structuré d'étapes de traitement des données et de modélisation.

Régularisation Technique pénalisant la complexité d'un modèle pour réduire l'overfitting (ex. : Ridge L_2 , Lasso L_1).

SHAP Méthode d'interprétabilité basée sur la théorie des jeux coopératifs, attribuant à chaque variable une contribution marginale à la prédiction.

Silhouette Coefficient mesurant la qualité d'un clustering : proche de 1 si les clusters sont bien séparés, proche de 0 s'ils se chevauchent.

SMOTE Technique de rééchantillonnage qui génère synthétiquement des exemples de la classe minoritaire pour corriger le déséquilibre des classes.

Tuning Processus d'optimisation des hyperparamètres d'un modèle, souvent via une recherche aléatoire ou par grille.

Annexe A Variables du dataset

Variable	Type	Description	Unité / Modalités
age	Continue	Âge de l'individu	années
bmi	Continue	Indice de masse corporelle	kg/m ²
daily_steps	Continue	Nombre de pas quotidiens	pas/jour
sleep_hours	Continue	Durée de sommeil	heures/nuit
water_intake_l	Continue	Consommation d'eau	litres/jour
calories_consumed	Continue	Apport calorique quotidien	kcal/jour
smoker	Binaire	Statut tabagique	0 = non, 1 = oui
alcohol	Binaire	Consommation d'alcool	0 = non, 1 = oui
resting_hr	Continue	Fréquence cardiaque au repos	bpm
systolic_bp	Continue	Pression artérielle systolique	mmHg
diastolic_bp	Continue	Pression artérielle diastolique	mmHg
cholesterol	Continue	Taux de cholestérol total	mg/dL
family_history	Binaire	Antécédents familiaux de maladie	0 = non, 1 = oui
gender	Catégorielle	Sexe de l'individu	Male / Female
disease_risk	Binaire	Variable cible : risque de maladie	0 = non, 1 = oui

Annexe B Hyperparamètres testés (RandomizedSearchCV)

Modèle	Hyperparamètre	Valeurs explorées
Ridge	alpha	[0.01, 0.1, 1, 10, 100]
Lasso	alpha	[0.001, 0.01, 0.1, 1, 10]
ElasticNet	alpha, l1_ratio	[0.01–10], [0.1, 0.5, 0.9]
Random Forest	n_estimators, max_depth	[50, 100, 200], [5, 10, 15]
XGBoost	learning_rate, n_estimators	[0.01, 0.05, 0.1], [100, 200]