

Modélisation des comportements de santé par apprentissage automatique

Régression, classification et clustering sur données synthétiques

Ardacham Mahamat Tegouene

Master 1 MIA SHS — Université de Montpellier Paul Valéry

Tuteurs : Sophie Lèbre & Jérôme Pasquet

Juin 2026

Plan de la présentation

Contexte et problématique

Jeu de données et pipeline

Analyse exploratoire (EDA)

Modélisation supervisée

Clustering et interprétabilité

Bilan et perspectives

Question centrale

**Quels facteurs du mode de vie influencent le plus l'état de santé
— et peut-on les identifier, les modéliser et les expliquer ?**

Motivations :

- ▶ Les maladies chroniques résultent de comportements quotidiens mesurables
- ▶ Données de santé de plus en plus disponibles (IoT, dossiers médicaux)
- ▶ ML peut modéliser des relations complexes là où la statistique classique atteint ses limites

Seuils médicaux de référence :

- ▶ Obésité : $IMC > 30$ (OMS)

Le jeu de données — *Health & Lifestyle Dataset*

Caractéristiques :

- ▶ **100 000 individus**, 15 variables
- ▶ Dataset **synthétique** (Kaggle)
- ▶ Aucune valeur manquante
- ▶ Aucun outlier (méthode IQR)


Variables cibles :

- ▶ cholesterol → régression
- ▶ disease_risk → classification

Types de variables :

Type	Variables
Continues	age, bmi, steps sleep, cholesterol systolic_bp, hr
Binaires	smoker, alcohol family_history disease_risk
Catégorielle	gender

Pipeline CRISP-DM



- ▶ Approche **itérative** : chaque étape informe la suivante
- ▶ EDA → anticipe les problèmes de signal
- ▶ Feature engineering → 3 variables métier créées, data leakage détecté

Distributions

- ▶ Skewness $< |0.02|$ pour toutes les variables continues
- ▶ Distributions **quasi-uniformes**
- ▶ Aucune transformation nécessaire

Classe cible

- ▶ Déséquilibre **75% / 25%**
- ▶ Modèle naïf $\rightarrow$ 75%

Résultat central

- ▶ Corrélations $< |0.01|$ entre **toutes** les variables
- ▶ Variable la plus corrélée à `disease_risk` : `resting_hr` avec $r = 0.005$
- ▶ **Signal linéaire quasi-nul**

Implication : orientation vers les méthodes non-linéaires (RF, XGBoost)

Régression — Protocole et modèles

Objectif : prédire cholestérol (mg/dL)

Protocole :

- ▶ Split 80/20 — Validation croisée K-Fold ($k = 5$)
- ▶ Tuning par RandomizedSearchCV ($n_iter=20$)
- ▶ Métriques : R^2 , RMSE, MAE

6 modèles — logique de spectre de complexité :

Modèle	Type	Spécificité
Régression linéaire	Baseline	Référence
Ridge (L_2)	Régularisée	Réduit les coefficients
Lasso (L_1)	Régularisée	Annule des coefficients
ElasticNet	Régularisée	$L_1 + L_2$
Random Forest	Ensemble	Non-linéaire, parallèle
XGBoost	Ensemble	Non-linéaire, séquentiel

Régression — Résultats

Modèle	R^2	RMSE	MAE	CV- R^2
Linéaire (baseline)	0.0001	43.33	37.59	≈ 0
Ridge (tuné)	0.0001	43.33	37.59	≈ 0
Lasso (tuné)	-0.000	43.33	37.60	≈ 0
ElasticNet	-0.000	43.33	37.60	≈ 0
Random Forest	-0.005	43.44	37.67	≈ 0
XGBoost (tuné)	0.0001	43.33	37.59	≈ 0

Analyse critique

- ▶ **Lasso** : 16/16 coefficients = 0 $\rightarrow$ prédit la moyenne (224.3 mg/dL)
- ▶ **Data leakage** sur hypercholesterol : R^2 0.675 artificiel, corrigé à ≈ 0

Classification — Résultats

Protocole : split stratifié 80/20, K-Fold stratifié ($k = 5$),
`class_weight='balanced'` vs SMOTE

Modèle	Accuracy	Précision	Rappel	F1	AUC
Naïf (tout à 0)	0.752	n/a	0.000	0.000	0.500
Logistic Reg.	0.498	0.249	0.509	0.335	0.499
Random Forest	0.568	0.245	0.355	0.290	0.494
XGBoost	0.525	0.246	0.441	0.316	0.499

Analyse critique

- ▶ **AUC ≈ 0.5** pour tous = équivalent à un tirage aléatoire
- ▶ SMOTE et `class_weight` ne peuvent pas extraire un signal absent
- ▶ Cohérent avec la régression : `disease_risk` généré

Clustering — K-Means et CAH

K-Means ($k = 3$)

CAH Ward ($n = 5\,000$)

Cluster	Profil	IMC	Cluster	Profil
0	Obèse hypertendu	35.00		Non-fumeurs, HTA
1	Surpoids normotendu	29.11		Fumeurs modérés
2	Normal hypertendu	24.02		Fumeurs intenses, HTA

Partition : **IMC** + **pression**
systolique

Isole un groupe de **fumeurs**
intenses

Métrique	K-Means	CAH	
Silhouette	0.103	0.105	Faible — données sans structure
ACP 2D	24.3% de variance		15 dims quasi-indépendantes

Interprétabilité — Convergence des méthodes

5 méthodes : coefficients LR, Ridge, feature importance RF & XGBoost, SHAP

Variable	LR	RF	XGB	SHAP	Ridge	Score
systolic_bp	✓	✓	✓	✓	✓	5/5
daily_steps	✓	✓	.	✓	.	3/5
family_history	✓	.	✓	.	✓	3/5
bmi	.	✓	.	✓	.	2/5

Interprétation

- ▶ Les 5 méthodes **ne convergent pas** → elles mesurent du bruit aléatoire
- ▶ systolic_bp partout : grande variance, pas signal causal
- ▶ **La divergence est elle-même un résultat analytique**

Bilan — Résultat central

Limite fondamentale du dataset synthétique

Les variables ont été générées **indépendamment**, sans relation causale encodée.

Aucune technique ne peut extraire un signal qui n'existe pas.

Ce que ça prouve :

- ▶ Corrélations < 0.01 en EDA prédisaient ce résultat
- ▶ Lasso : 16/16 coefficients = 0
- ▶ $R^2 \approx 0$, AUC ≈ 0.5 partout
- ▶ Interprétabilité

Ce n'est pas un échec :

- ▶ Data leakage détecté et corrigé
- ▶ Pipeline rigoureux et complet
- ▶ Diagnostic critique mené à chaque étape
- ▶ Directement transposable à des données réelles

Perspectives

1. **Changer de dataset** — cohortes Framingham ou NHANES : vraies relations biologiques, même pipeline
2. **Améliorer la classification** — stacking, réseaux de neurones (Deep Learning, M2)
3. **Déploiement** — API REST (FastAPI) avec prédictions + valeurs SHAP associées
4. **Interprétabilité avancée** — Partial Dependence Plots (PDP), ICE
5. **Data drift** — suivi de l'AUC sur nouvelles cohortes, réentraînement périodique
6. **Master 2** — causalité, fairness algorithmique, apprentissage fédéré

Merci pour votre attention

Questions ?

Ardacham Mahamat Teguene — M1 MIASHS — Juin 2026