



Modélisation des comportements de santé par apprentissage automatique

Régression, classification et clustering sur données synthétiques

ARDACHAM Mahamat Teguene

Master 1 MASHS — Université de Montpellier Paul Valéry

Tuteurs : Sophie Lèbre & Jérôme Pasquet — Juin 2026

Plan de la présentation

- I Introduction
- II Problématique et contextes
- III Jeu de données et Pipeline
- IV Etat de l'art
- V Analyse exploratoire des données (EDA)
- VI Feature Engineering
- VII Régression
- VIII Classification
- IX Clustering
- X Interprétabilité — 5 méthodes comparées
- XI Conclusion

I. Introduction

Aujourd'hui :

- Les montres connectées mesurent notre sommeil
- Les applications comptent nos pas
- Les bilans sanguins enregistrent notre cholestérol
- ...

On génère sans le savoir **une quantité massive d'informations** sur nos habitudes de vie.

Mais avoir des données ne suffit pas : encore faut-il savoir les analyser, les comprendre, et en tirer des conclusions utiles.

C'est exactement ce que permet la data science, elle offre des outils pour :

- explorer des jeux de données complexes
- construire des modèles prédictifs
- expliquer ce qui se passe derrière les chiffres.

II. Problématique et contextes – contexte data science

PROBLÉMATIQUE

Quels facteurs du mode de vie influencent le plus l'état de santé — et peut-on les identifier, les modéliser et les expliquer de manière rigoureuse ?

Contexte data science

La data science permet aujourd'hui d'aborder des problèmes variés :

- prédiction du risque de maladies chroniques,
- segmentation de populations selon leurs profils de santé,
- identification des facteurs de risque comportementaux,
- ...

Objectif : prédire une personne est à risque de maladie ET expliquer (interprétabilité) :

Est-ce à cause de son manque de sommeil ? De son cholestérol élevé ? De son inactivité physique ?


Variable cible régression : cholesterol (mg/dL) | Variable cible classification : disease_risk (0/1)

II. Problématique et contextes – contexte metier

Contexte métier

Les maladies chroniques — maladies cardiovasculaires, diabète de type 2, hypertension :

- représentent aujourd’hui la première cause de mortalité mondiale [1],
- se développent progressivement sous l’effet d’une accumulation de comportements quotidiens :



Ameli – Le risque cardiovasculaire et ses facteurs

Ces facteurs comportementaux laissent des traces mesurables dans les indicateurs biologiques.

[1] Frank W. Booth, Christian K. Roberts, and Matthew J. Laye. Lack of exercise is a major cause of chronic diseases. *Comprehensive Physiology*, 2(2) :1143–1211, 2012.

II. Problématique et contextes – seuils médicaux

Seuils médicaux de référence

- Obésité : IMC > 30 (seuil OMS) = un déséquilibre énergétique chronique
- Hypercholestérolémie : taux de cholestérol > 200 mg/dL (NCEP) = un risque cardiovasculaire accru
- Hypertension : pression systolique ≥ 140 mmHg (ESC) = une hypertension

L'enjeu est donc double :

1)

Comprendre comment les habitudes de vie se traduisent en risques mesurables

2)

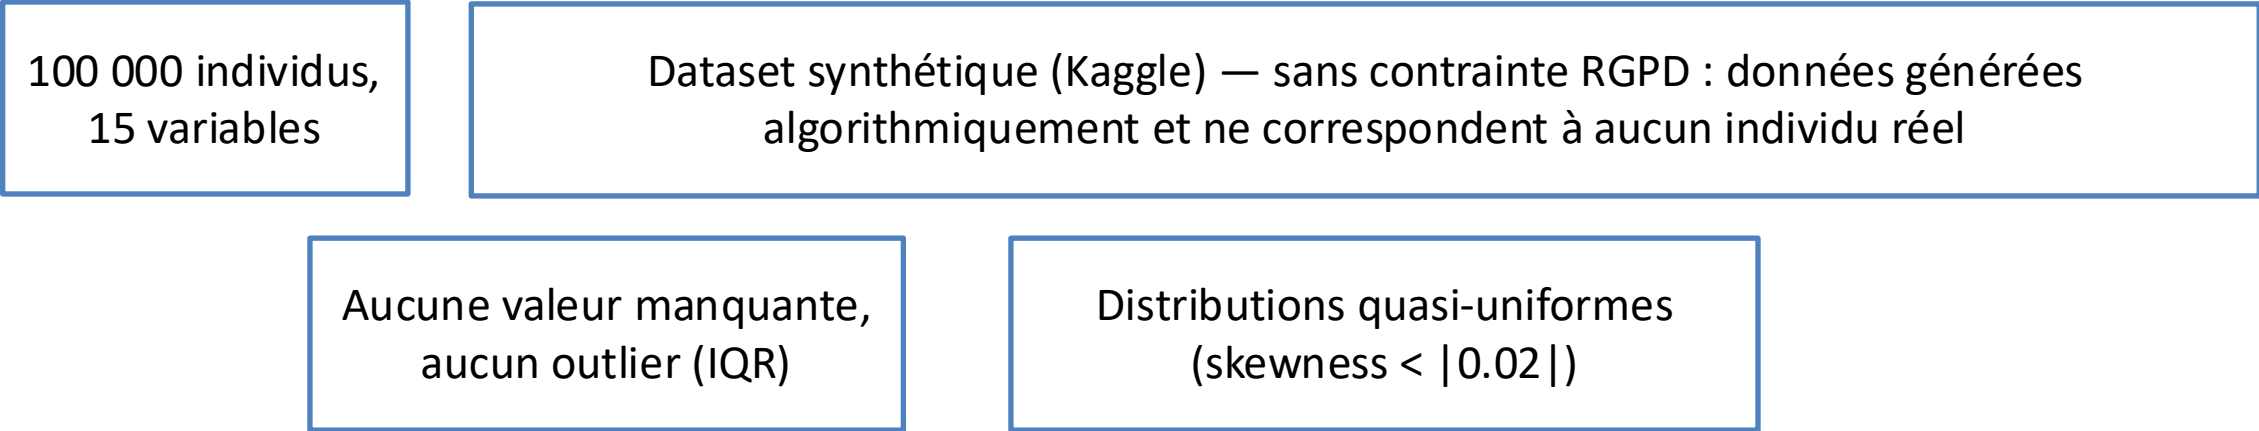
Evaluer dans quelle mesure des modèles de ML peuvent capturer ces relations à partir de données

III. Jeu de données et Pipeline


Type	Variables
Habitudes de vie (6)	daily_steps, sleep_hours, water_intake_l, calories_consumed, smoker, alcohol
Indicateurs biologiques (5)	bmi, resting_hr, systolic_bp, diastolic_bp, cholesterol
Caractéristiques personnelles (4)	age, gender, family_history

Table 3.1 - Variables

Points clés



III. Jeu de données et Pipeline



Approche itérative : chaque étape informe la suivante (EDA → anticipation des problèmes de signal → choix des modèles → interprétabilité)

Tâche	Meilleur modèle	Métrique principale	Conclusion
Régression	XGBoost tuné	R ² = 0.0001	Aucun signal — tous équivalents
Classification	Logistic Regression	AUC = 0.499	Équivalent tirage aléatoire
Clustering	K-Means k=3	Silhouette = 0.103	Profils biologiques interprétables

IV. Etat de l'art — ML en santé






Figure 4.1 - Vue d'ensemble des familles d'algorithmes ML (d'après Rajpurkar et al., 2022)




Prédiction du risque cardiovasculaire

Type 2 Diabetes Symptoms



Détection précoce du diabète de type 2



Stratification de patients par profil de mode de vie

IV. Etat de l’art — comparatif des algorithmes utilisés

Algorithme	Famille	Type	Avantage clé	Limite
Régression linéaire	Linéaire	Supervisé	Interprétable, baseline	Relations linéaires seulement
Ridge (L2)	Régularisée	Supervisé	Stabilise coefficients instables	Ne sélectionne pas les variables
Lasso (L1)	Régularisée	Supervisé	Sélection automatique vars.	Élimine variables corrélées
ElasticNet (L1+L2)	Régularisée	Supervisé	Combine Ridge + Lasso	2 hyperparamètres à tuner
Random Forest	Ensemble	Supervisé	Non-linéaire, parallèle	Peu interprétable
XGBoost	Ensemble	Supervisé	Corrige erreurs séquentielles	Risque surapprentissage
Régression logistique	Linéaire	Classif.	Interprétable, rapide	Frontière de décision linéaire
K-Means	Partitionnel	Non superv.	Rapide, O(n)	k fixé, sensible aux outliers
CAH Ward	Hiérarchique	Non superv.	Dendrogramme lisible	O(n²) → 5 000 individus max

Table 4.1 - Vue d'ensemble des comparatifs des algorithmes utilisés

V. Analyse exploratoire des données (EDA)

Présentation générale du dataset

Le jeu de données contient 100 000 observations décrites par 15 variables (l'identifiant id est exclu).

Type	Variables
Continues (10)	age, bmi, daily_steps, sleep_hours, cholesterol, systolic_bp, diastolic_bp, resting_hr, water_intake_l, calories_consumed
Binaires (4)	smoker, alcohol, family_history, disease_risk
Catégorielle (1)	gender

Table 5.1 – Type de variables

Statistiques descriptives

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$
$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Table 5.2 – Statistiques descriptives des variables continues

Variable	Moyenne	Écart-type	Min	Max
age	48.5 ans	17.9	18	79
bmi	29.0	6.3	18.0	40.0
daily_steps	10 480	5 484	1 000	19 999
sleep_hours	6.5 h	2.0	3.0	10.0
cholesterol	224.3 mg/dL	43.3	150	299
systolic_bp	134.6 mmHg	26.0	90	179
resting_hr	74.5 bpm	14.4	50	99


V. Analyse exploratoire des données (EDA)

Distributions des variables continues

Le coefficient d'asymétrie (skewness) mesure la symétrie d'une distribution :

$$\text{Skew}(X) = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

Skewness > 1 = distribution très asymétrique, biaise les modèles linéaires et nécessite une transformation log.



Toutes les variables continues affichent un **skewness < |0.02|** : distributions quasi-uniformes

=>

Génération synthétique aléatoire des données


Figure 5.1 – Distributions des variables continues du dataset

V. Analyse exploratoire des données (EDA)

Analyse des corrélations

Le coefficient de corrélation de Pearson entre deux variables X et Y :

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$$



Résultat central

Toutes les corrélations < |0.01|

La plus élevée avec disease_risk : resting_hr avec r= 0.01
(non significatif sur 100 000 individus)

disease_risk généré indépendamment



Méthodes non-linéaires : Random Forest ou XGBoost :

- peuvent théoriquement capturer des relations plus complexes
- échoueront même ici, ce qui confirme l'absence totale de signal.


Figure 5.2 – Matrice de corrélation de Pearson entre toutes les variables du dataset

V. Analyse exploratoire des données (EDA)

disease_risk présente un déséquilibre des classes : 75.2% sont sans risque contre seulement 24.8% à risque.

Problème : un modèle naïf qui prédit toujours "sans risque" obtient déjà 75% d'accuracy — sans avoir rien appris.

Solution : on privilégie le F1-score, la précision, le rappel et l'AUC-ROC capables de détecter les deux classes.



Bilan de l'EDA

Point	Constat
Valeurs manquantes	Aucune
Distributions	Quasi-uniformes (skewness < 0.02)
Outliers	Aucun (méthode IQR)
Corrélations	Quasi-nulles (< 0.01)
Classe cible	Déséquilibrée (75/25)

Table 5.3 – Bilan de l'analyse exploratoire

Figure 5.3 - Déséquilibre 75% / 25% — un modèle naïf atteint 75% d'accuracy sans rien apprendre

VI. Feature Engineering

Encodage des variables catégorielles

$$\text{gender_enc} = \begin{cases} 1 & \text{si Male} \\ 0 & \text{si Female} \end{cases}$$

$$\text{hypercholesterol} = \begin{cases} 1 & \text{si cholestérol} > 200 \text{ mg/dL} \\ 0 & \text{si cholestérol} \leq 200 \text{ mg/dL} \end{cases}$$

Variable temporaire, dérivée de la variable cible, créée pour le clustering

3 variables métier créées à partir des connaissances médicales

$$\text{hypertension} = \begin{cases} 1 & \text{si systolic_bp} \geq 140 \text{ ou diastolic_bp} \geq 90 \\ 0 & \text{sinon} \end{cases}$$

Seuil ESC : European Society of Cardiology

$$\text{bmi_cat} = \begin{cases} 0 & \text{bmi} < 18.5 \text{ (sous-poids)} \\ 1 & 18.5 \leq \text{bmi} < 25 \text{ (normal)} \\ 2 & 25 \leq \text{bmi} < 30 \text{ (surpoids)} \\ 3 & \text{bmi} \geq 30 \text{ (obèse)} \end{cases}$$

Seuil OMS : Organisation Mondiale de la Santé

$$\text{lifestyle_score} = \frac{\text{daily_steps}}{\text{max}} + \frac{\text{sleep_hours}}{\text{max}} + \frac{\text{water_intake_l}}{\text{max}} - \text{smoker} - \text{alcohol} - \frac{\text{bmi}}{\text{max}} - \frac{\text{calories_consumed}}{\text{max}}$$

Score composite heuristique où chaque variable continue est divisée par son maximum pour la ramener entre 0 et 1, ce qui évite qu'une variable à grande échelle (comme daily_steps, jusqu'à 20 000) domine une variable à petite échelle (comme sleep_hours, entre 3 et 10).

Termes positifs = comportements bénéfiques pour la santé | **Termes négatifs** = facteurs de risque établis

VII. Régression — prédire le taux de cholestérol

Selon le NCEP, le cholestérol est un facteur de risque cardiovasculaire reconnu.

Objectif : prédire le taux de cholestérol (en mg/dL) à partir des habitudes de vie et indicateurs biologiques.

Data Leakage détecté et corrigé

hypercholesterol directement dérivée de la variable cible : 'donner la réponse' au modèle

Exclue de la régression, conservée uniquement pour le clustering

R^2 artificiel = 0.675 avec leakage $\rightarrow R^2 \approx 0$ après suppression

Protocole expérimental

Split 80/20
(random_state=42) :
80 000 train / 20 000 test

K-Fold k=5 :
16 000 exemples/fold,
bon compromis coût/fiabilité

RandomizedSearchCV
n_iter=20 : 20 tirages
aléatoires vs GridSearch
exhaustif

Métriques :
 R^2 , RMSE (mg/dL), MAE
(mg/dL)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

VII. Régression — Résultats

Modèle	R^2	RMSE (mg/dL)	MAE (mg/dL)	CV- R^2
LinearRegression (baseline)	0.0001	43.33	37.59	≈ 0
Ridge ($\lambda = 7197$, tuné)	0.0001	43.33	37.59	≈ 0
Lasso ($\lambda = 9.54$, tuné)	-0.0000	43.33	37.60	≈ 0
ElasticNet	-0.0000	43.33	37.60	≈ 0
Random Forest (tuné)	-0.005	43.44	37.67	≈ 0
XGBoost (tuné)	0.0001	43.33	37.59	≈ 0

Table 7.1 – Résultats de régression (variable cible : cholesterol)

Analyse critique

- Lasso (tuné) fixe 16/16 coefficients à 0, il prédit uniquement la moyenne (224.3 mg/dL) pour chaque individu
- Random Forest : $R^2 < 0$ est pire que la moyenne (surajustement du bruit)
- XGBoost : $R^2 = 0.0001$
- Data leakage corrigé : R^2 0.675 $\rightarrow \approx 0$ après suppression de hypercholesterol
- Différences entre -0.005 et 0.0001 statistiquement négligeables, aucun modèle retenu

Cause : variables générées indépendamment — signal absent par construction

VIII. Classification — prédire le risque de maladie

Objectif : prédire si un individu est à risque de maladie (disease_risk = 1) ou non (disease_risk = 0)

Le dataset présente un déséquilibre de classes : 75.2% sans risque, 24.8% à risque.

Protocole expérimental

Split stratifié 80/20 : stratify=y
maintient le ratio 75.2/24.8

Stratified K-Fold (k = 5) :
maintient le ratio de classes dans
chaque exemple/fold.

Gestion du déséquilibre :
SMOTE crée de faux individus
supplémentaires dans la minoritaire

Sans stratification, un fold pourrait ne contenir que des individus sans risque et biaiser l'évaluation

Métriques d'évaluation

$$\text{Précision} = \frac{TP}{TP + FP}$$

$$\text{Rappel} = \frac{TP}{TP + FN}$$

$$\text{F1-score} = \frac{2 \times \text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

VIII. Classification — Résultats

Modèle	Accuracy	Précision	Rappel	F1	AUC-ROC
Naïf (tout à 0)	0.752	—	0.000	0.000	0.500
Logistic Regression	0.498	0.249	0.509	0.335	0.499
Random Forest	0.568	0.245	0.355	0.290	0.494
XGBoost	0.525	0.246	0.441	0.316	0.499

Table 3.2 – Résultats de classification (variable cible : *disease_risk*)

La précision du modèle naïf est indéfinie : $TP = 0$, $FP = 0$

Analyse critique

- $AUC \approx 0.5$ pour tous = équivalent à un tirage aléatoire
- SMOTE : même résultat — ne peut pas créer un signal absent
- `class_weight='balanced'` : rappel monte mais $accuracy < 50\%$, ils sur corrigent le déséquilibre au détriment de la précision
- Accuracy seule trompeuse sur données déséquilibrées → F1 + AUC obligatoires
- Cohérent avec régression : *disease_risk* généré indépendamment de toutes les variables




Figure 8.1 — Courbes ROC — $AUC \approx 0.5$

VIII. Classification — Résultats




Figure 8.2 — Matrices de confusion des trois modèles de classification

Quel est le meilleur modèle en classification ?

Aucun modèle n'est retenu pour déploiement.

AUC ≈ 0.5 pour tous, aucun ne discrimine mieux qu'un tirage aléatoire : choisir le « meilleur » n'a pas de sens statistique.

IX. Clustering — identifier des profils de mode de vie


Objectif : regrouper les individus selon leur similarité pour identifier des profils types de mode de vie.

Pas de variable cible, la variable `disease_risk` est exclue du clustering.

Préparation des données

Les variables explicatives sont standardisées (z-score) avant d'appliquer les algorithmes pour garantir une contribution équitable de toutes les dimensions : `daily_steps` (valeurs jusqu'à 20 000) dominerait `sleep_hours` (valeurs entre 3 et 10).

Sélection du nombre de clusters - méthode du coude et coefficient de silhouette



k	Inertie	Silhouette
2	1 346 768	0.0979
3	1 238 076	0.1030
4	1 188 303	0.0967
5	1 152 260	0.0886
10	1 031 548	0.0744

Table 9.1 — Inertie et silhouette selon k (K-Means)

k = 3 maximise la silhouette et correspond au coude de la courbe d'inertie.

Figure 9.1 — Inertie intra-cluster et coefficient de silhouette selon k (K-Means)

IX. Clustering — K-Means & CAH

K-Means : partitionne la population selon l’IMC bmi ($\sigma = 6.3$) et la pression artérielle systolique systolic_bp ($\sigma = 26.0$).

Cluster	Taille	IMC moyen	Syst. (mmHg)	Profil
0	32 754	35.0 (obèse)	142 (hypertendu)	Obèse hypertendu
1	27 673	29.1 (surpoids)	115 (normotendu)	Surpoids normotendu
2	39 573	24.0 (normal)	142 (hypertendu)	Poids normal hypertendu

Table 9.2 — Profils des clusters K-Means ($k = 3$)

CAH : construit un dendrogramme en fusionnant progressivement les clusters les plus proches.

Ward cherche des sous-groupes homogènes, y compris sur des variables binaires comme smoker.

Cluster	Taille	Fumeurs	Syst. (mmHg)	Profil
0	2 928	2%	142	Non-fumeurs hyperten dus
1	1 407	18%	115	Fumeurs modérés, normotendus
2	665	100%	142	Fumeurs intenses, hyperten dus

Table 9.3 — Profils des clusters CAH ($k = 3, n = 5\ 000$)

IX. Clustering — Evaluation et visualisation

Visualisation par ACP : données vivent dans un espace à 15 dimensions : il est impossible de les représenter directement. Les deux premières composantes expliquent 24.3% de la variance totale. Avec 15 variables quasi-indépendantes (l'EDA) : 24.3% en 2D est donc attendu.

Métrique	K-Means	CAH	Interprétation
Silhouette	0.103	0.105	Faible — clusters peu séparés
Variance ACP (2D)	24.3%		Projection insuffisante (15 dims → 2D)

Table 9.4 — Comparaison K-Means vs CAH

Malgré des silhouettes faibles (≈ 0.10), on a des profils :

- obèse hypertendu (K-Means)
- fumeurs intenses + hypertendus(CAH)

La faible silhouette reflète l'absence de groupes naturels francs dans des données synthétiques générées sans structure causale — pas une erreur méthodologique.




Figure 9.2 — Visualisation des clusters K-Means ($k = 3$) par projection ACP (2 composantes, 24.3% de variance)

X. Interprétabilité — 5 méthodes comparées

Les outils d’interprétabilité convergent-ils vers les mêmes variables influentes, même en l’absence de signal ?

Outils utilisés : coefficients des modèles linéaires, impureté de Gini et SHAP (complément visuel).

Variable	LR	RF	XGB	SHAP	Ridge	Score
systolic_bp	✓	✓	✓	✓	✓	5/5
daily_steps	✓	✓	—	✓	—	3/5
family_history	✓	—	✓	—	✓	3/5
bmi	—	✓	—	✓	—	2/5

Table 10.1 – Variables dans le top 5 de chaque méthode d’interprétabilité

- Les 5 méthodes ne convergent pas, mesurent du bruit aléatoire
- systolic_bp partout : grande variance, pas signal causal
- Divergence = résultat analytique en soi (Rudin 2019)

Sur données réelles : cholestérol, tabagisme, IMC domineraient




Figure 10.1 – SHAP summary plot (XGBoost) — complément visuel d’interprétabilité

X. Interprétabilité — Résultat central

Limite fondamentale du dataset synthétique

Variables générées indépendamment — sans relation causale encodée.

Aucune technique ne peut extraire un signal qui n'existe pas.

Preuves convergentes

- Corrélations < 0.01 dès l'EDA le prédisait
- Lasso : 16/16 coefficients = 0
- $R^2 \approx 0$ et AUC ≈ 0.5 pour tous les modèles
- Data leakage détecté et corrigé (R^2 0.675 $\rightarrow$ 0)
- Interprétabilité divergente (5 méthodes)

Ce n'est pas un échec — valeur méthodologique

- Pipeline complet et rigoureux (CRISP-DM)
- Détection du data leakage — piège rare en cours théoriques
- Validation croisée stratifiée systématique
- Directement transposable à des données réelles (Framingham)

« Savoir diagnostiquer pourquoi un modèle échoue est aussi précieux que d'en construire un qui réussit. »

XI. Conclusion — Perspectives

Perspectives

- Changer le dataset (Framingham ou NHANES) — vraies relations biologiques
- Deploiement API REST (FastAPI) : profil individuel → prédiction + valeurs SHAP
- Master 2 : Causalité
- Interprétabilité avancée

Note sur l'utilisation de IA - Claude

- Recherche bibliographique
- Structuration du document
- Relecture et reformulation
- Débogage et code

XI. Conclusion — Outils & Enseignements

Catégorie	Outil	Usage
Langage	Python 3	Ensemble du projet
Manipulation données	pandas, numpy	Chargement, nettoyage, feature engineering
Modélisation	scikit-learn, xgboost	Entraînement, tuning, évaluation
Déséquilibre classes	imbalanced-learn	Rééchantillonnage SMOTE
Interprétabilité	shap	Valeurs SHAP sur XGBoost
Réduction de dim.	scikit-learn (PCA)	Visualisation clustering
Versionnement	Git / GitHub	Suivi des notebooks et du rapport
Rédaction	L ^A T _E X	Mémoire

Table 11.1 – Outils et environnement technique

Enseignement M1	Application dans le projet
ACP / ACM	Réduction dimensionnelle pour la visualisation des clusters
Régression linéaire & diagnostic	Baseline régression, Ridge, Lasso, ElasticNet
Classification supervisée	Logistic Regression, Random Forest, XGBoost
Apprentissage non supervisé	K-Means, CAH
Descente de gradient & optimisation	Compréhension de XGBoost et de la log-loss
Régression logistique	Baseline classification + interprétation coefficients
Régularisation & optimisation	Ridge, Lasso, ElasticNet
Déséquilibre de classes	class_weight, SMOTE (imbalanced-learn)
Python	Ensemble du pipeline de data science

Table 11.2 – Lien entre enseignements MIASHS et applications projet

World Health Organization. Obesity : preventing and managing the global epidemic. Technical Report 894, WHO, 2000.

National Cholesterol Education Program. Third report of the expert panel on detection, evaluation, and treatment of high blood cholesterol in adults (atp iii). Technical Report 02-5215, NIH, 2002.

Bryan Williams et al. 2018 esc/esh guidelines for the management of arterial hypertension. European Heart Journal, 39(33) :3021–3104, 2018.

Pete Chapman et al. Crisp-dm 1.0 : Step-by-step data mining guide. Technical report, SPSS Inc., 2000.

Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote : Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16 :321–357, 2002.

Ziad Obermeyer and Ezekiel J. Emanuel. Predicting the future — big data, machine learning, and clinical medicine. New England Journal of Medicine, 375(13) :1216–1219, 2016.

...

Merci pour votre attention

Questions ?
